大数据系统与大规模数据分析

大数据存储系统（1）

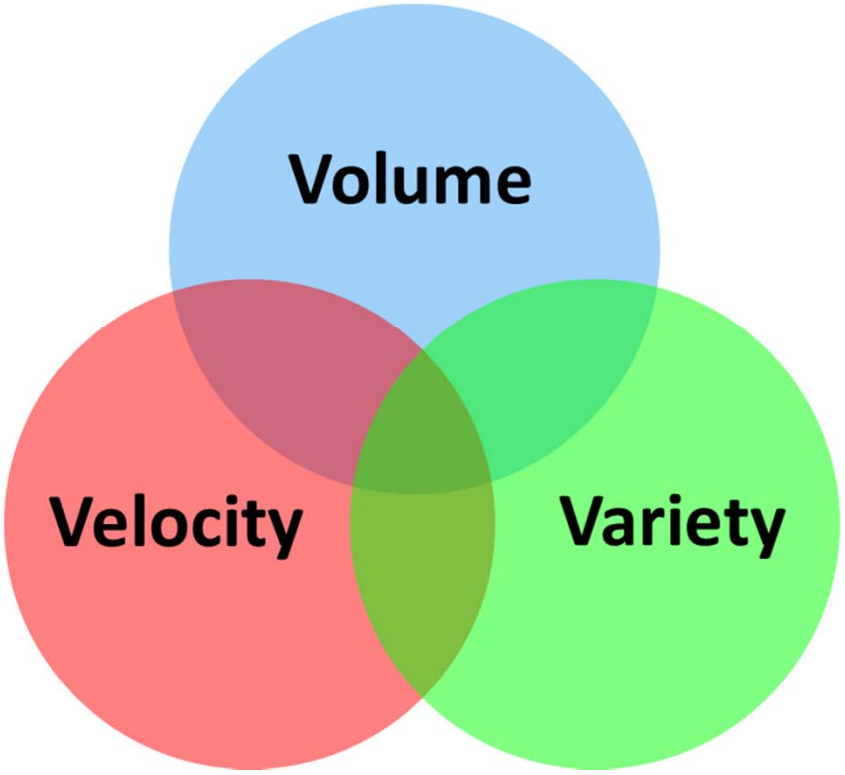

陈世敏

中科院计算所
计算机体系结构
国家重点实验室

Outline

- 分布式系统基本概念
- 分布式文件系统
- Google File System和HDFS

Outline

- 分布式系统基本概念
  - 网络与协议
  - 通信方式
  - 分布式系统类型、故障类型、CAP
- 分布式文件系统
- Google File System和HDFS

Internet（互联网）

- 为什么叫Internet?
  - Internet: the network of networks
- Network: network of devices
  - 通过网线、无线、交换机等把设备连接起来
  - 设备：计算机、平板、手机、无线传感器……
  - 局域网：实验室、家庭内网、数据中心网络、校园网、公司内网……
- Network of networks
  - 把一个个局域网连接起来
  - 形成覆盖全球的网络
- 谁来连？
  - ISP (Internet Service Provider) 建立各自的骨干网
  - 骨干网(Backbone network)：通常是光纤
  - 是冗余的，两地之间通常存在不同ISP的不止一条线路

AT&T美国骨干网

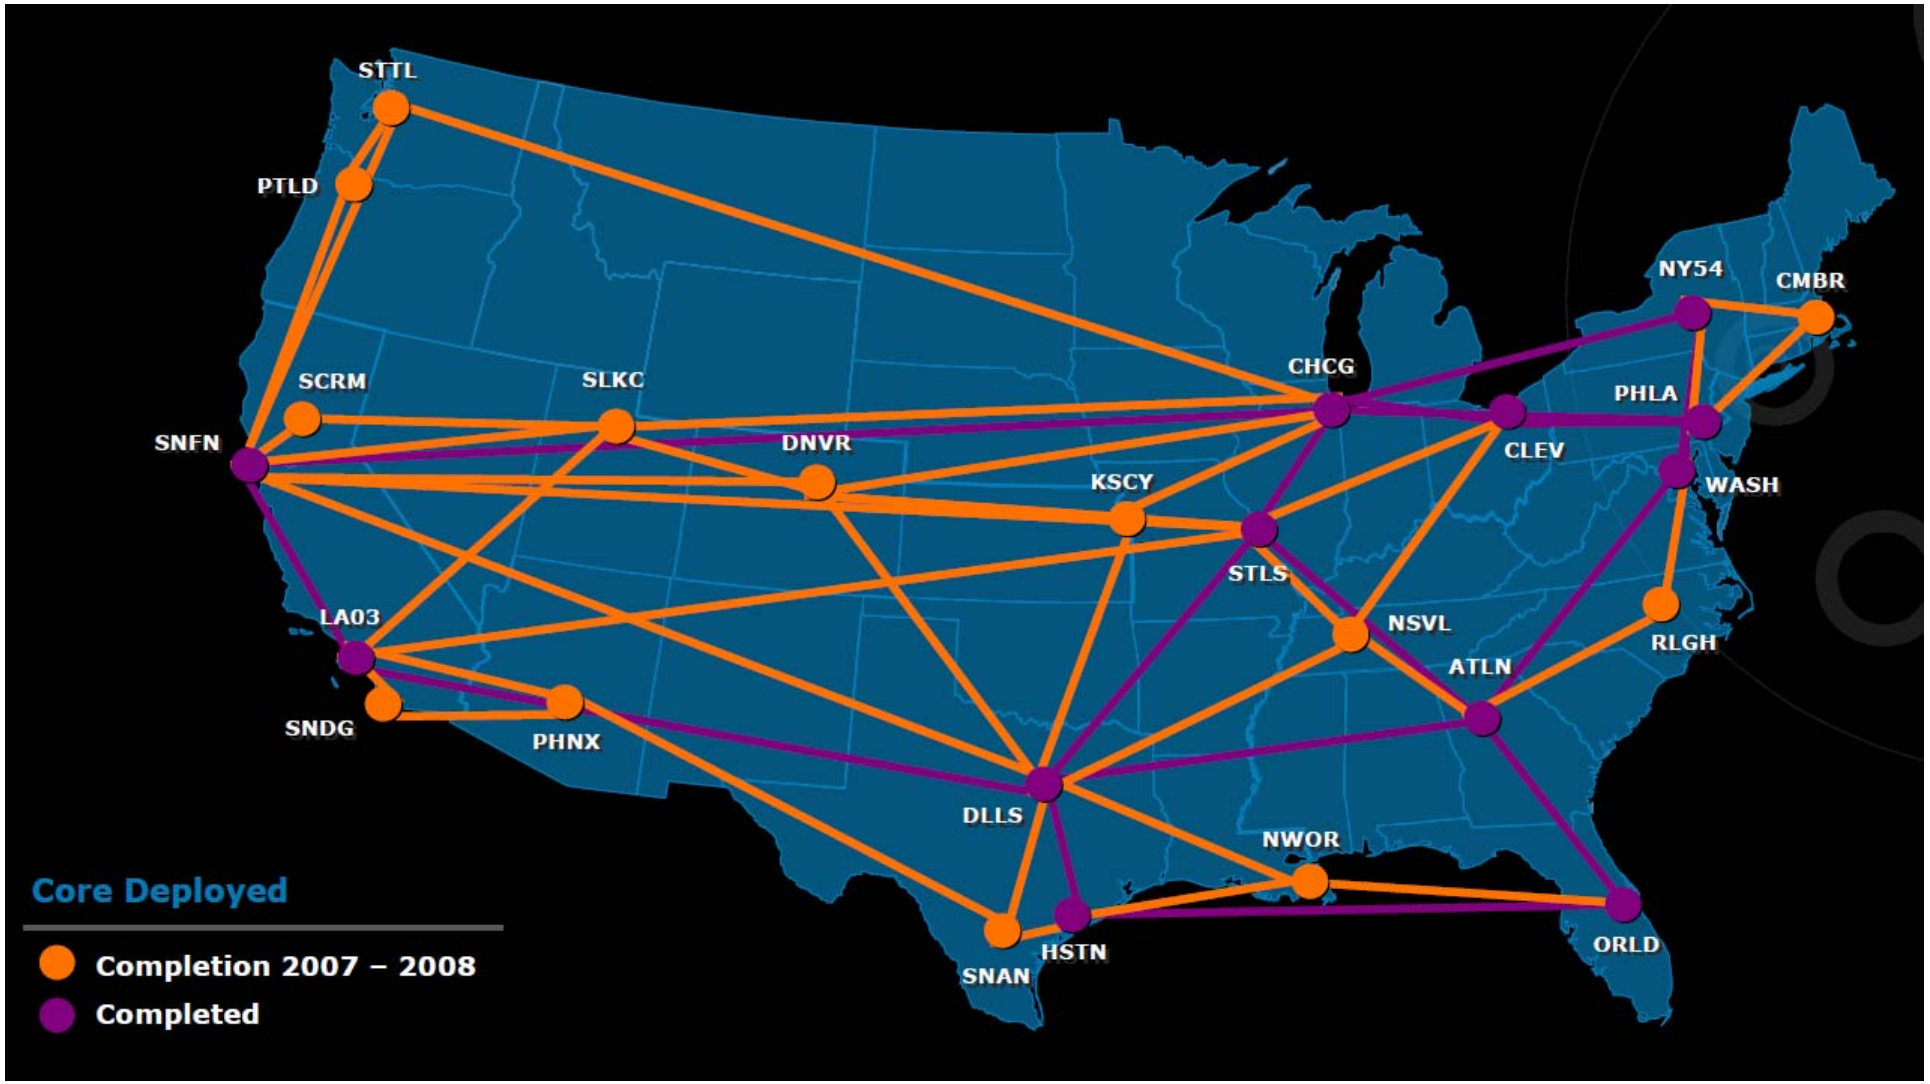

Sprint美国骨干网

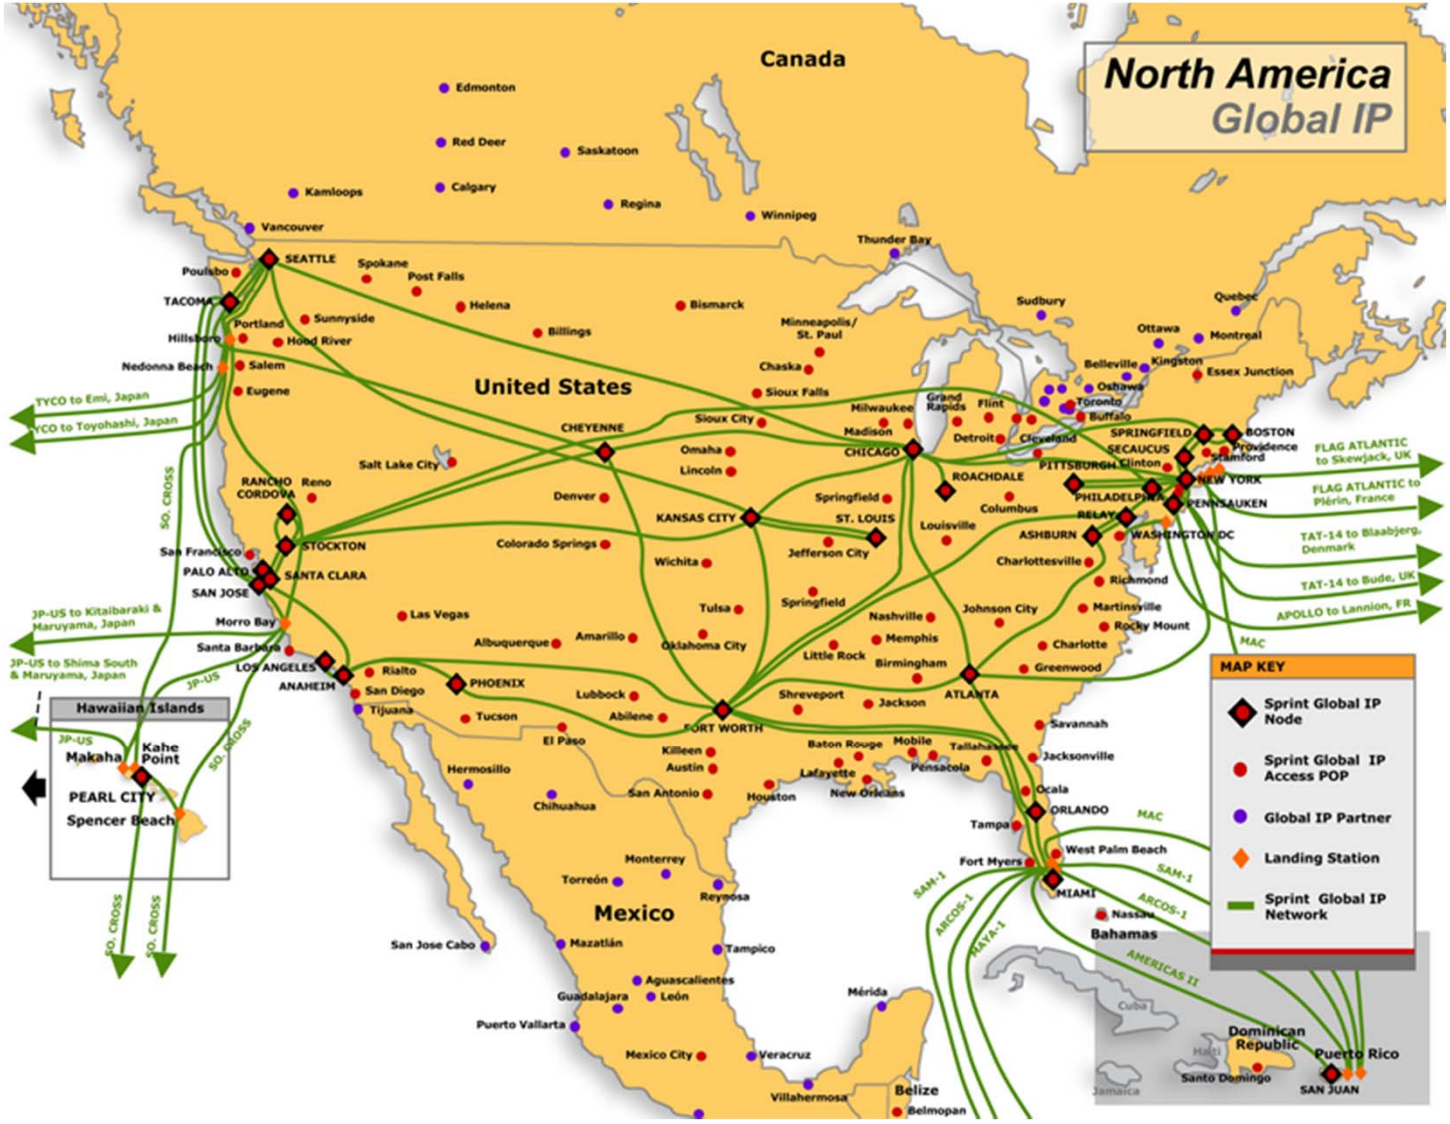

CenturyLink Fiber Network

Circuit Definitions

Fiber Route

CenturyLink® Business

中国教育科研网CERNET

ChinaNet （中国电信）

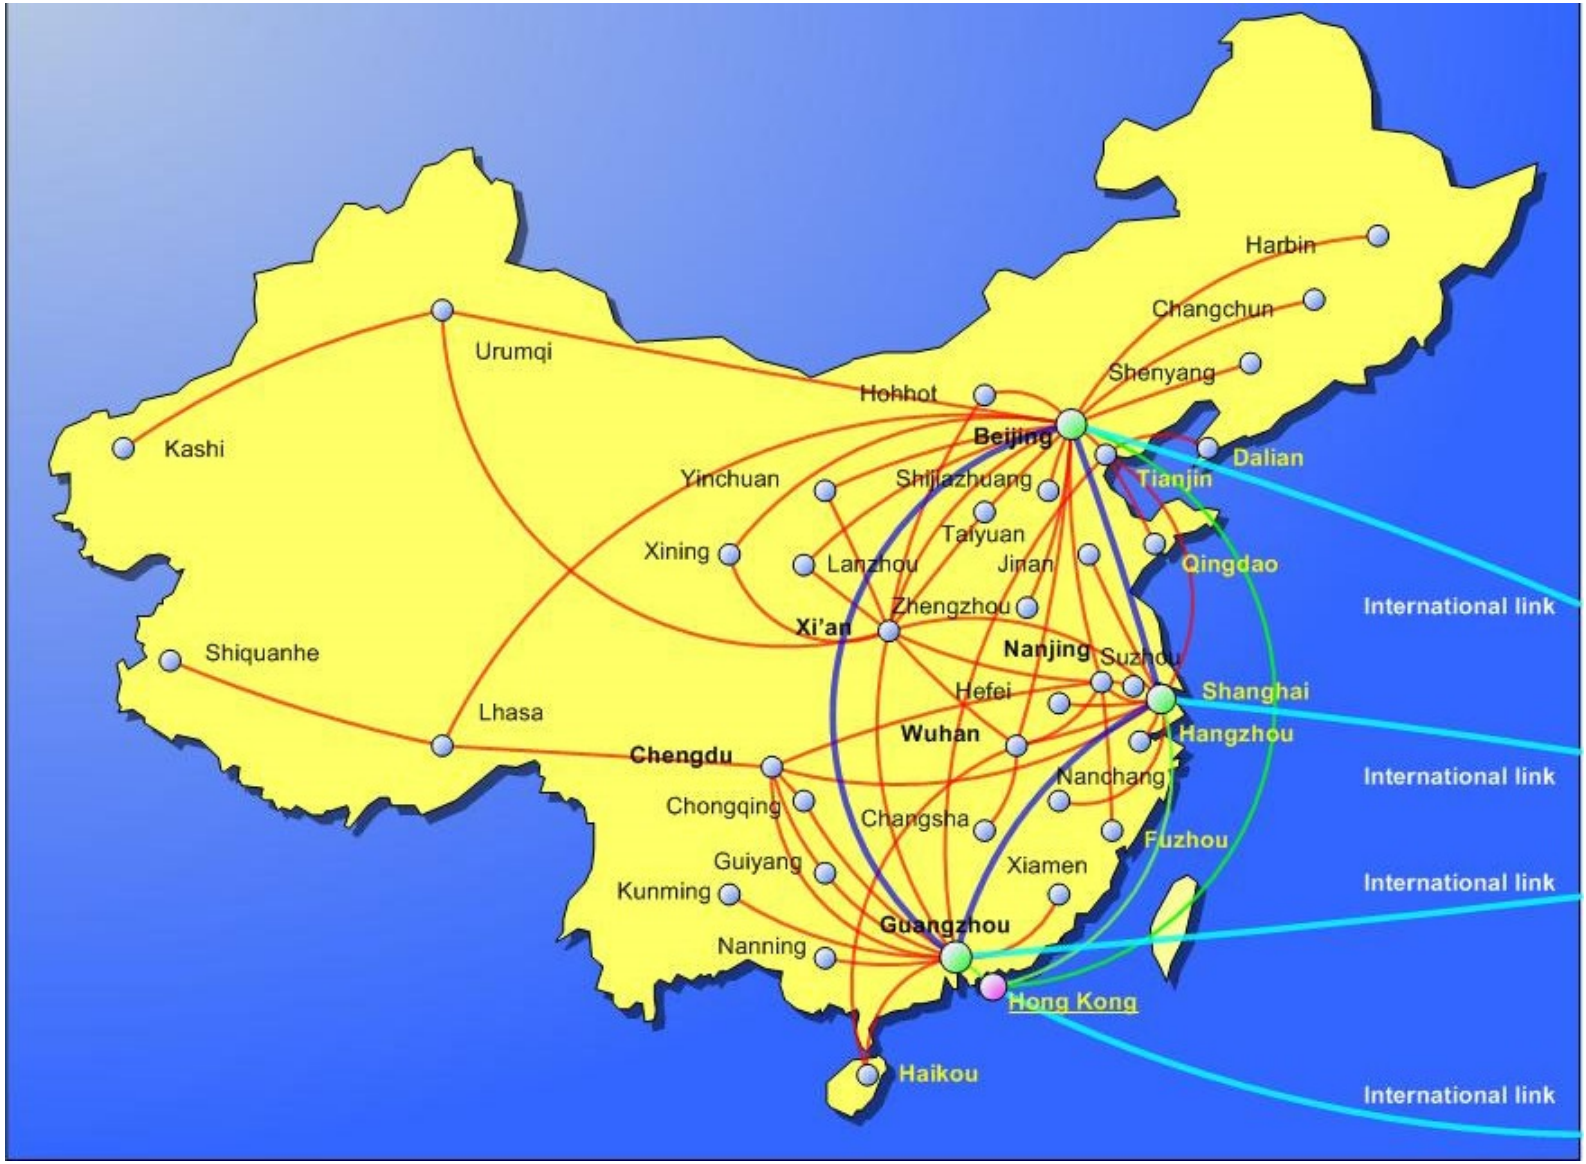

海底光缆

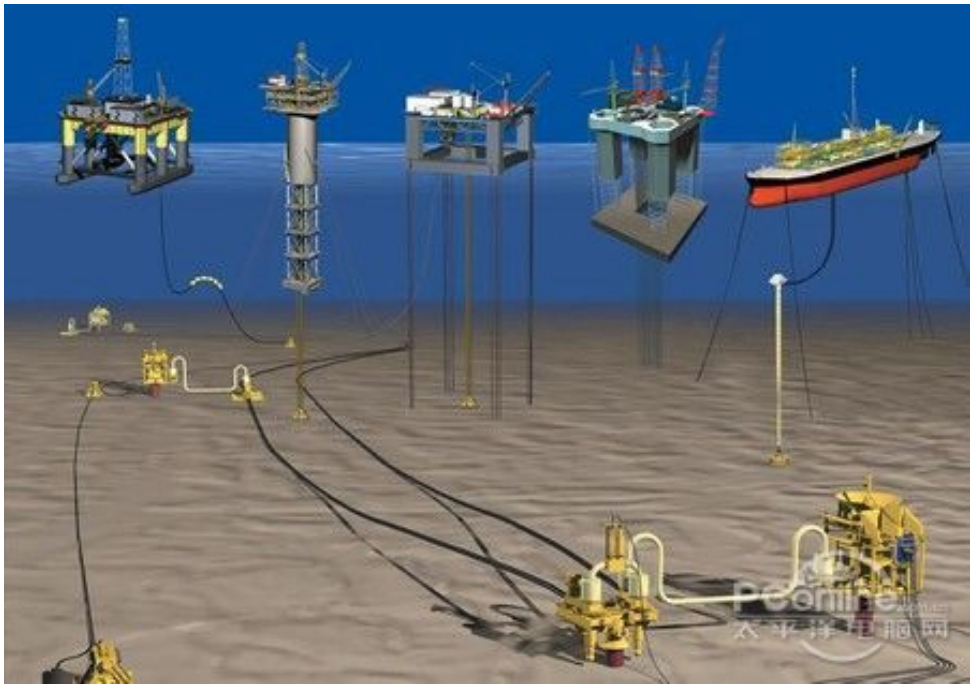

图片来源：百度图片

全球海底光缆

（source: telegeography.com）

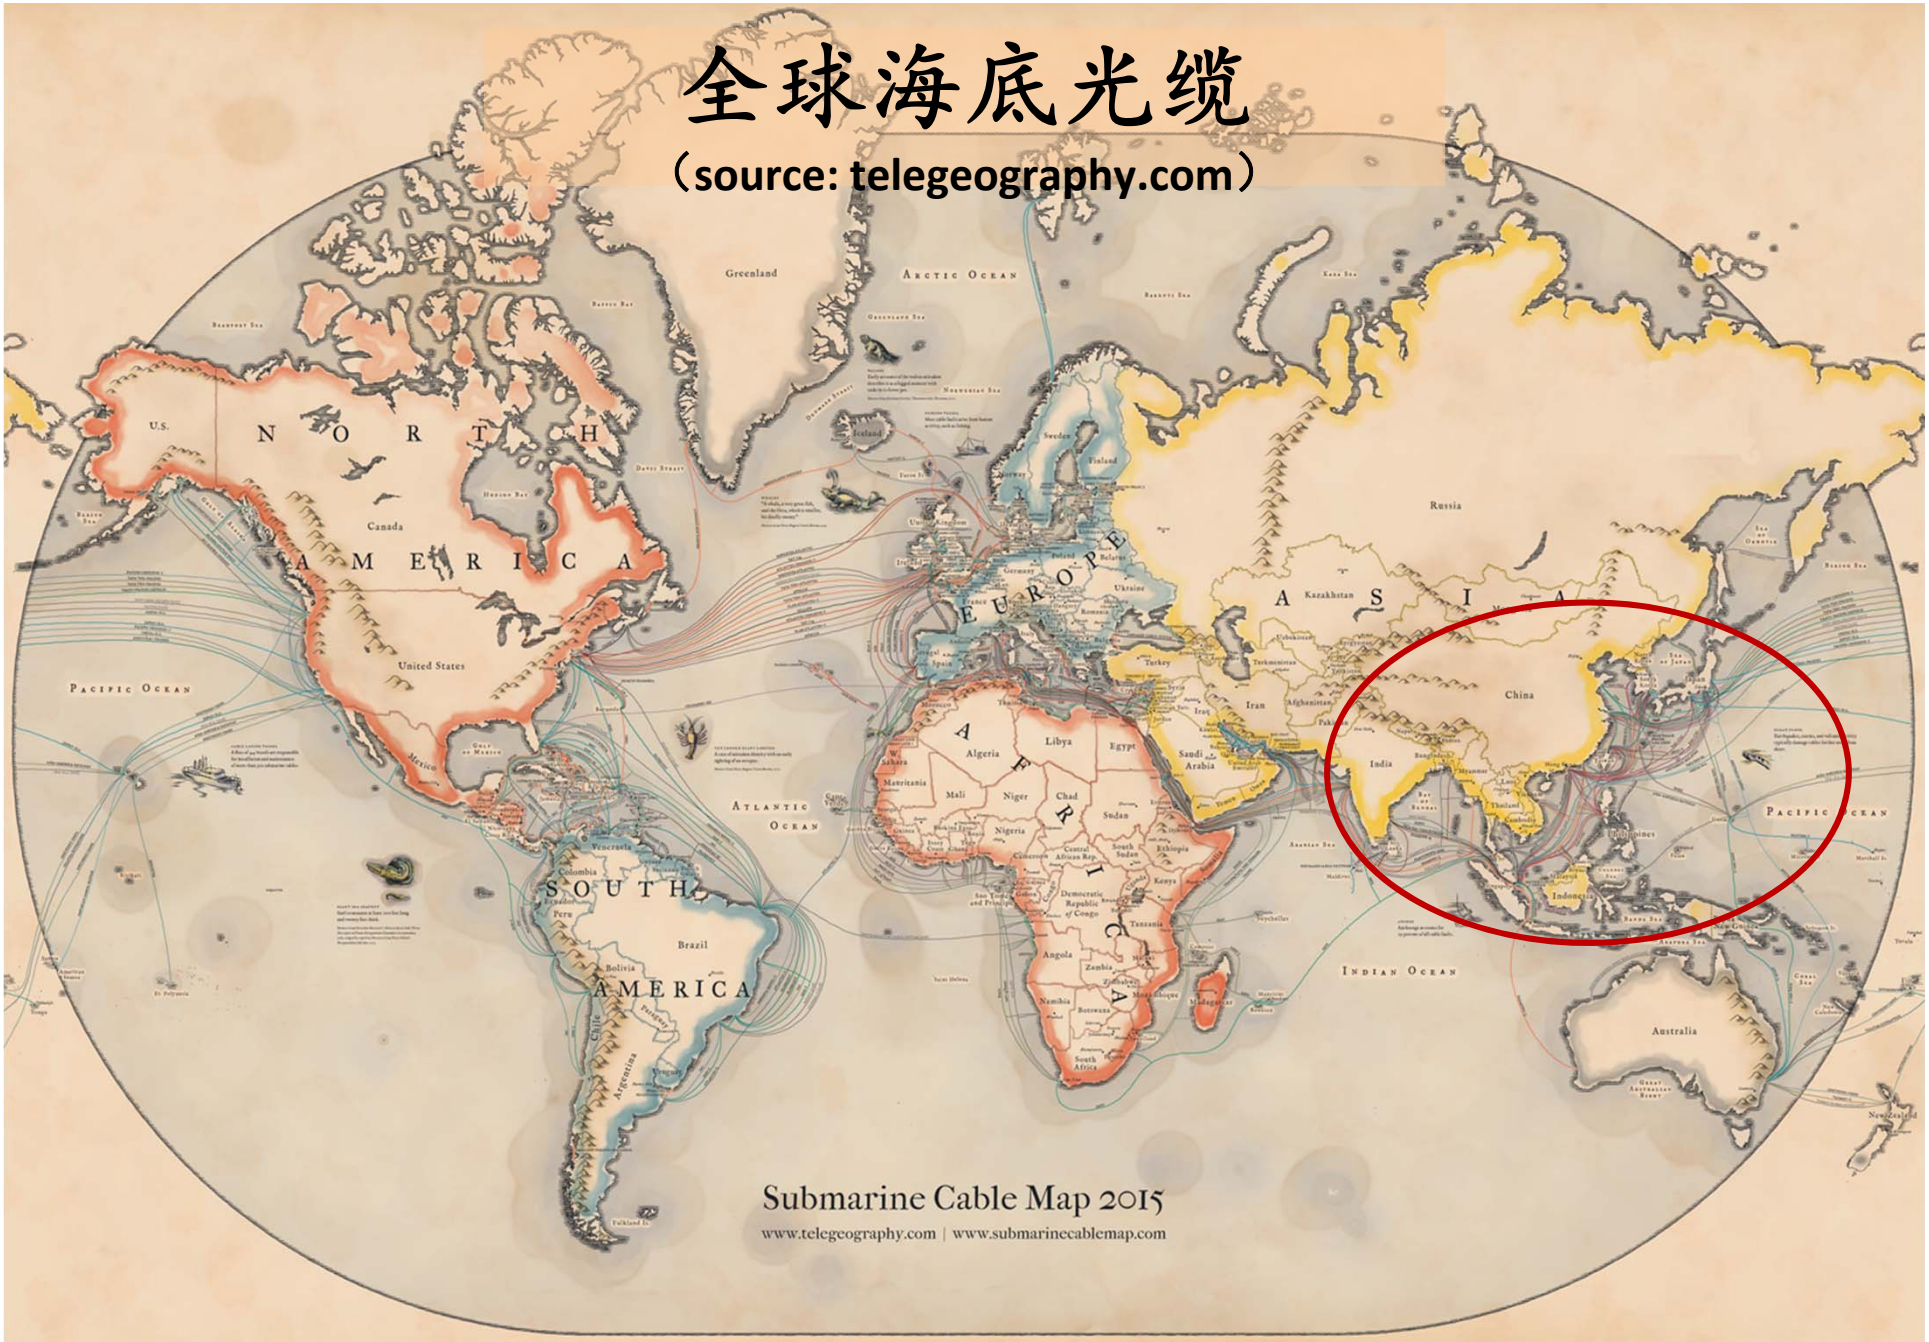

海底光缆

（source: telegeography.com）

Protocol (通信协议)

- 什么是Protocol?
  - 两方或多方之间
  - 对通信方式的协定
    - 语法
      - 数据格式，编码，长度
    - 语义

Open Systems Interconnection Model (OSI) vs. Internet

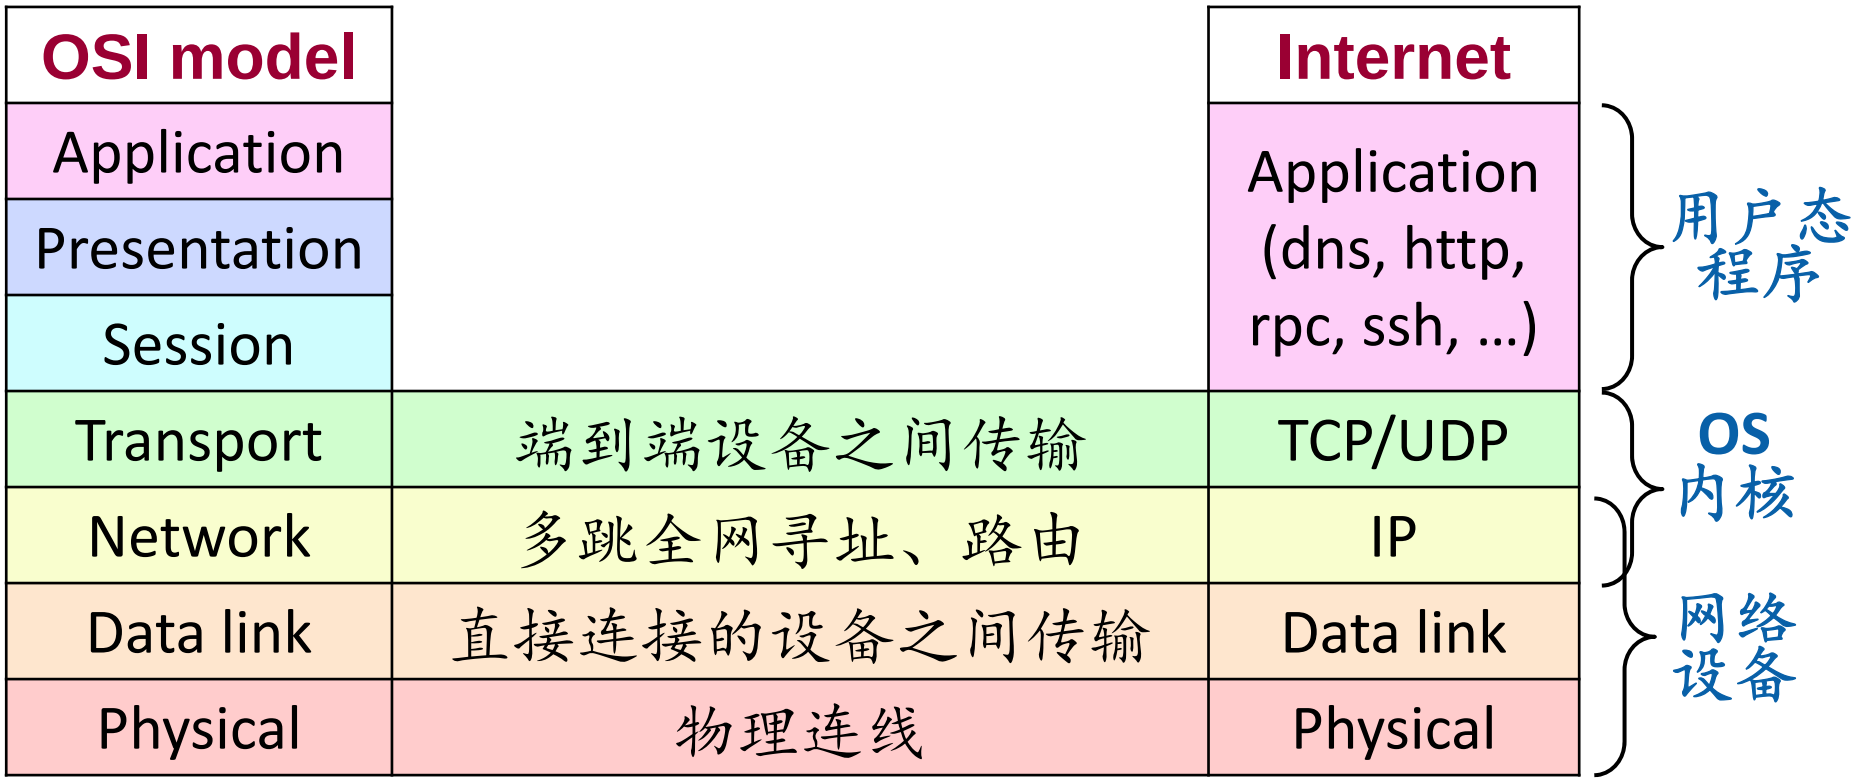

IP/TCP/UDP

- IP (Internet Protocol)
  - IPv4地址：例如210.76.211.7，唯一标识一台联网的机器
  - Routing(路由)
  - IP packet: header, data
  - Connectionless (无连接), unordered(无序), best-effort (不保证可靠)
- TCP (Transmission Control Protocol)
  - 在IP基础上实现
  - Port端口号：不同的进程/socket
  - Reliable (可靠的), ordered (有顺序), connection-oriented (有连接), error checked (数据校验)

建立连接成本高，
但是使用方便

- UDP (User Datagram Protocol)
  - 在IP基础上实现
  - Port端口号：不同的进程
  - 进行数据校验，其它与IP相同

不需建立连接，速度快
但是应用程序要自己检查
数据是否收到、顺序等

应用层协议

- Encapsulate
  - 一层包一层

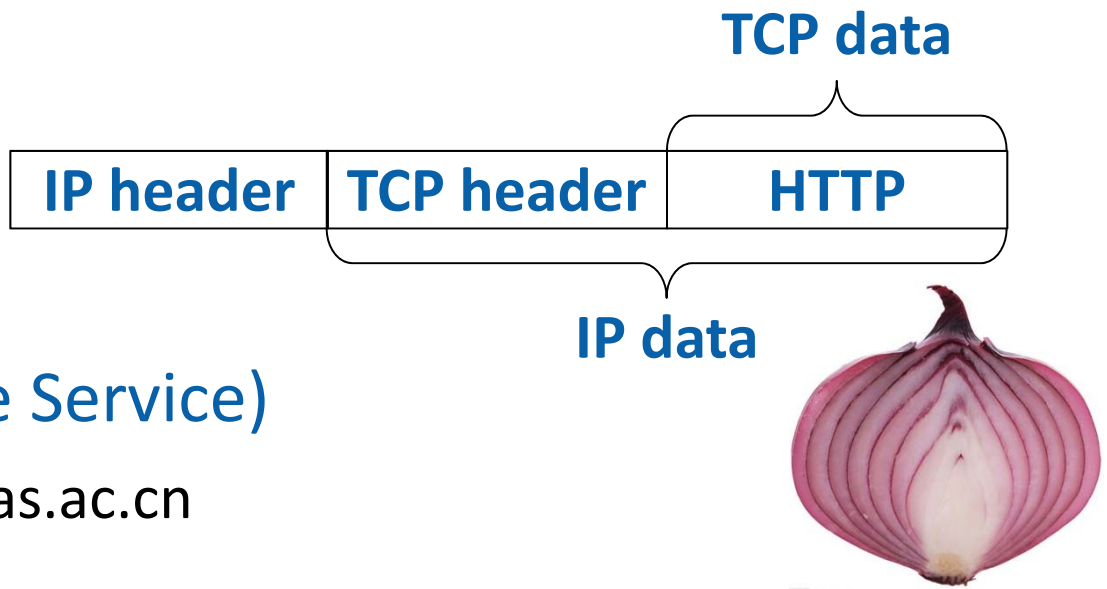

- DNS (Domain Name Service)
  - 域名：例如 sep.ucas.ac.cn
  - UDP port 53
  - 全球有根域名服务，各国各自管理自己的域名分配
- HTTP (Hyper Text Transfer Protocol)
  - TCP port 80
  - 有的其它协议是基于HTTP实现的，以便通过防火墙等

Process/Thread

- 在OS内核中两者很相似
- Process (进程)
  - 创建：fork
  - 私有的虚存空间
  - 私有的打开文件 (files, sockets, devices, pipes …)
- Thread (线程)
  - 创建：pthread_create➔clone
  - 共享的虚存空间
  - 共享的打开文件
  - 一个进程中可以有多个线程

应用程序进程间的通信方式

- Shared memory (共享内存)
  - 在单机上
    - 同一个进程内部，多个线程之间
    - 多个进程之间，把同一块物理内存映射到多个进程的虚存空间中
  - 一方修改，另一方可以立即看到
  - 需要并发控制
- Message passing (消息传递)
  - 单机上，多进程之间
  - 多机之间
  - 例如：socket (TCP/UDP)，pipe等

通常的消息传递（例如Socket）

请求：功能+参数

- 功能：功能的ID或者功能名
  - 例如：HTTP GET, HTTP PUT
  - 接收方根据它，完成需要的操作
- 参数：输入数据
  - 编码(Encoding)，序列化(Serialization)

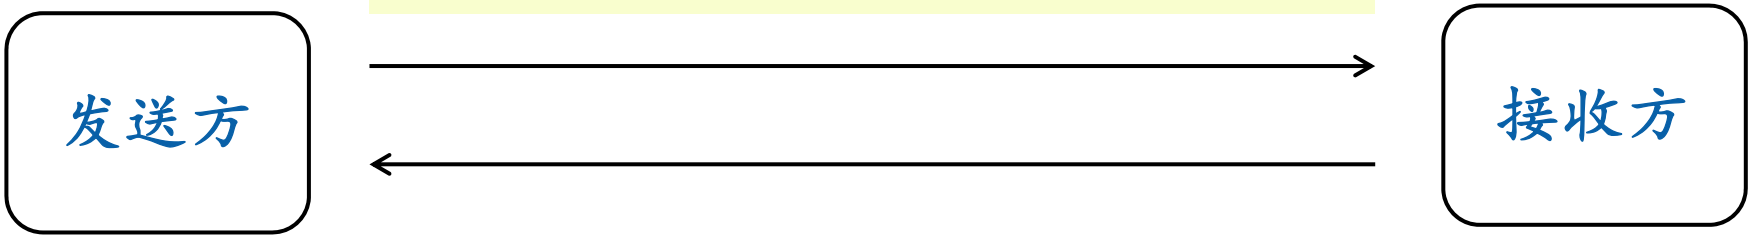

回答：结果+结果数据

- 结果：结果ID或者结果名
  - 例如：OK, ERROR, SUCCESS
- 结果数据：也需要编码和串行化

举例：访问一个网页

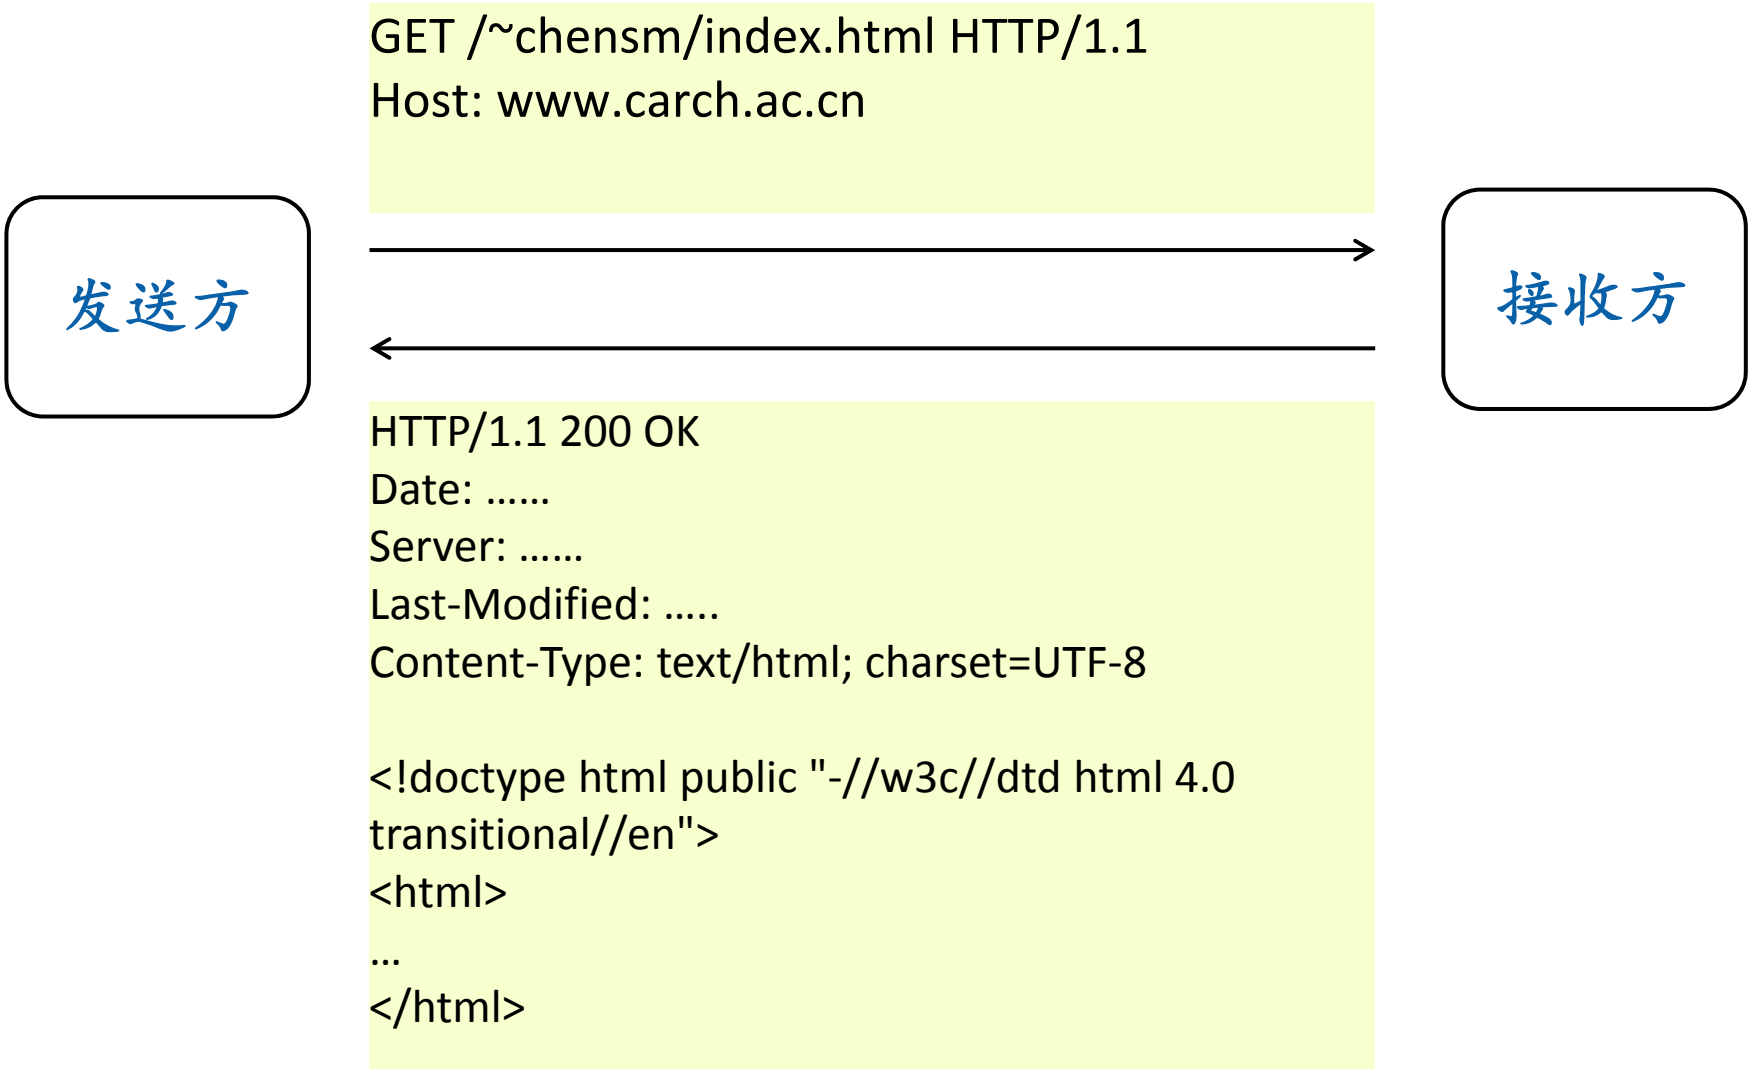
GET /~chensm/index.html HTTP/1.1
Host: www.carch.ac.cn
发送方
接收方
HTTP/1.1 200 OK
Date: ……
Server: ……
Last-Modified: …..
Content-Type: text/html; charset=UTF-8
<!doctype html public "-//w3c//dtd html 4.0
transitional//en">
<html>
…
</html>

分布式系统类型

- Client / Server
  - 客户端发送请求，服务器完成操作，发回响应
  - 例如：3-tier web architecture
    - Presentation: web server
    - Business Logic: application server
    - Data: database server
- P2P (Peer-to-peer)
  - 分布式系统中每个节点都执行相似的功能
  - 整个系统功能完全是分布式完成的
  - 没有中心控制节点
- Master / workers
  - 有一个/一组节点为主，进行中心控制协调
  - 其它多个节点为workers，完成具体工作

故障模型(Failure Model)

- Fail stop
  - 当出现故障时，进程停止/崩溃
- Fail slow
  - 当出现故障时，运行速度变得很慢
- Byzantine failure
  - 包含恶意攻击

CAP定理

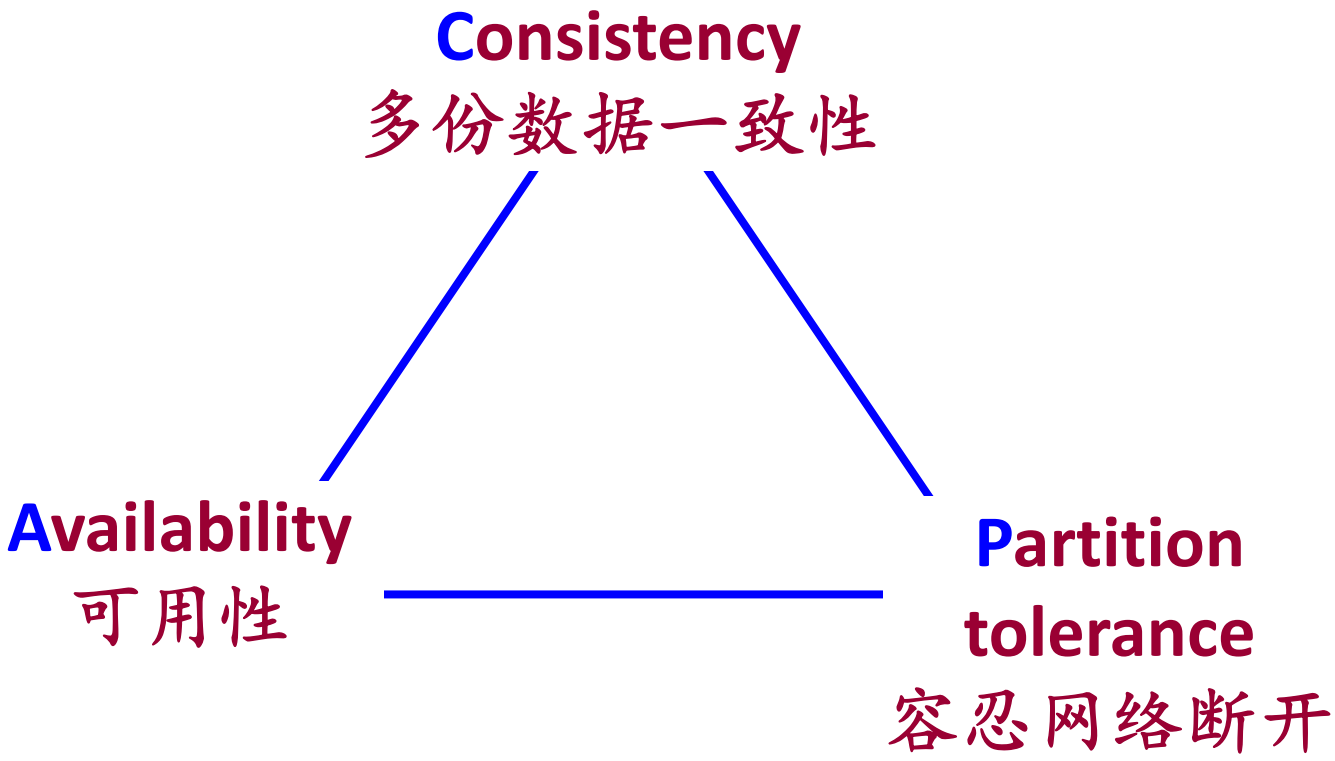

三者不可得兼

系统设计的理念

- Simple is beauty
  - 本质的往往是简单的
  - 越复杂的越难以正确地实现，可能引入各种漏洞问题

  - “Simplicity is the ultimate sophistication.”
    — Leonardo da Vinci
  - “Nature is pleased with simplicity.”
    — Isaac Newton
  - “世上本无事，庸人自扰之.”
    —孔子
  - “大道至简，衍化至繁”
    —老子

Outline

- 分布式系统基本概念
- 分布式文件系统
  - NFS
  - AFS
- Google File System和HDFS

本地文件系统 (Local File System)

- 例子： Linux ext4, Windows ntfs, Mac OS hfs …

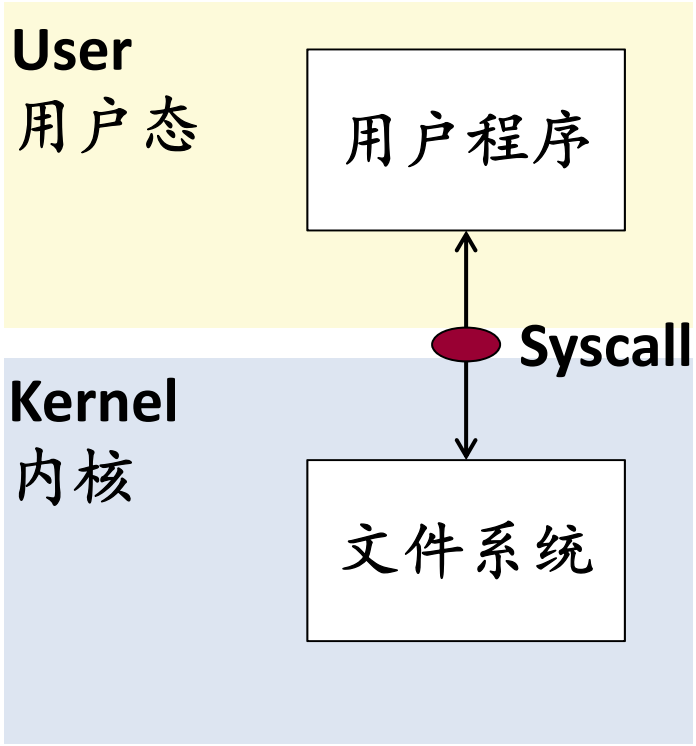

open,
close,
read,
write,
lseek, (改变文件位置)
stat, (文件属性,包括修改时间，长度等信息)
目录操作,
……

举例

// 把/myfile文件的开始4KB的数据拷贝到文件尾部

```
char buf[4096];
int fd = open (“/myfile”, 0600, O_RDWR);
read(fd, buf, 4096);
lseek(fd, 0, SEEK_END);
write(fd, buf, 4096);
close(fd);
```

NFS (Sun's Network File System)

- Sun公司1985发布了NFSv2，定义了开放的client/server之间的通信协议标准
- 非常流行，很多数据存储产品都提供NFS

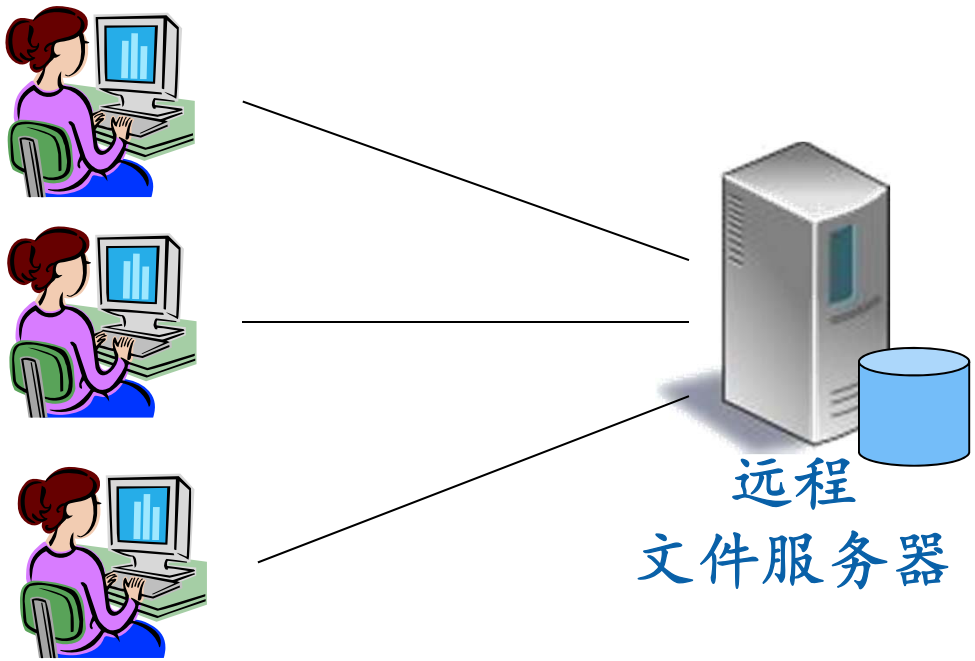

主要目的

- 从不同的终端都可以访问同一个目录
- 多用户共享数据
- 集中管理

参考：http://pages.cs.wisc.edu/~remzi/OSTEP/

访问的文件

- 主要是用户目录下的文件
- 文档编辑、编程、编译、运行

- 不是：处理大规模数据

系统架构

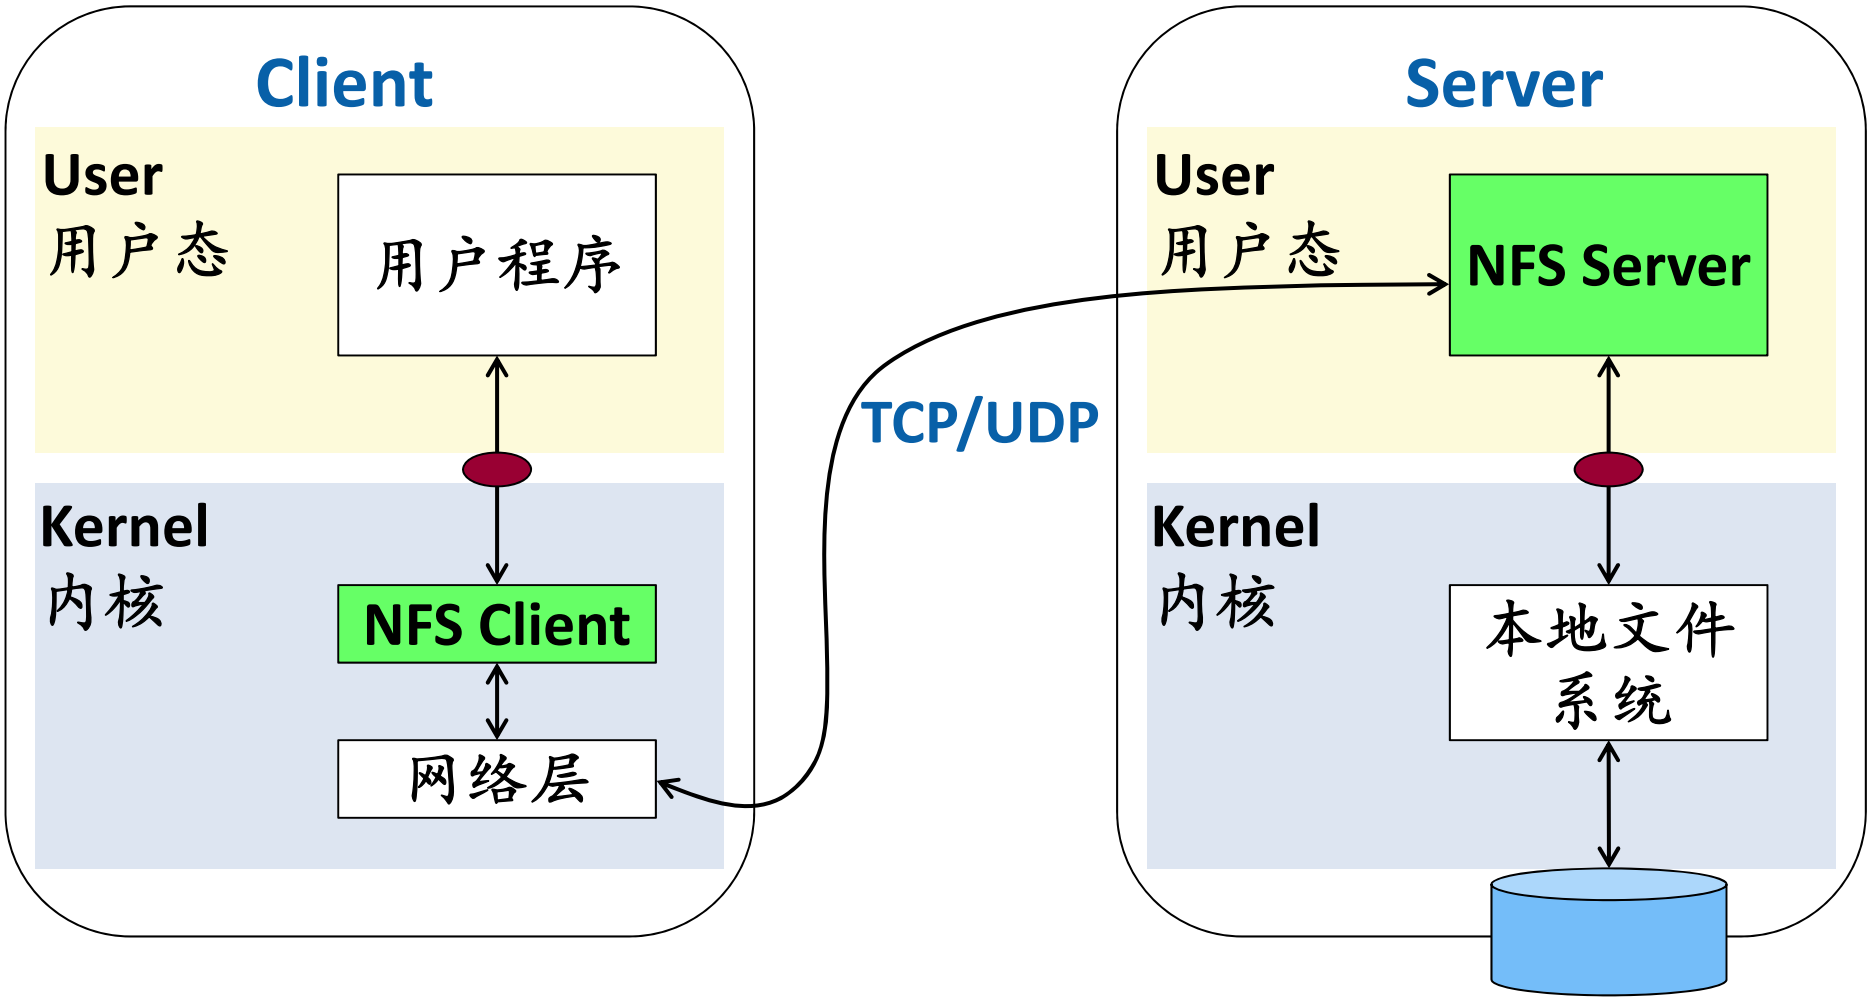
Client
User
用户态
用户程序
Kernel
内核
NFS Client
网络层
TCP/UDP
Server
User
用户态
NFS Server
Kernel
内核
本地文件
系统

如何设计为好？

- NFSv2设计目标1
  - Simple and Fast server crash recovery
    服务器出现故障，可以简单快速地恢复
    (Fail-stop 模型)

- 怎么样最简单？
  - 什么都不用做，最简单
  - 希望：当出现故障，NFS Server重新启动，不用做其它操作
- 解决方案
  - Stateless
  - Idempotent

保存State的问题

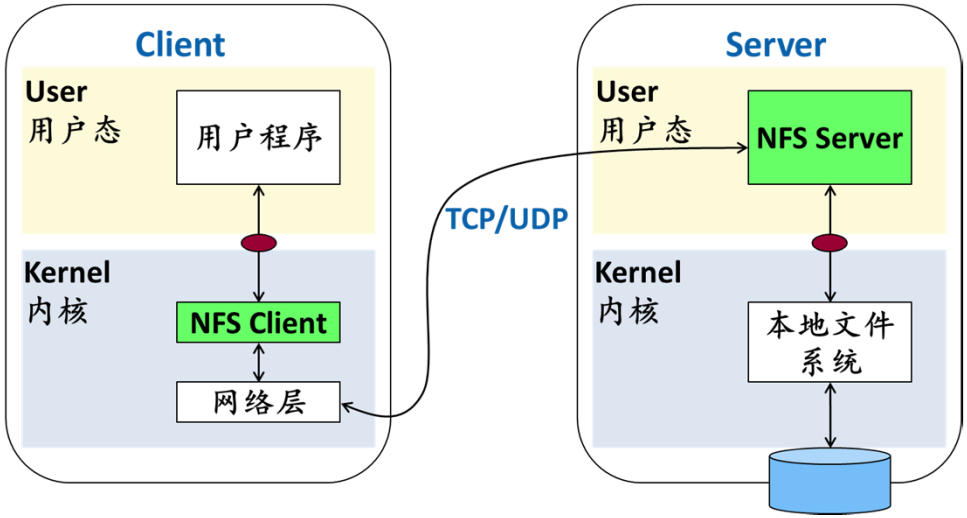

- 例如：客户端打开文件的文件内部位置信息，如果保存在NFS Server里，会怎么样？
- 故障重启后，内存状态都丢失了，客户端再次操作就会出错！

```
int fd = open (“/myfile”, 0600, O_RDWR);
read(fd, buf, 4096);
lseek(fd, 0, SEEK_END);
write(fd, buf, 4096);
close(fd);
```

crash

NFS Server Restart

还会写到文件尾吗？

Stateless（无状态）

- NFS Server不保持任何状态，每个操作都是无状态的
- NFSPROC_READ
  - 输入参数: file handle, offset, count
  - 返回结果: data, attributes
- NFSPROC_WRITE
  - 输入参数: file handle, offset, count, data
  - 返回结果: attributes
- NFSPROC_LOOKUP
  - 输入参数: directory file handle, name of file/directory to look up
  - 返回结果: file handle
- NFSPROC_GETATTR
  - 输入参数: file handle
  - 返回结果: attributes
- 等等

举例

客户端

服务器端

```
int fd = open ("/myfile", …);
```

发送LOOKUP(根/的FH_r, "myfile")

处理LOOKUP，找到"myfile"，
返回唯一标识FH_1

接收LOOKUP结果
在内核file table中分配file desc
记录myfile的FH_1
记录文件位置为0
返回fd

FH: File Handle

举例

客户端

服务器端

```
read(fd, buf, 4096);
```

发送READ(FH_1,0,4096)

处理READ，读文件，
返回数据和文件属性

接收READ结果
记录文件位置为0+4096=4096
拷贝数据到buf
记录文件属性(修改时间，长度等)
返回0（成功）

举例

客户端　　服务器端

```
lseek(fd, 0, SEEK_END);
```

记录文件位置为文件长度1048576
返回0（成功）

假设文件原始长度为1MB

举例

客户端　　服务器端

```
write(fd, buf, 4096);
```

拷贝buf中的数据
发送WRITE(FH_1,1048576,4096,数据)

处理WRITE，写文件，
返回文件属性

接收WRITE结果
记录文件位置为1048576+4096=1052672
记录文件属性(修改时间，长度等)
返回0（成功）

举例

客户端　　服务器端

```
close(fd);
```

释放file desc
返回0（成功）

Idempotent（幂等性：重复多次结果不变）

- READ操作是Idempotent
  - 在没有其它操作前提下，重复多次结果是一样的
  - 为什么？

不改变数据

- WRITE操作是Idempotent
  - 在没有其它操作前提下，重复多次结果是一样的
  - 为什么？

在相同位置写相同的数据

Server Crash Recovery

- NFS Server
  - 只用重启，什么额外操作都不用
  - 因为Stateless

- NFS Client
  - 如果一个请求没有响应，那么就不断重试
  - 因为Idempotent

如何设计为好？

- NFSv2设计目标2
  - 远程文件操作性能高
- 解决思路：Client cache (在内存中)，缓存读写的数据

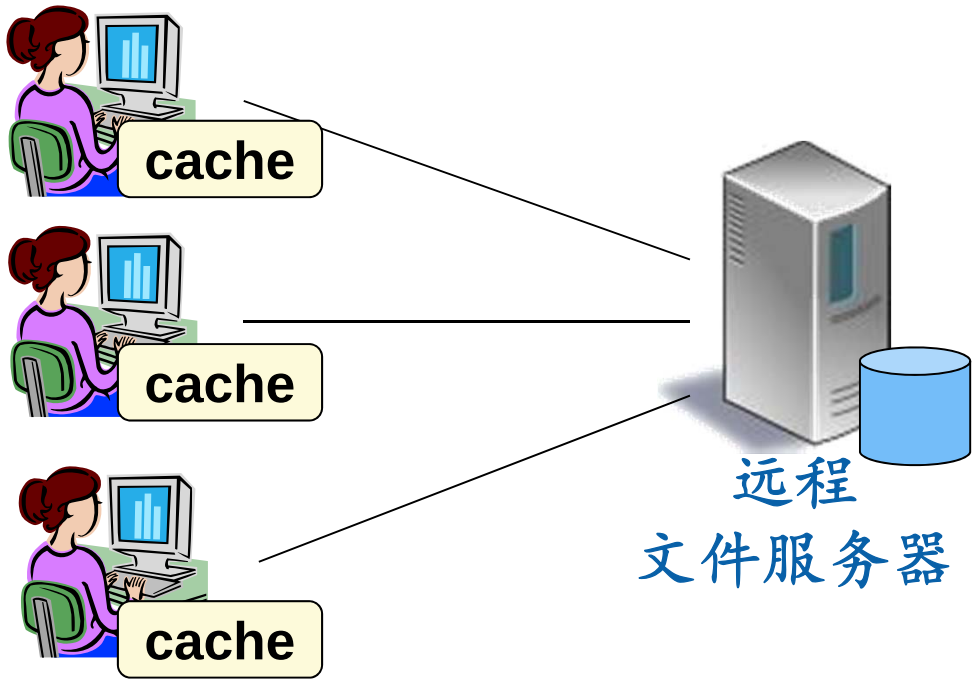

- 尽量利用cache数据
- 避免远程操作

问题：Cache Consistency

- 对于同一个文件，并发访问冲突问题的表现
- 例如：文件A(版本)

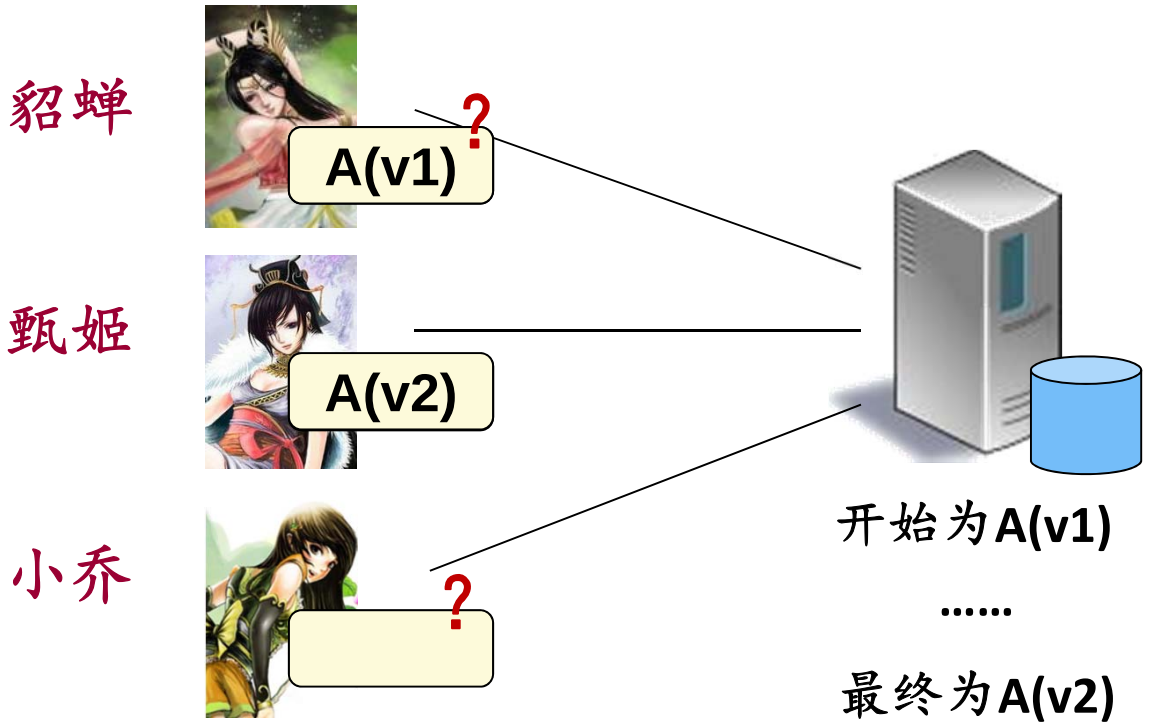

- Client貂蝉读了文件A(v1)，放入缓存
- Client甄姬读了文件A(v1)，然后写，成为A(v2)
- 问题1：貂蝉不知道缓存的数据变成了过时的
- 问题2：其它client小乔如何能读到最新的数据？

注意：这里和transaction ACID不同，可以理解为每个文件操作是一个单独事务！

NFSv2对于Cache Consistency的解决方法

- Flush-on-close (又称作close-to-open) consistency
  - 在文件关闭时，必须把缓存的已修改的文件数据，写回NFS Server

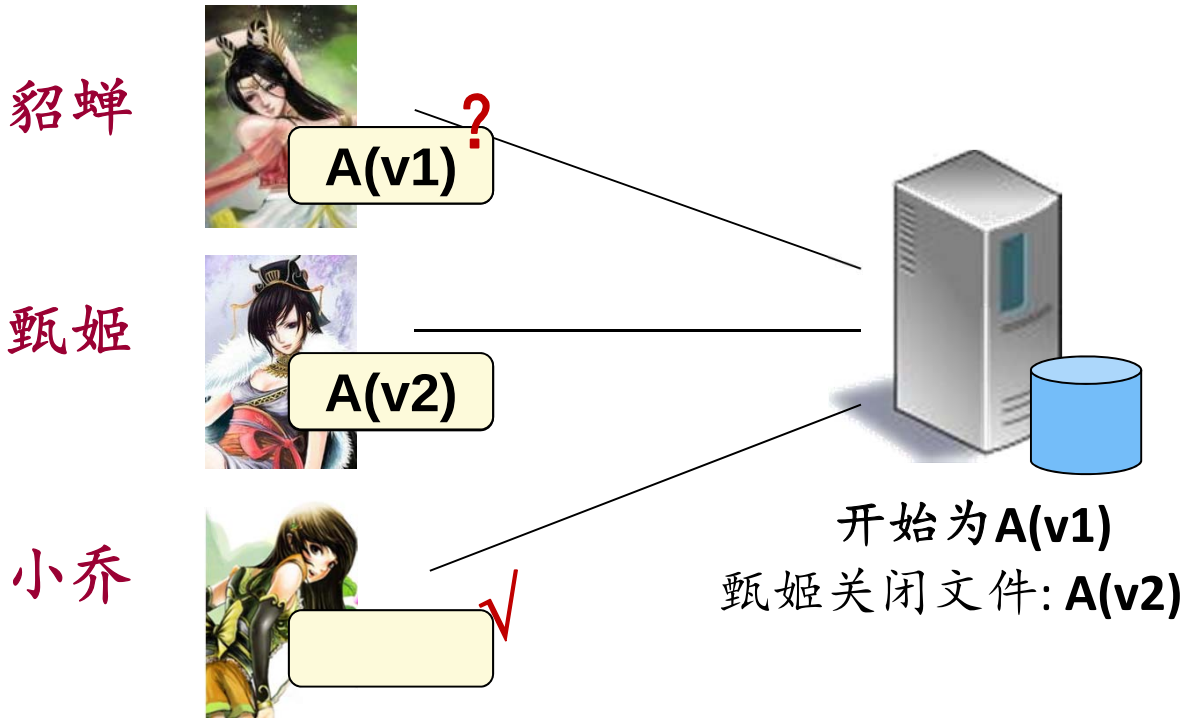

- Client貂蝉读了文件A(v1)，放入缓存
- Client甄姬读了文件A(v1)，然后写，成为A(v2)
- 甄姬关闭文件时，将最新版本发回NFS Server

问题：貂蝉怎么知道服务器上文件变化了，需要丢弃旧版本呢？

NFSv2对于Cache Consistency的解决方法

- Flush-on-close (又称作close-to-open) consistency
  - 在文件关闭时，必须把缓存的已修改的文件数据，写回NFS Server

- 每次在使用缓存的数据前，必须检查是否过时
  - 发送GETATTR请求，获得最新的文件属性
  - 比较文件修改时间

- 性能问题
  1. 大量的GETATTR（即使文件只被一个client缓存）
  2. 关闭文件时写回文件

AFS (Andrew File System)

- CMU M. Satyanarayanan (Satya) in 1980s
- 在美国大学中很流行
- 设计目标：Scalability
  - 一个服务器支持尽可能多的客户端
  - 解决NFS polling状态的问题

解决polling状态的问题

- Invalidation
  - Client 获得一个文件时，在server上登记
  - 当server发现文件修改时，向已登记的client发一个callback
  - Client收到callback，则删除缓存的文件

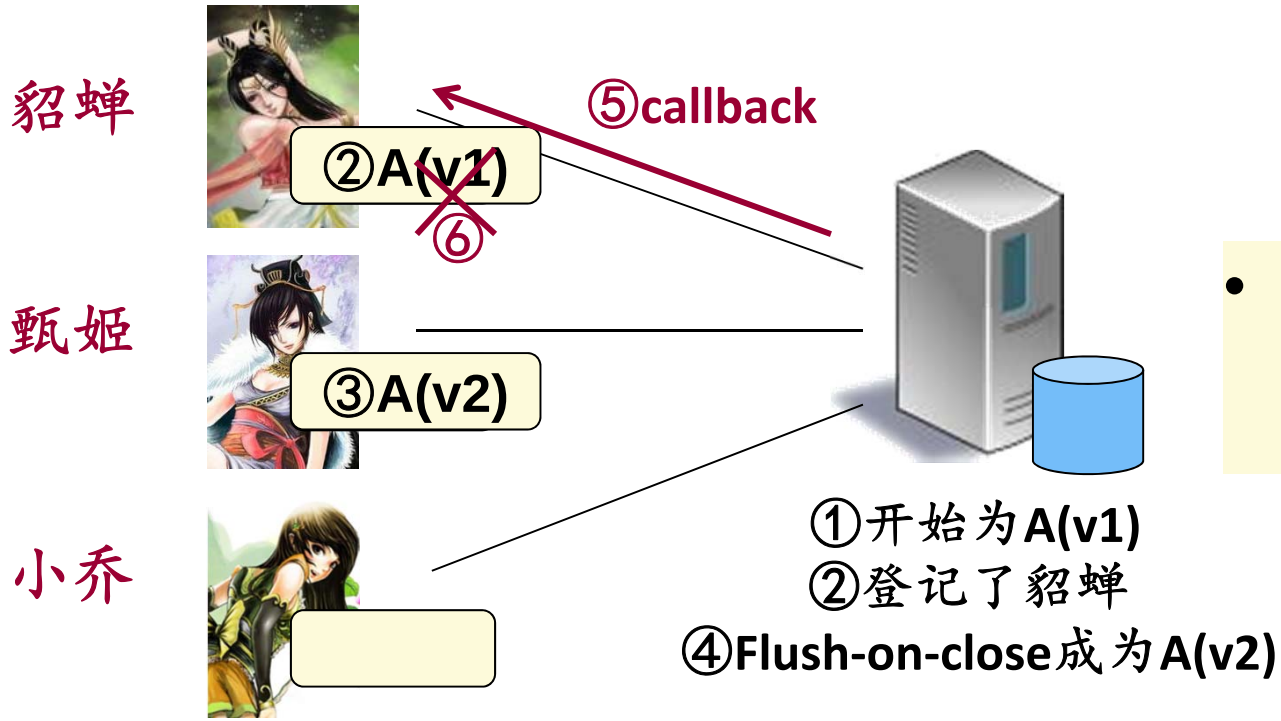

- 有效地避免了polling的代价，减轻了Server的负担

其它不同点：AFS vs. NFSv2

- AFS缓存整个文件
  - 而NFS是以数据页为单位的
  - AFS open: 将把整个文件从Server读到Client
  - 多次操作：就像本地文件一样
  - 单次对一个大文件进行随机读/写：比较慢
- AFS缓存在本地硬盘中
  - 而NFS的缓存是在内存中的
  - 所以AFS可以缓存大文件
- AFS
  - 有统一的名字空间，而NFS可以mount到任何地方
  - 有详细权限管理等

Outline

- 分布式系统基本概念
- 分布式文件系统
- Google File System和HDFS

GFS/HDFS

- Google File System
  - SOSP 2003，C/C++实现
  - Google MapReduce系统的基础

- Hadoop Distributed File System
  - Google File System的开源实现
  - 基于Java
  - 应用层的文件系统
  - 与Hadoop捆绑在一起

GFS/HDFS是应用层文件系统

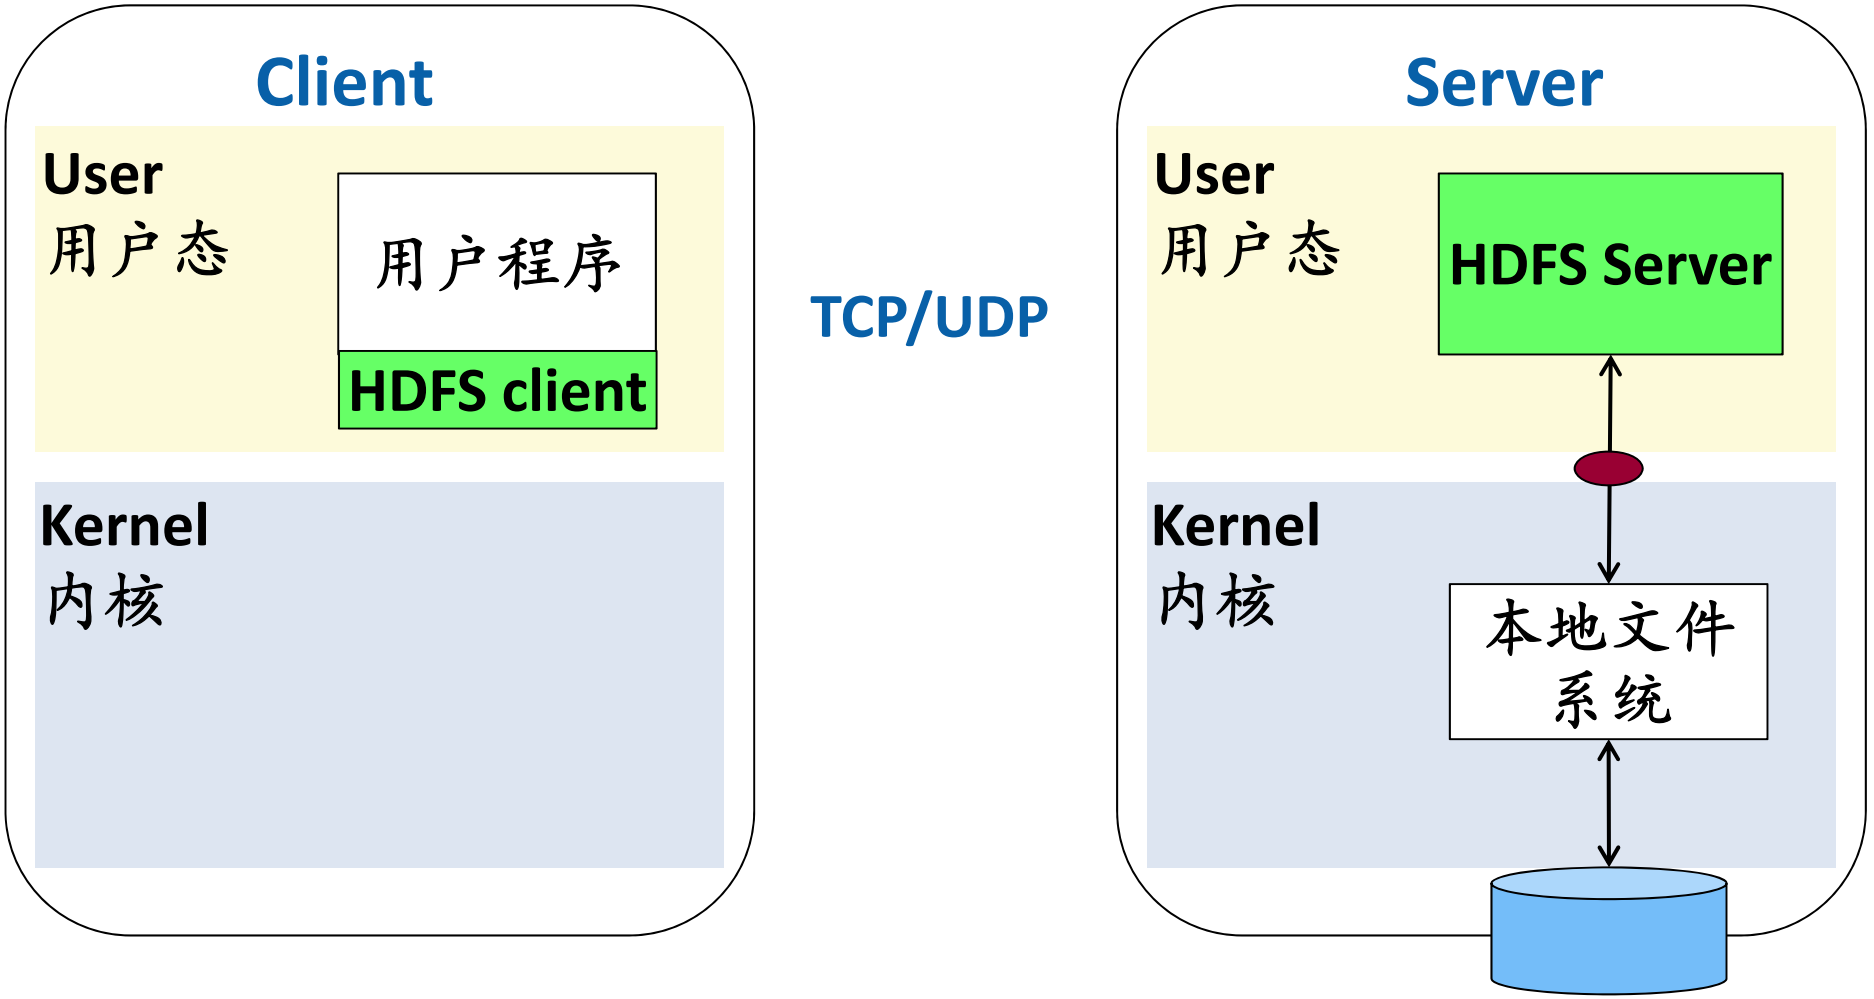

POSIX文件系统 vs. 应用层文件系统

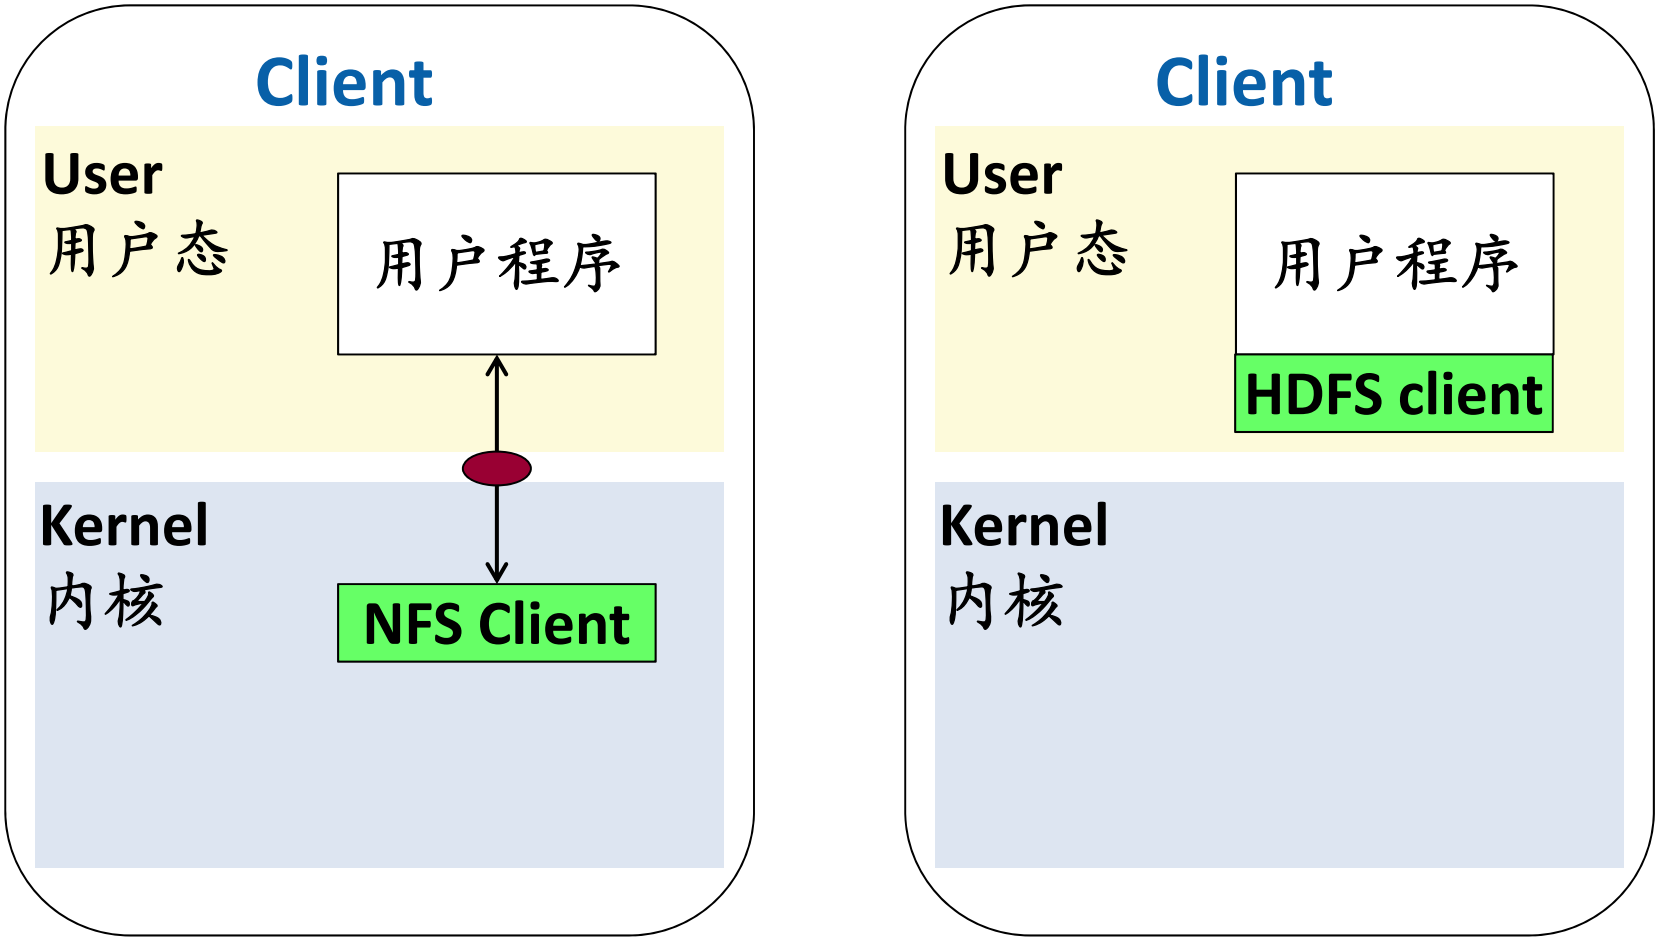

所有程序不改变就可以用

必须链接HDFS client库才能使用

GFS设计目标

- 优化
  - 大块数据的顺序读
  - 并行追加(append)
- 不支持
  - 对已有文件的修改(overwrite)操作
  - 所以，consistency的实现可以大大简化！

HDFS/GFS系统架构

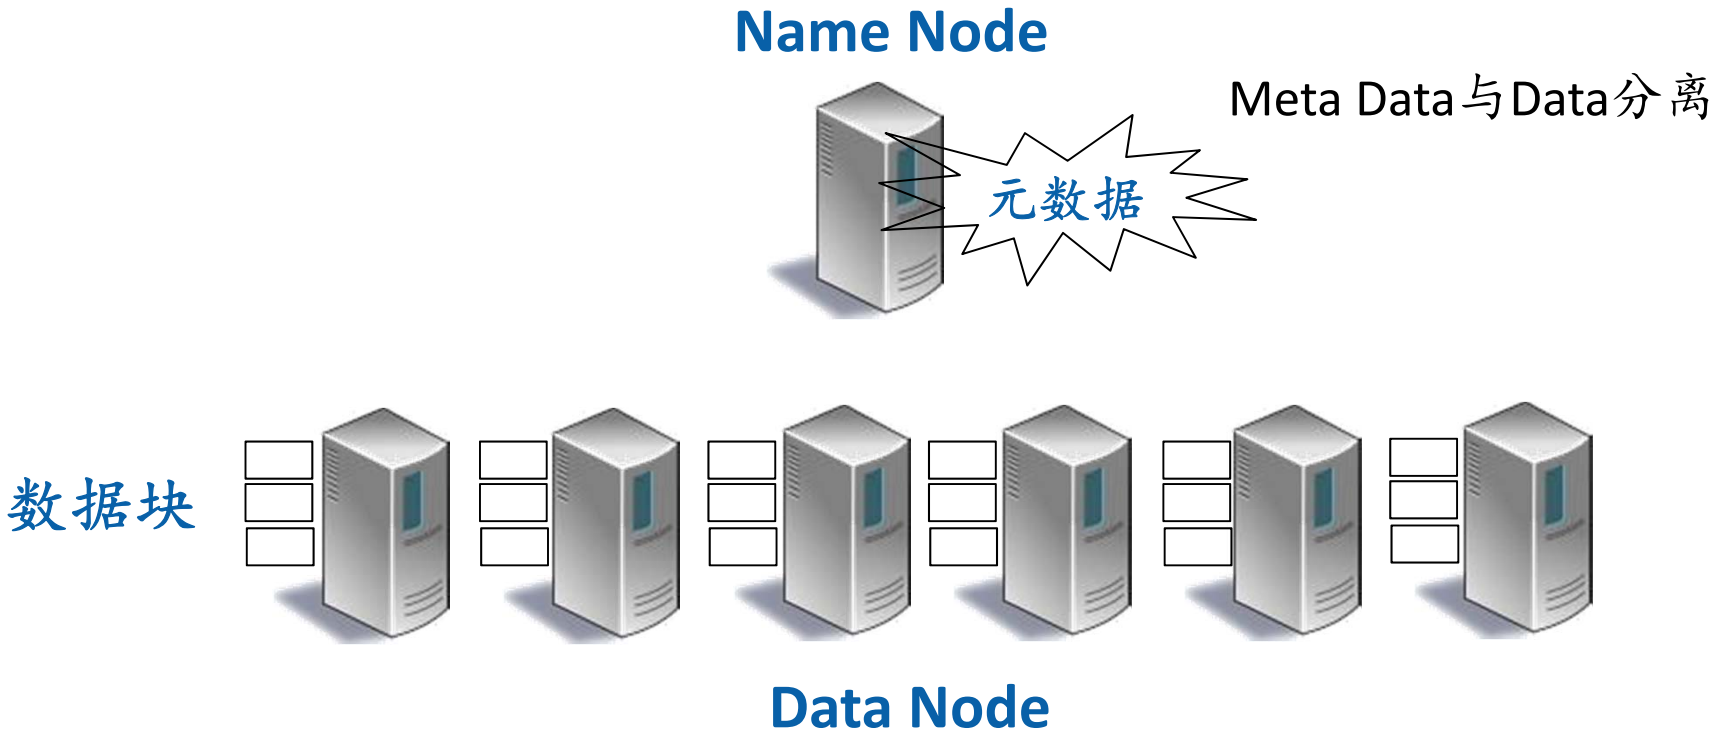

- Name Node：存储文件的metadata(元数据)
  - 文件名，长度，分成多少数据块，每个数据块分布在哪些Data Node上
- Data Node: 存储数据块

HDFS/GFS系统架构

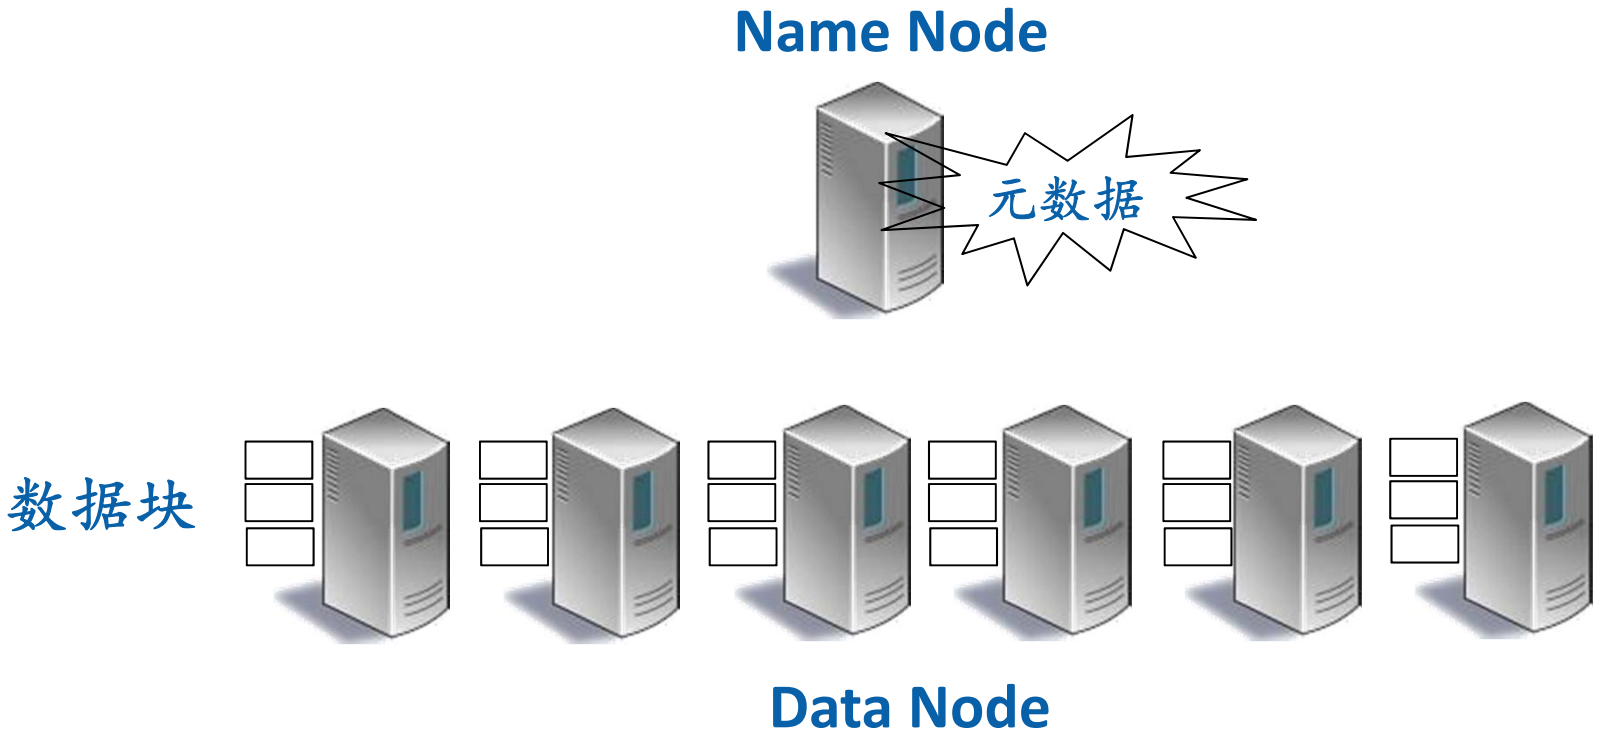

- 文件切分成定长的数据块（默认为64MB大小的数据块）
- 每个数据块独立地分布存储在Data Node上
- 默认每个数据块存储3份，在3个不同的data node上
  - Rack-aware

HDFS/GFS文件操作：open

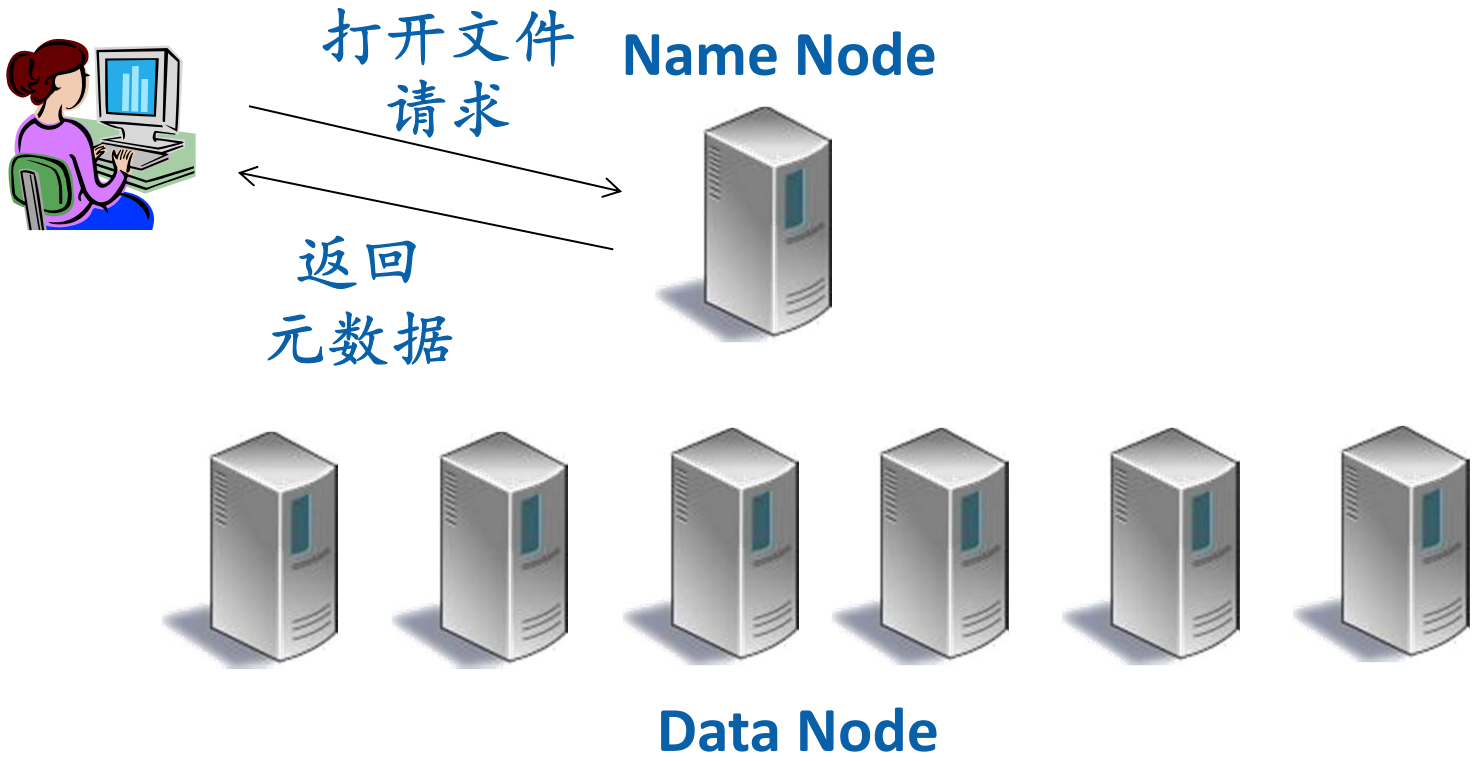

- 打开文件时，与Name Node通信一次

HDFS/GFS文件操作：read

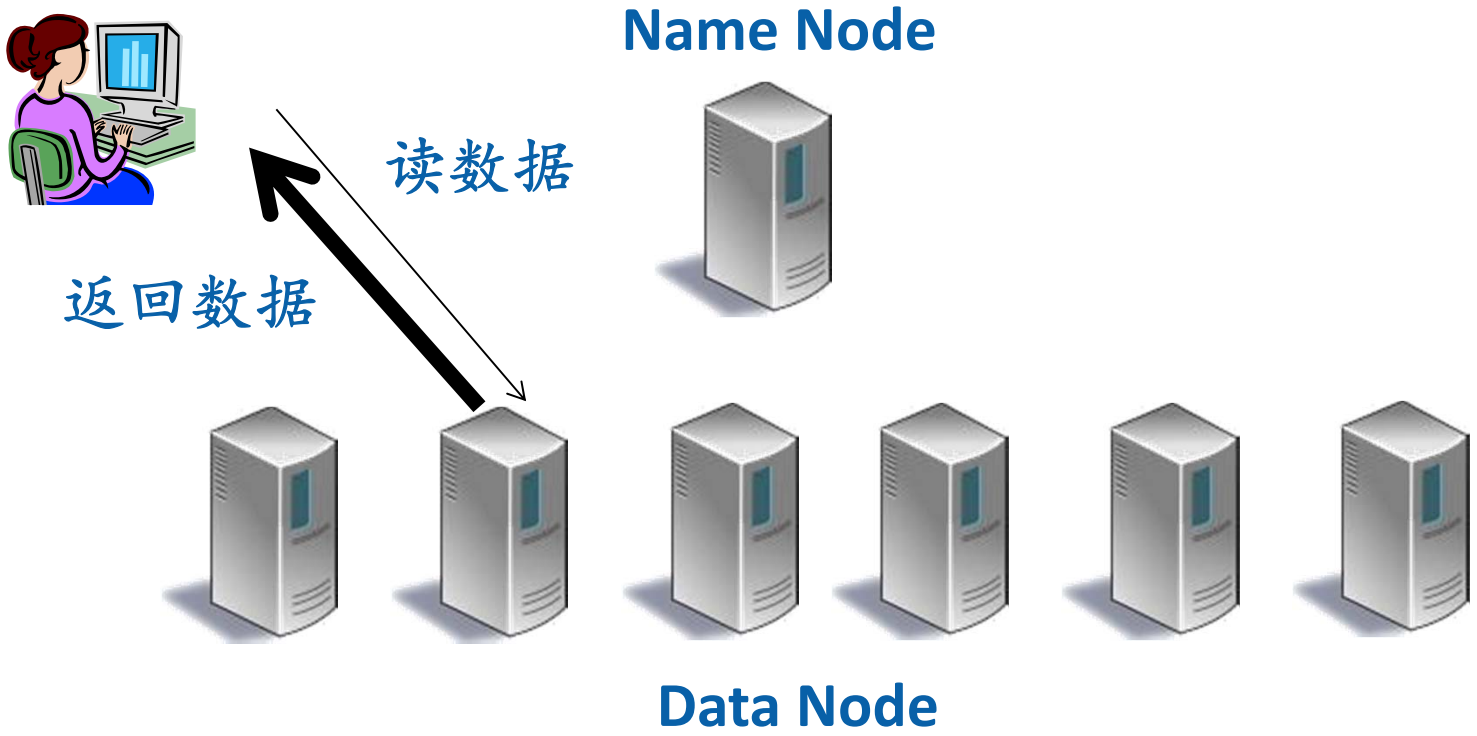

- 之后的读操作，直接与Data Node通信，绕过了Name Node
- 可以从多个副本中选择最佳的Data Node读取数据

HDFS/GFS文件操作：read

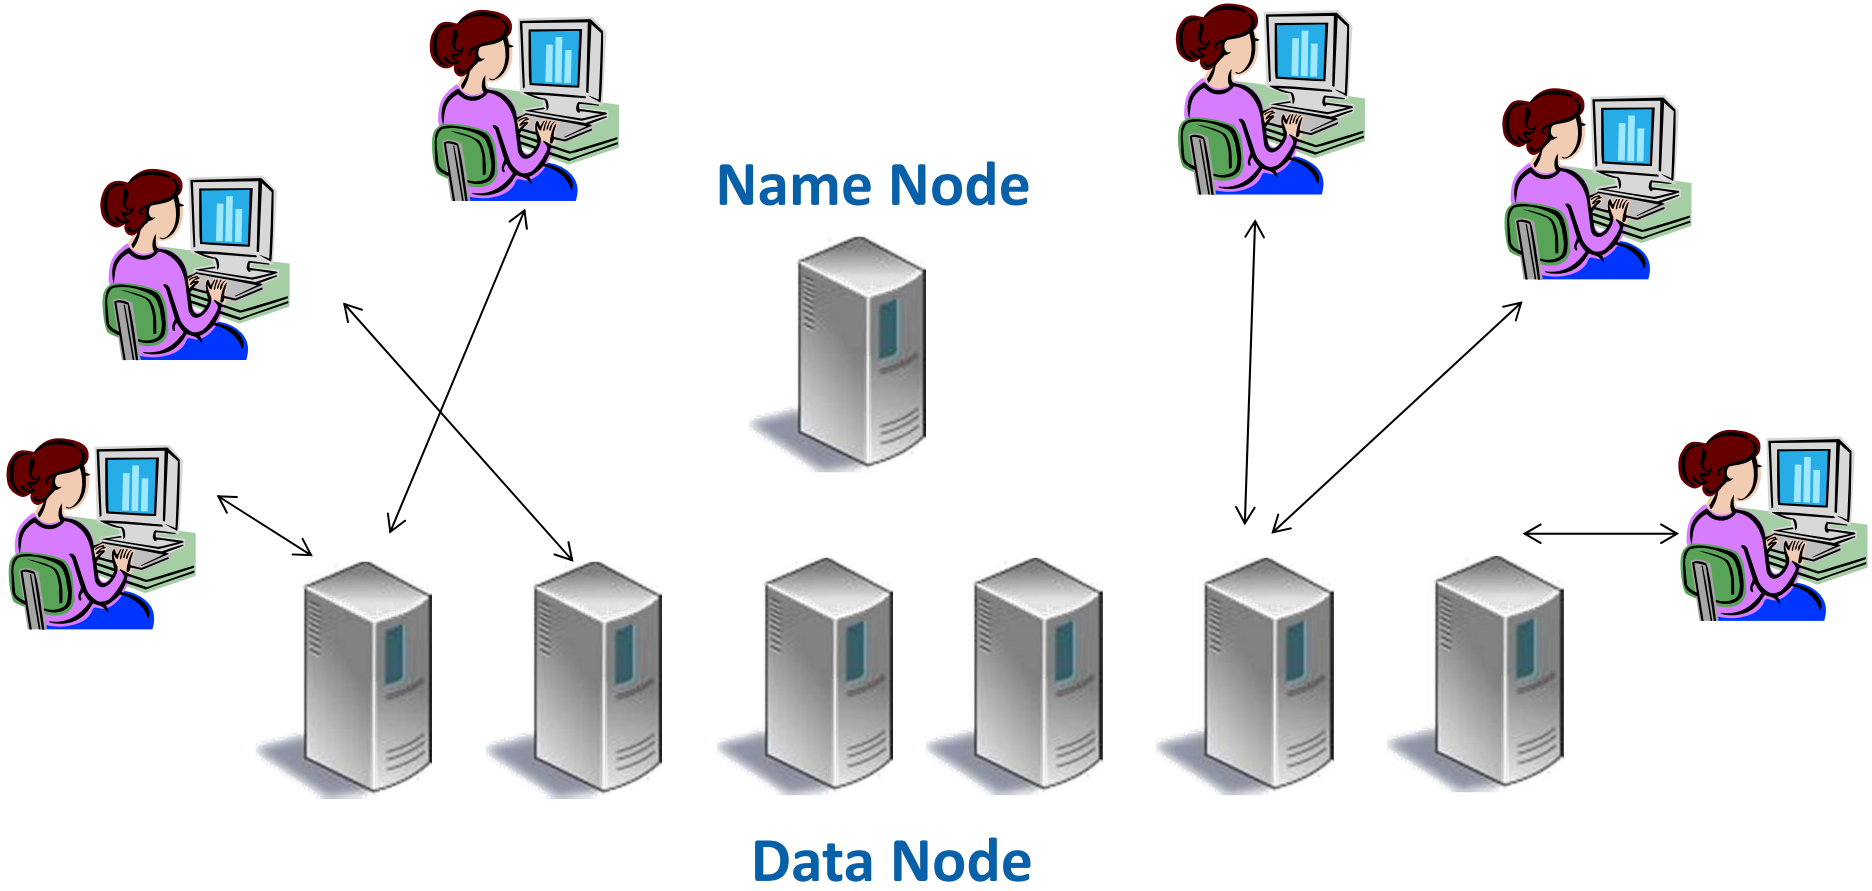

- 可以支持很多并发的读请求

HDFS/GFS文件操作：write(1)

Client 可能是在一个
Data Node 所在的机器上

写新创建的文件
不是修改已有的文件！

请求写数据块

返回应写的
Data Nodes

Name Node

Data Node

- Name Node决定应该写到哪些Data Nodes
  - Rack-aware, load balancing
  - 3个副本：本机、本机柜、其它机柜

HDFS/GFS文件操作：write(2)

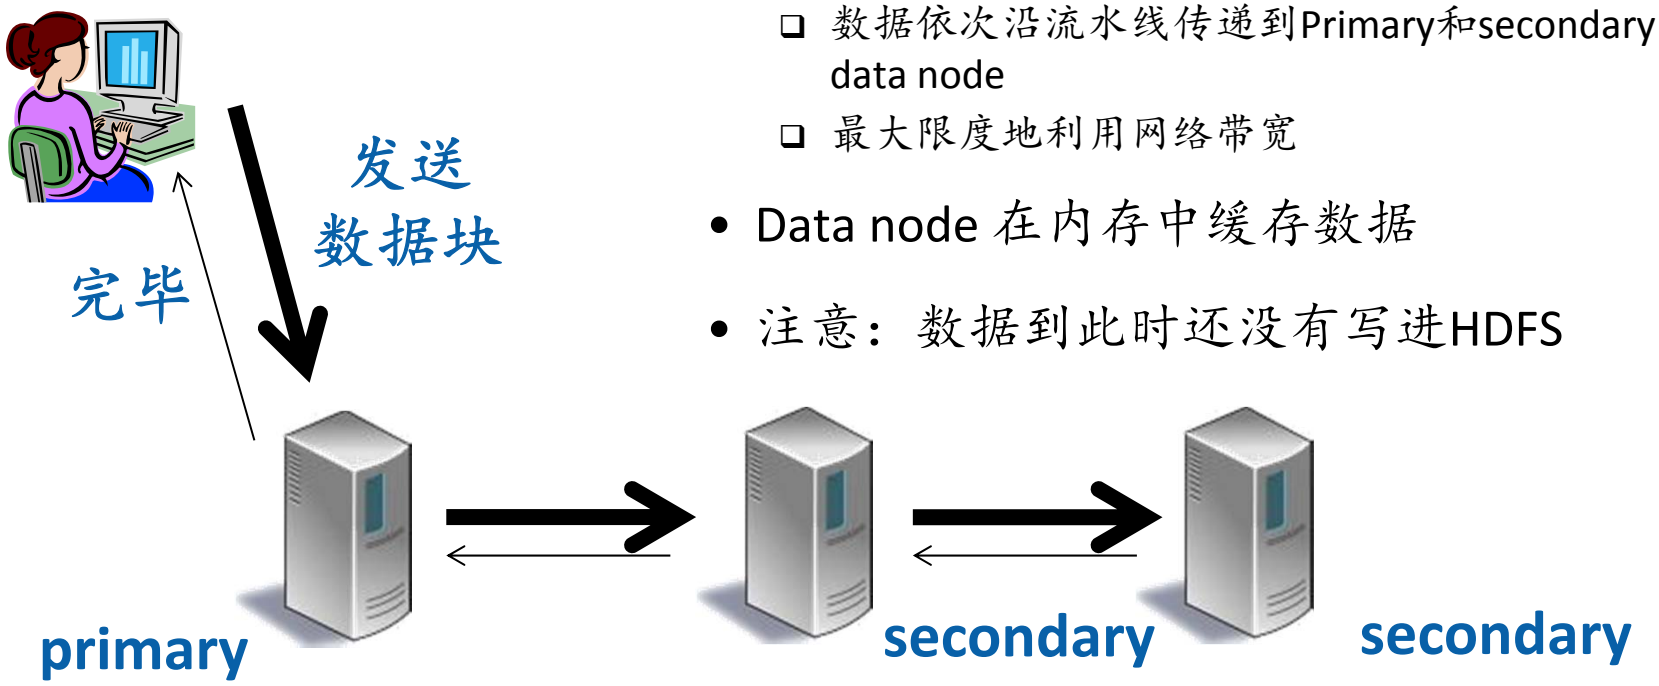

- 形成一个数据传递的pipeline
  - 数据依次沿流水线传递到Primary和secondary data node
  - 最大限度地利用网络带宽
- Data node 在内存中缓存数据
- 注意：数据到此时还没有写进HDFS

HDFS/GFS文件操作：write(3)

- 收到写命令时才进行真正地写操作
- 把缓存的数据写到文件系统中

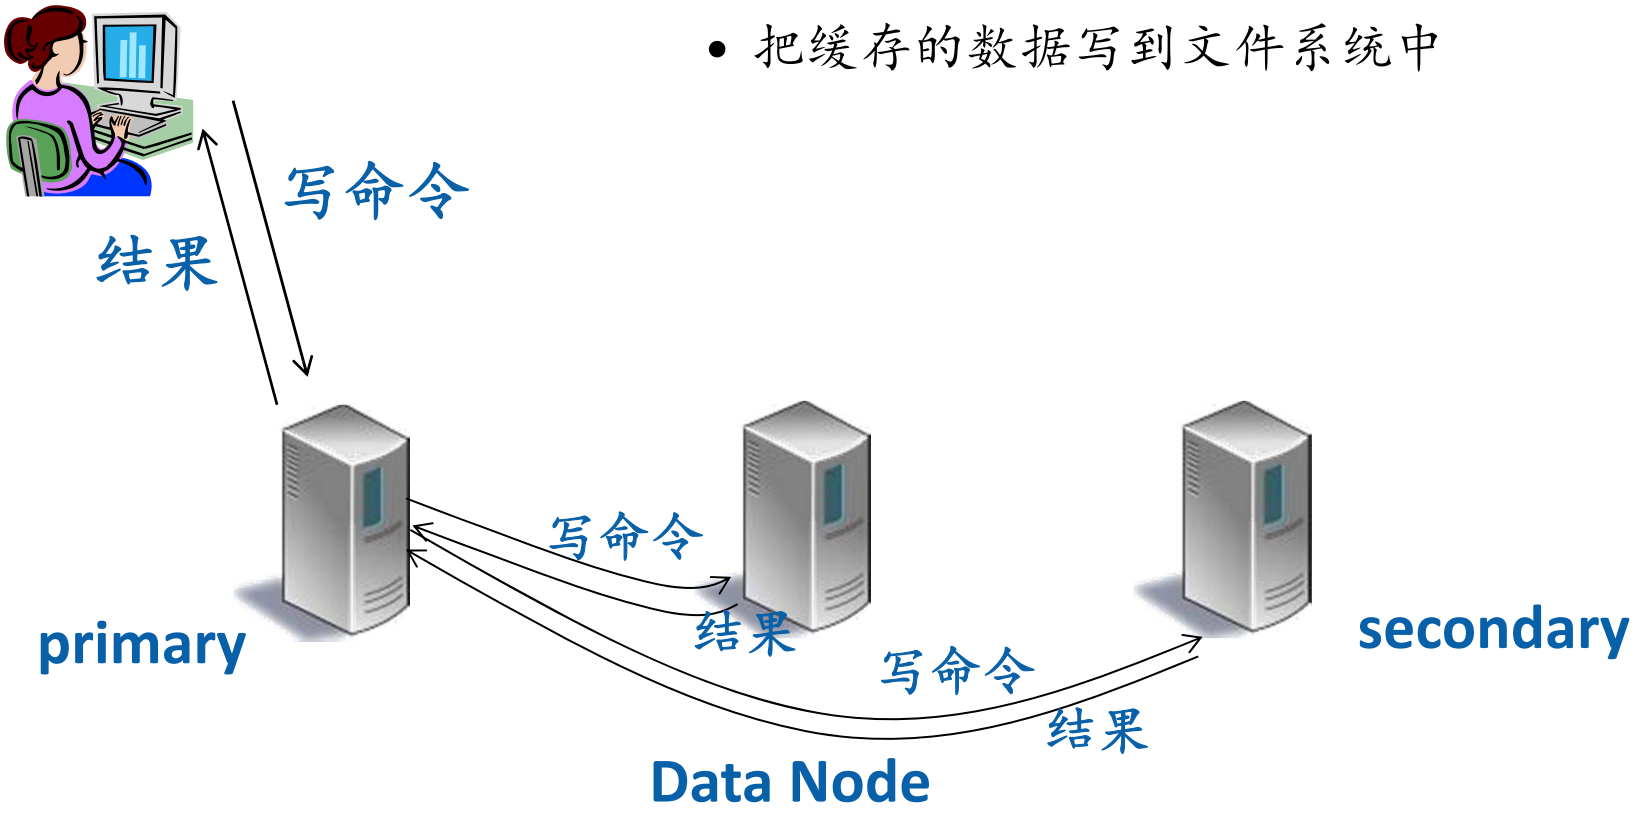

HDFS/GFS文件操作：并发写的问题

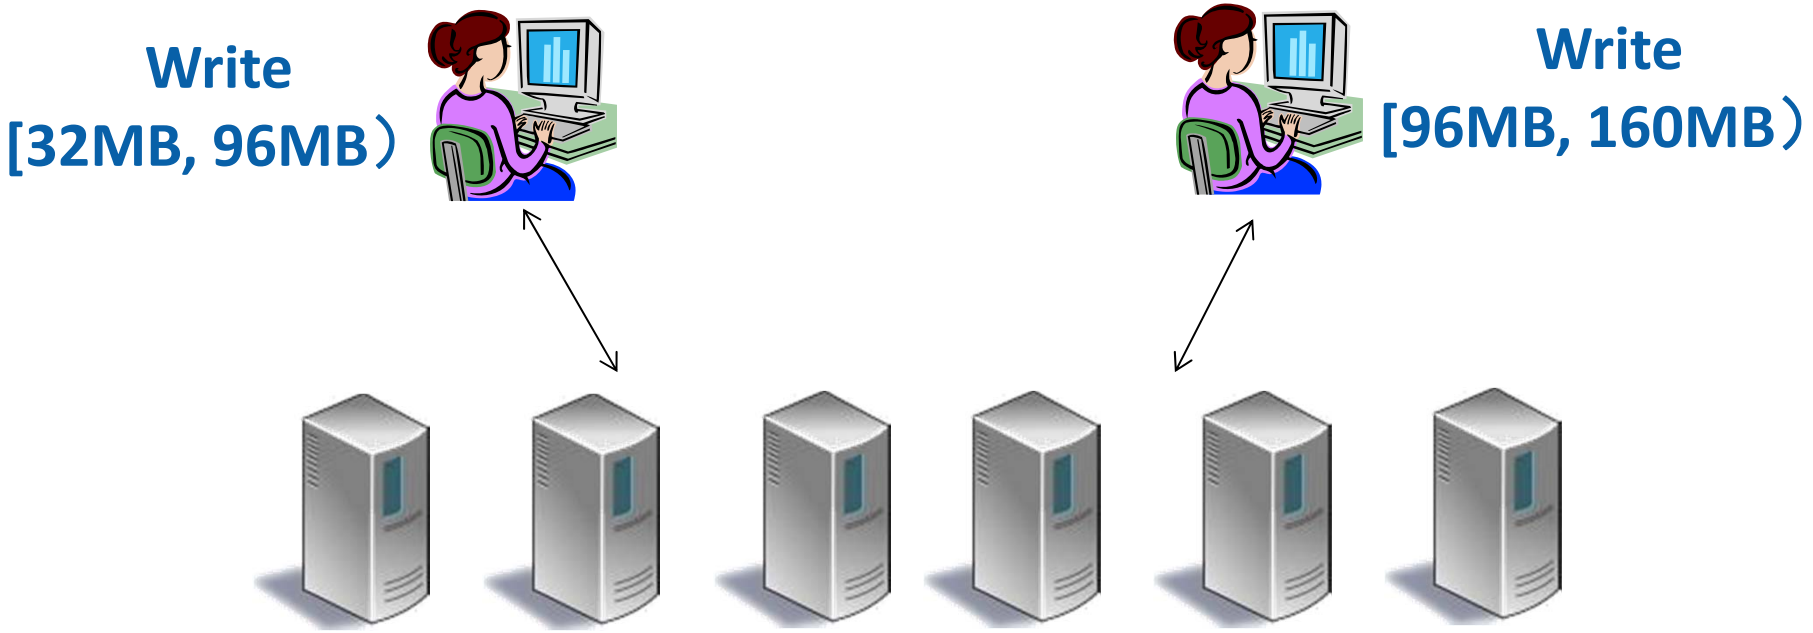

- 如果一个写操作跨了两个数据块
  - 那么就被分解成为两个独立的写数据块操作
  - 完全没有任何关于两个独立数据块写顺序的规定
  - 实际上是distributed transaction，有问题！

HDFS/GFS文件操作：并发写的问题

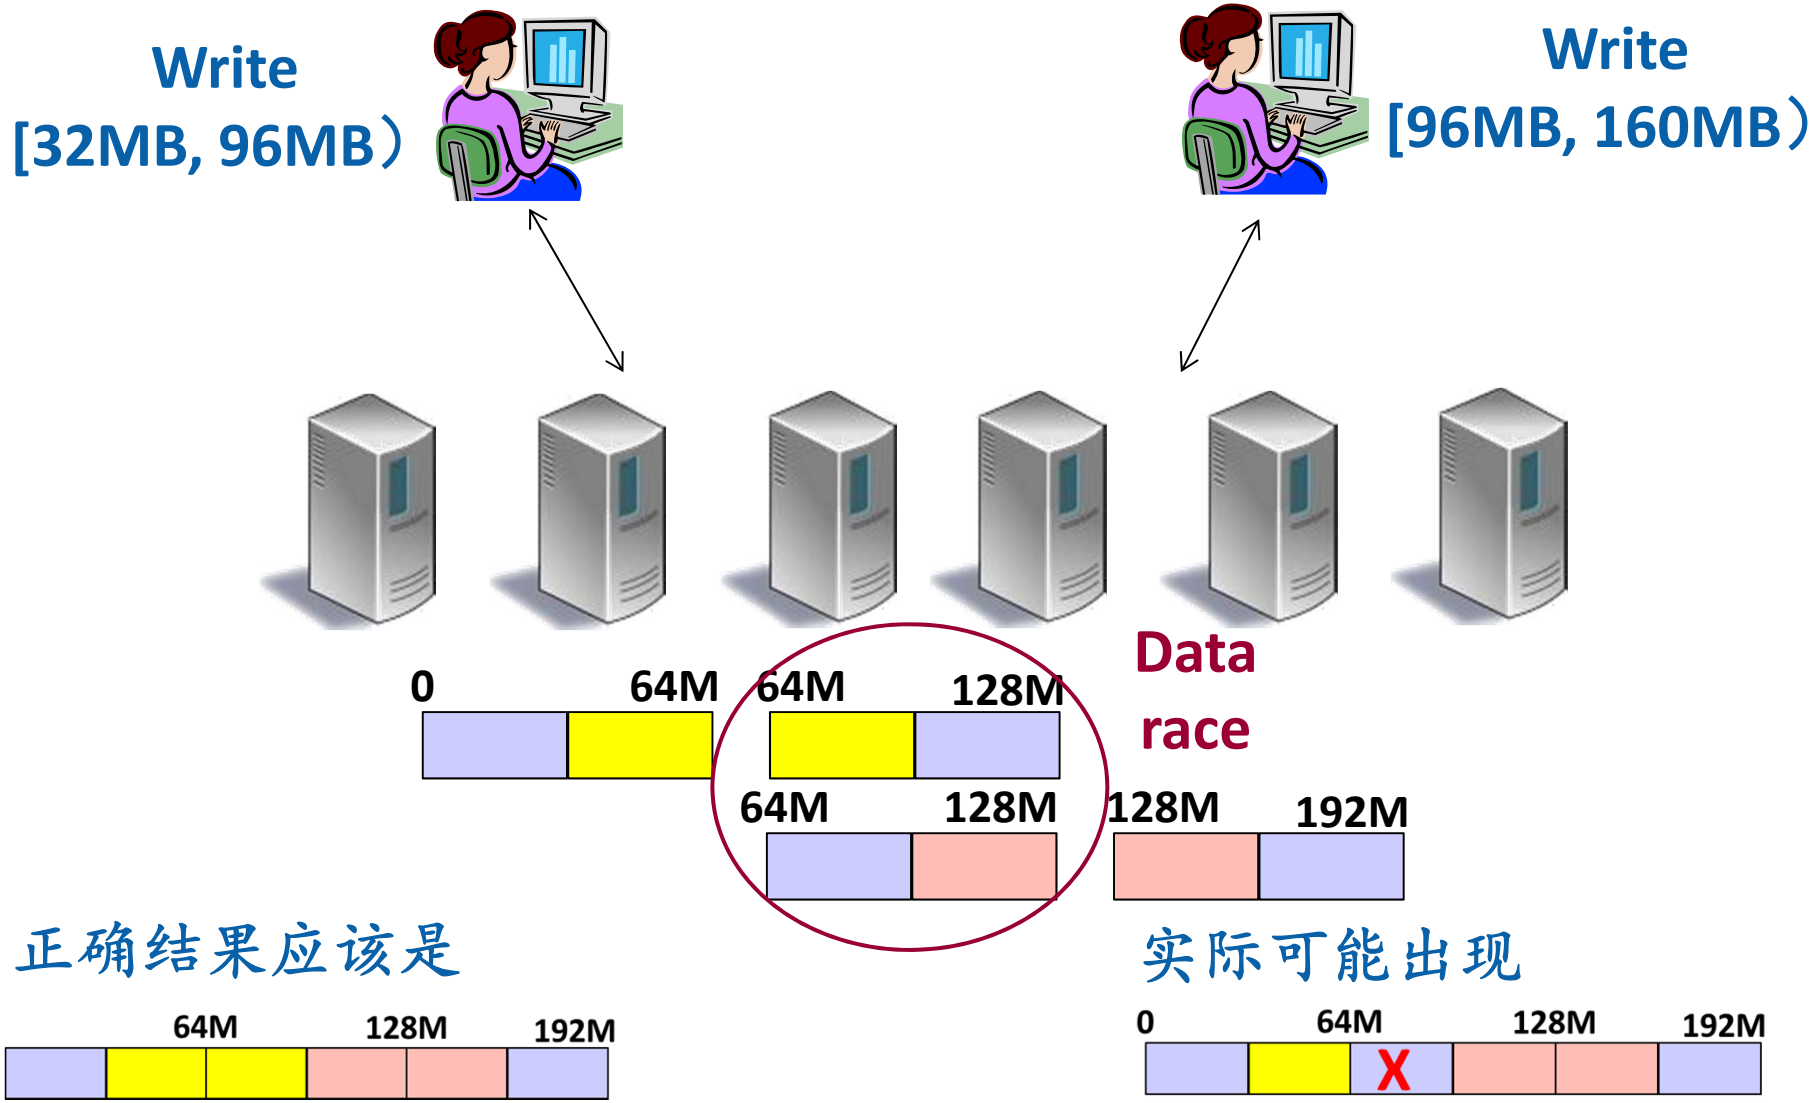

HDFS/GFS文件操作：并发Append

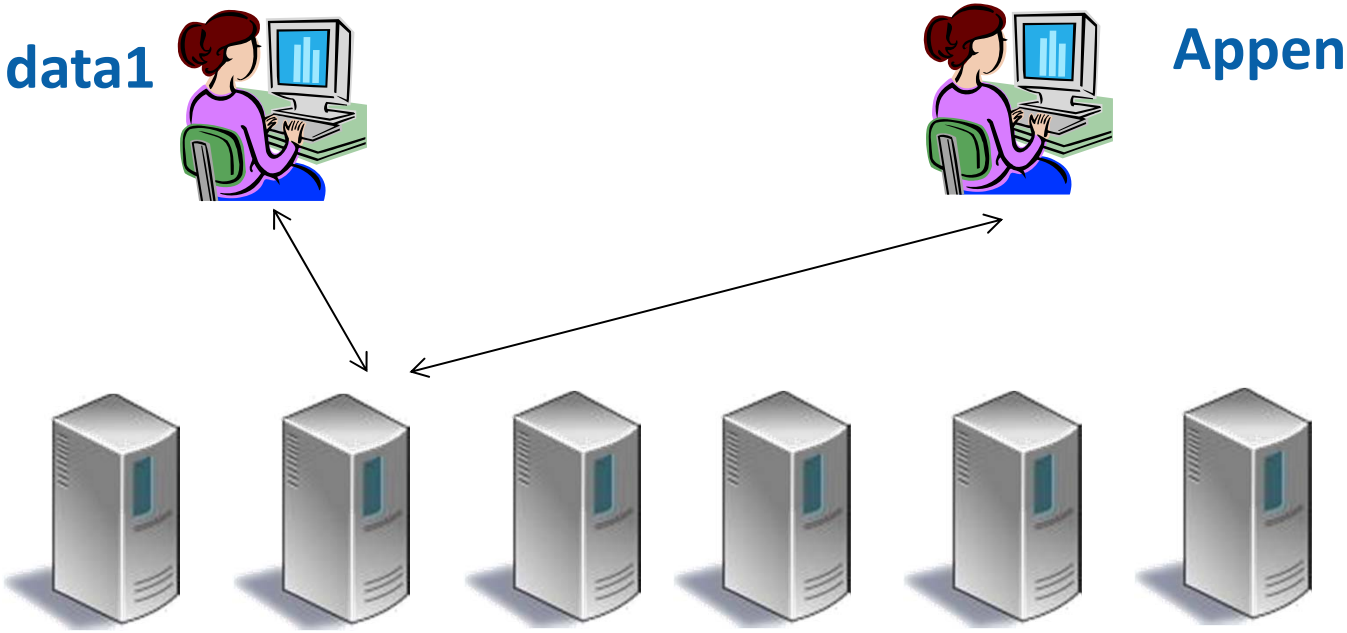

- 文件最后一个数据块在同一个primary data node
- 可以在单机上完成concurrency control
- 保证并行append成功，但是不保证append的顺序

HDFS/GFS小结

- 分布式文件系统
- 很好的顺序读性能
  - 为大块数据的顺序读优化
- 不支持并行的写操作：不需要distributed transaction
- 支持并行的append

总结

- 分布式系统基本概念
  - 网络与协议
  - 通信方式
  - 分布式系统类型、故障类型、CAP
- 分布式文件系统
  - NFS
  - AFS
- Google File System和HDFS