大数据系统与大规模数据分析

大数据存储系统（3）

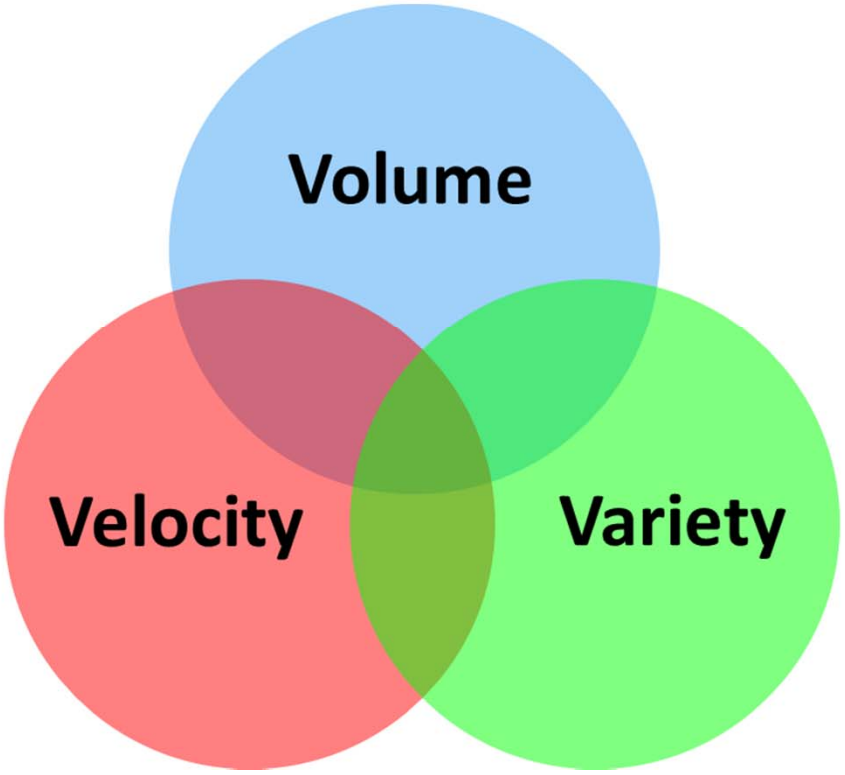

陈世敏

中科院计算所
计算机体系结构
国家重点实验室

作业时间安排

周次	内容	作业
第4周，3/31	大数据存储系统1：基础，文件系统，HDFS	作业1布置
第5周，4/7	大数据存储系统2：键值系统	
第6周，4/14	大数据存储系统3：图存储，document store	
第7周，4/21	大数据运算系统1：MapReduce, 图计算系统	作业1提交 作业2布置
第8周，4/28	大数据运算系统2：图计算系统，MR+SQL	
第9周，5/5	大数据运算系统3：内存计算系统	大作业布置 (系统,6人/组)
第10周，5/12	分布式哈希表，区块链技术中的加密算法	作业2提交
第11周，5/19	最邻近搜索和位置敏感（LSH）算法	作业3
第12周，5/26	奇异值分解与数据空间的维度约化	大作业布置 (分析,3人/组)
第13周，6/2	推荐系统	大作业 仅选1个
第14周，6/9	流数据采样与估计、流数据过滤与分析	
第15周，6/16	期末考试	
第16周，6/23	大作业验收报告	大作业验收

作业1安排

- 成绩：占总成绩10%
- 时间
  - 发布：2020/3/31(Wed)
  - 上交：**2020/4/21(Wed)，北京时间 6:09pm（共3周）**
  - 在sep课程网站>作业>作业1中提交
  - 晚交
    - 最晚：2020/4/28(Wed)，北京时间6:09pm，将扣除20%成绩
    - 之后不再接收，作业1成绩为0
- **抄袭：课程总分为0！**

作业提交的格式

- 文件命名
  - 组号_学号_hw1.java
  - 例如：0_201618013229032_hw1.java
  - 注意：上述文件名没有空格；不能上传rar或zip文件
- 程序中Java class的名字必须为
  - Hw1GrpX，其中X为组号，注意大小写
  - 例如： Hw1Grp0
- 自动检查程序会根据学号自动寻找对应的文件，重新命名为Hw1GrpX.java、编译、执行
  - 如果名称不正确，将无法找到或不能执行，就成绩=0

大数据存储系统（1）

- 分布式系统基本概念
  - 网络与协议
  - 通信方式
  - 分布式系统类型、故障类型、CAP
- 分布式文件系统
  - NFS
  - AFS
- Google File System和HDFS

大数据存储系统（2）

- Key-Value Store
  - Dynamo
  - Bigtable / Hbase
  - Cassandra
  - RocksDB
- Distributed Coordination: ZooKeeper
  - 概念
  - 数据模型和API
  - 基本原理
  - 应用举例

Outline

- Document Store
  - 树状结构数据模型
    - JSON
    - Google Protocol Buffers
  - MongoDB
    - API and Query Model
    - Architecture
- 图存储系统(Graph Database)

JSON

- JavaScript Object Notation
  - 是一个低成本的数据交换格式
  - 是Javascript程序语言标准(1999年)的子集
- JSON对应于程序语言中的结构与数组
- 举例：

```
{“id” : 131234, “name” : “张飞”, “major” : “计算机”, “year”: 2013, “course” :
   [ {“course name” : “体系结构”, “year” : “2014”, “grade” : 85},
    {“course name” : “操作系统”, “year” : “2014”, “grade” : 90},
    {“course name” : “英语”, “year” : “2013”, “grade” : 87} ],
  “address”: {“州” : ”幽州”,
                “郡” : ”涿郡”,
                “街道” : “张家庄”,
                “邮编” : ”072750”}
}
```

JSON 格式定义

- Value
  - 基础类型： string, number, true/false, null
  - Object
  - Array
- Object

  {“key_1” : $value_1$, … , “key_n” : $value_n$}
- Array

  [$value_1$, … , $value_n$]

JSON举例

- 我们仔细分析一下这个例子：

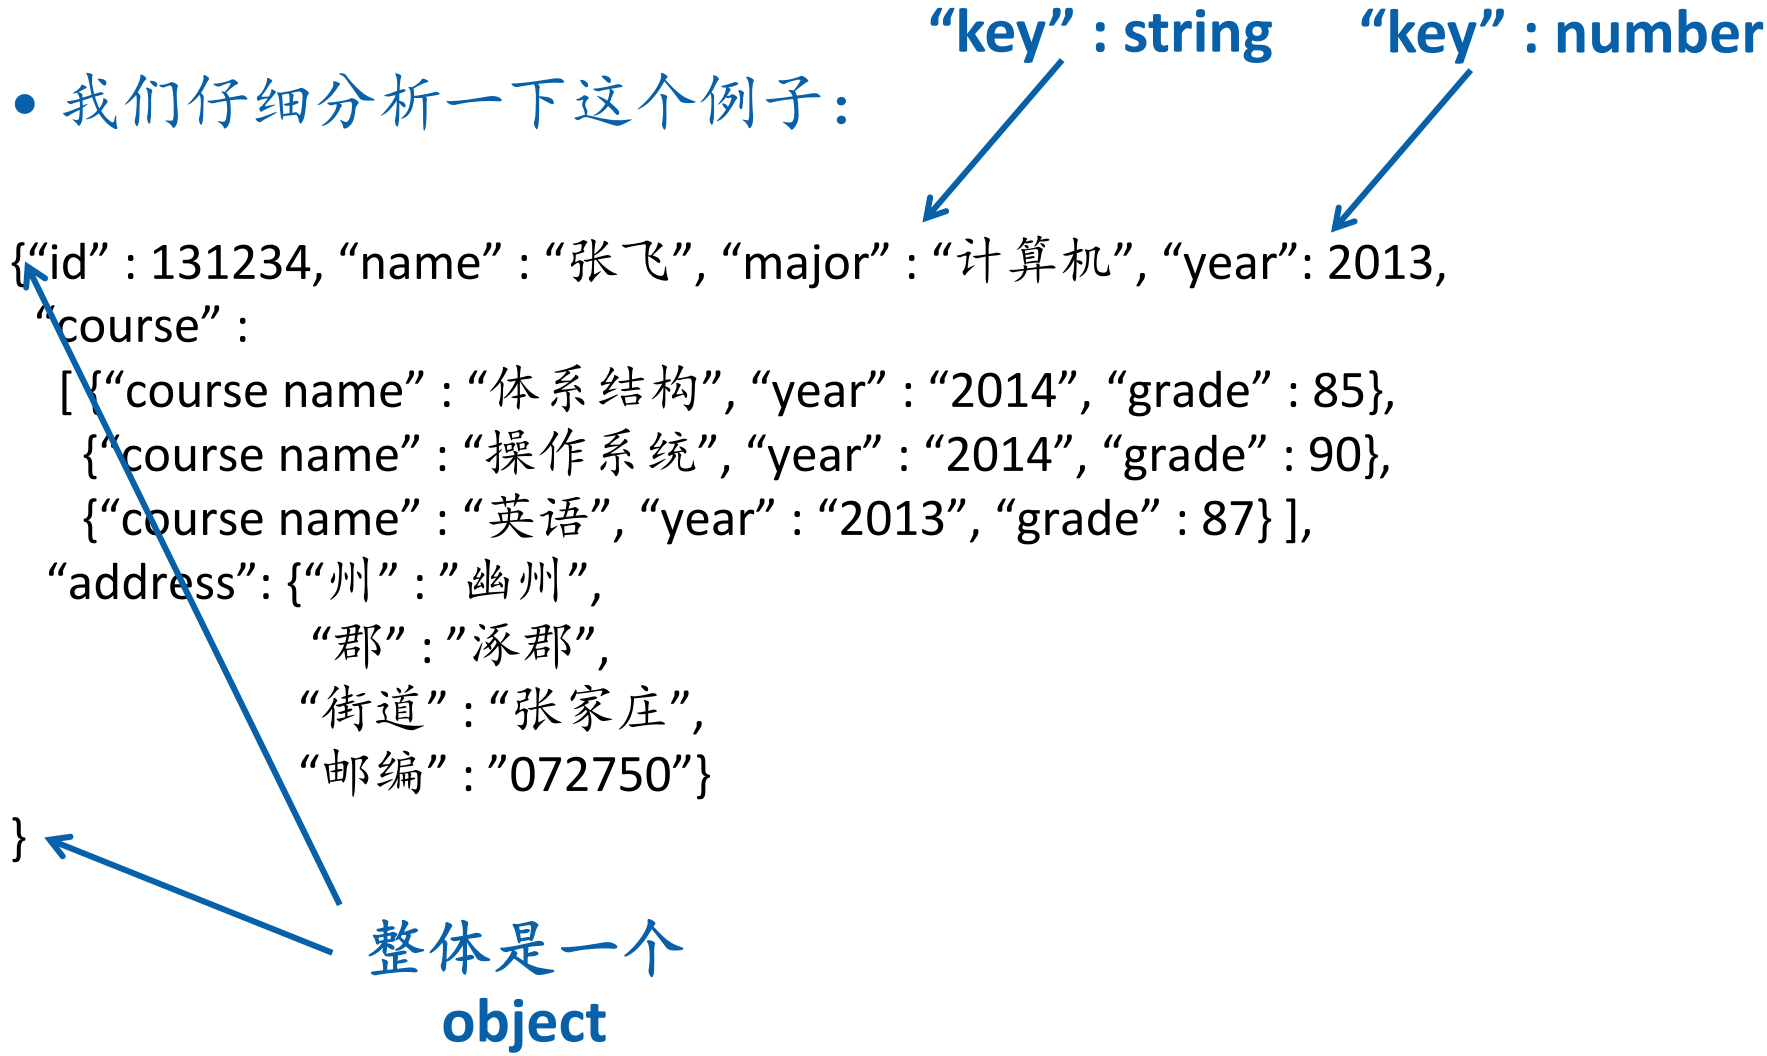

JSON举例

- 我们仔细分析一下这个例子：

```
{“id” : 131234, “name” : “张飞”, “major” : “计算机”, “year”: 2013,
  “course” :
    [ {“course name” : “体系结构”, “year” : “2014”, “grade” : 85},
      {“course name” : “操作系统”, “year” : “2014”, “grade” : 90},
      {“course name” : “英语”, “year” : “2013”, “grade” : 87} ],
   “address”: {“州” : ”幽州”,
               “郡” : ”涿郡”,
               “街道” : “张家庄”,
               “邮编” : ”072750”}
}
```

嵌套的Array，
Array的每个元素是一个object

JSON举例

- 我们仔细分析一下这个例子：

```
{“id” : 131234, “name” : “张飞”, “major” : “计算机”, “year”: 2013,
  “course” :
    [ {“course name” : “体系结构”, “year” : “2014”, “grade” : 85},
      {“course name” : “操作系统”, “year” : “2014”, “grade” : 90},
      {“course name” : “英语”, “year” : “2013”, “grade” : 87} ],
   “address”: {“州” : ”幽州”,
               “郡” : ”涿郡”,
               “街道” : “张家庄”,
               “邮编” : ”072750”}
}
```

嵌套的object

JSON举例

- 我们仔细分析一下这个例子：

```
{“id” : 131234, “name” : “张飞”, “major” : “计算机”, “year”: 2013,
  “course” :
    [ {“course name” : “体系结构”, “year” : “2014”, “grade” : 85},
      {“course name” : “操作系统”, “year” : “2014”, “grade” : 90},
      {“course name” : “英语”, “year” : “2013”, “grade” : 87} ],
   “address”: {“州” : ”幽州”,
                “郡” : ”涿郡”,
                “街道” : “张家庄”,
                “邮编” : ”072750”}
}
```

☞JSON的数据类型定义是完全动态的，一个JSON记录本身自定义了自己的类型，不需要事先声明schema

Google Protocol Buffers

- Google推出，最初用于实现网络协议，所以叫protocol buffers
- 可以用于表达程序设计语言中的结构和数组
  - Google提供了一套软件库，可以把Protocol buffers的记录压缩编码，和解压缩解码，用于网络传输和存储
- 要求先定义类型，然后才可以表达数据

Google Protocol Buffers 举例

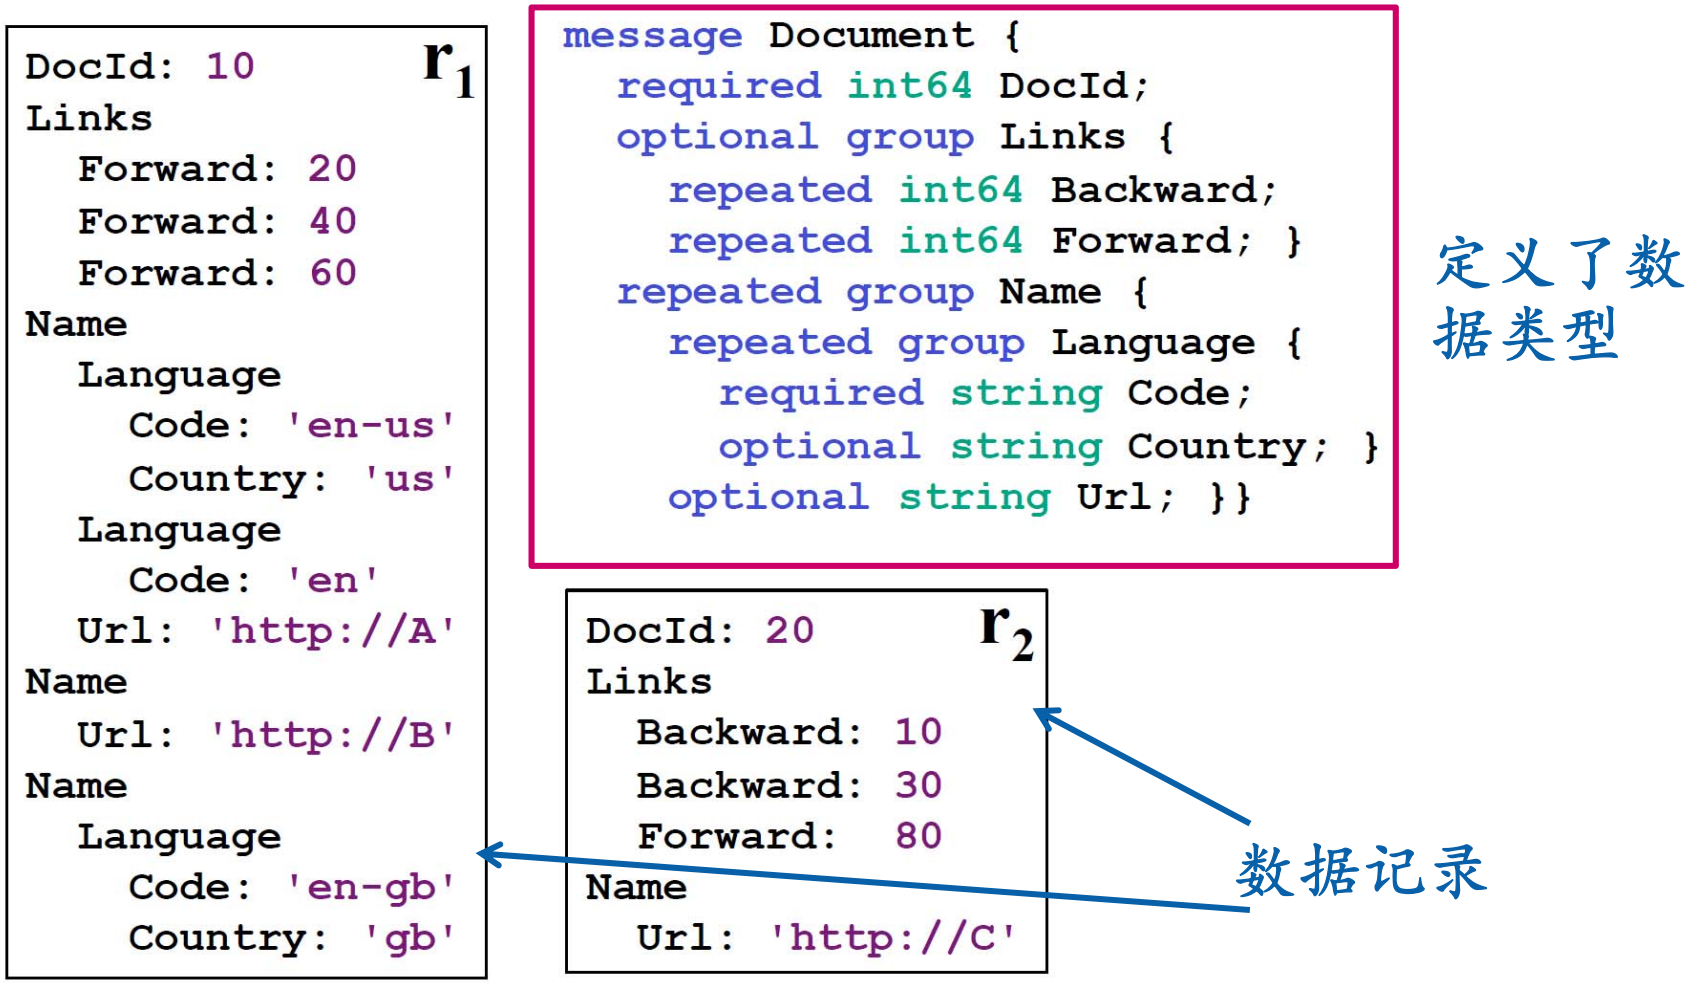

图来源："Dremel: Interactive Analysis of Web-Scale Datasets". PVLDB 3(1): 330-339 (2010)

Google Protocol Buffers 类型举例

```
message Document {
  required int64 DocId;
  optional group Links {
    repeated int64 Backward;
    repeated int64 Forward; }
  repeated group Name {
    repeated group Language {
      required string Code;
      optional string Country; }
    optional string Url; }}
```

把嵌套关系表达为一课语法树

?: optional

*: repeated

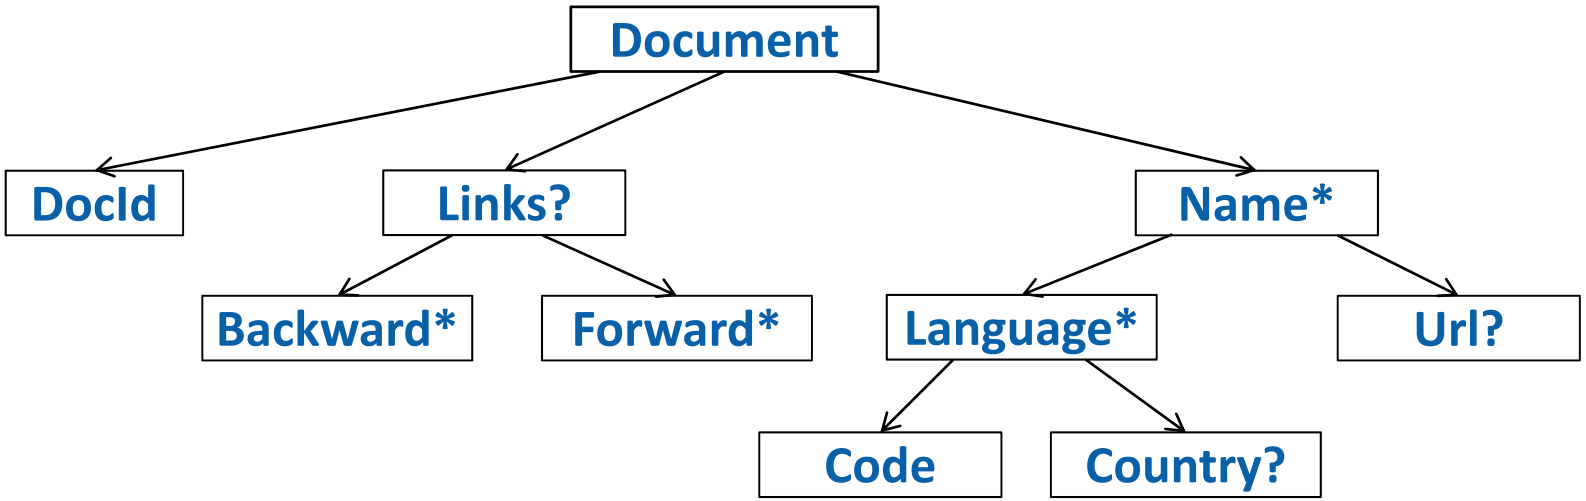

JSON vs. Google Protocol Buffers

- 相同点
  - 都可以表达程序设计语言中的结构和数组
  - 嵌套：JSON object, PB message/group
  - 数组：JSON array, PB repeated
  - 缺值的情况：JSON记录实际上没有规定一定要有什么域，PB optional
- 不同点
  - 数据类型：PB要求事先声明，JSON不需要
  - 实际使用情况不太一样
    - JSON数据设计的初衷是文本的
      - 但是MongoDB支持一种BSON的二进制编码方式
    - PB从设计开始就是二进制编码的，用于编码协议

JSON vs. XML

- 都是半结构化表示

- 10年前，XML刚出现时，期望很高
  - 但是XML非常heavy-weight
  - XML文件需要格式定义，XML的各种tag也使其比较大

- JSON比较light-weight
  - 自定义格式，简单的key-value形式
  - 已经逐渐为大量的应用所采用

其它相关数据格式/系统

- Apache Avro：一种树状数据格式
- Apache Thrift
  - 基于类似的理念，实现多语言的互相RPC调用
- Apache Parquet：一种列式树状数据格式

Document Store

- Document store
  - JSON是基本数据类型，存储为BSON二进制表示
- 基于C++实现
- 名词
  - Database ~ 关系型中的数据库概念
  - Collection ~ 关系型中的table概念
  - Document ~ 关系型中的记录概念
- 一个database包含多个collections，每个collection包含多个documents
  - document < 16MB

MongoDB

- 安装完毕后，主要有3个可执行程序
  - mongod - The database process.
  - mongos - Sharding controller.
  - mongo - The database shell (uses interactive javascript).

- 下面的例子都是基于mongo

MongoDB vs. SQL

- SQL的简单功能在MongoDB中都有对应的功能
- 下面我们以一个具体的例子来说明

{_id: ObjectId("509a8fb2f3f4948bd2f983a0"),
student_id : 131234, name : “张飞”, major : “计算机”, year: 2013}

注意：mongodb中key的双引号省略了

SQL create table

MongoDB的语法知道一下，考试不要求会写，但需要读懂

MongoDB

```
db.student.insert({
    student_id : 131234,
    name : “张飞”,
    major : “计算机”,
    year: 2013
})
```

SQL

```
create table student (
    student_id integer,
    name varchar(20),
    major varchar(20),
    year integer
);
```

JSON不定义类型，多以没有表定义的方法，第一个插入生成collection

{_id: ObjectId("509a8fb2f3f4948bd2f983a0"),
student_id : 131234, name : “张飞” , major : “计算机” , year: 2013}

SQL insert

MongoDB

```
db.student.insert({
    student_id : 131234,
    name : “张飞”,
    major : “计算机”,
    year: 2013
})
```

SQL

```
insert into student
values (131234, “张飞”, “计算机”, 2013);
```

{_id: ObjectId("509a8fb2f3f4948bd2f983a0"),
student_id : 131234, name : “张飞” , major : “计算机” , year: 2013}

SQL select

MongoDB

```
db.student.find(
   { major : "计算机" },
   {name : 1, year:1, _id:0}
)
```

SQL

```
select name, year
from student
where major = "计算机";
```

{_id: ObjectId("509a8fb2f3f4948bd2f983a0"),
student_id : 131234, name : "张飞" , major : "计算机" , year: 2013}

SQL group by aggregation

MongoDB

```
db.student.aggregate( [
{$match : { major : “计算机” }},
{$group : { _id:{year: “$year”},
            cnt: {$sum: 1}}
] )
```

SQL

```
select year, count(*) as cnt
from student
where major = “计算机”
group by year;
```

{_id: ObjectId("509a8fb2f3f4948bd2f983a0"),
student_id : 131234, name : “张飞” , major : “计算机” , year: 2013}

SQL group by aggregation

MongoDB另一种实现

```
db.student.group({
    key: { year: 1 },
    cond: { major: "计算机"} },
    $reduce:
      function(curr, result){
            result.total += 1;
      },
    initial: {total: 0}
} )
```

SQL

```
select year, count(*) as cnt
from student
where major = “计算机”
group by year;
```

{_id: ObjectId("509a8fb2f3f4948bd2f983a0"),
student_id : 131234, name : “张飞” , major : “计算机” , year: 2013}

其它运算相关

- 不支持Join
  - 两个Collection之间不能通过join连接起来
  - 想法
    - 相互关联的数据可以放在一个document中，嵌套表达
- 可以定义Index
  - Btree
  - Node size: 8KB

单机MongoDB

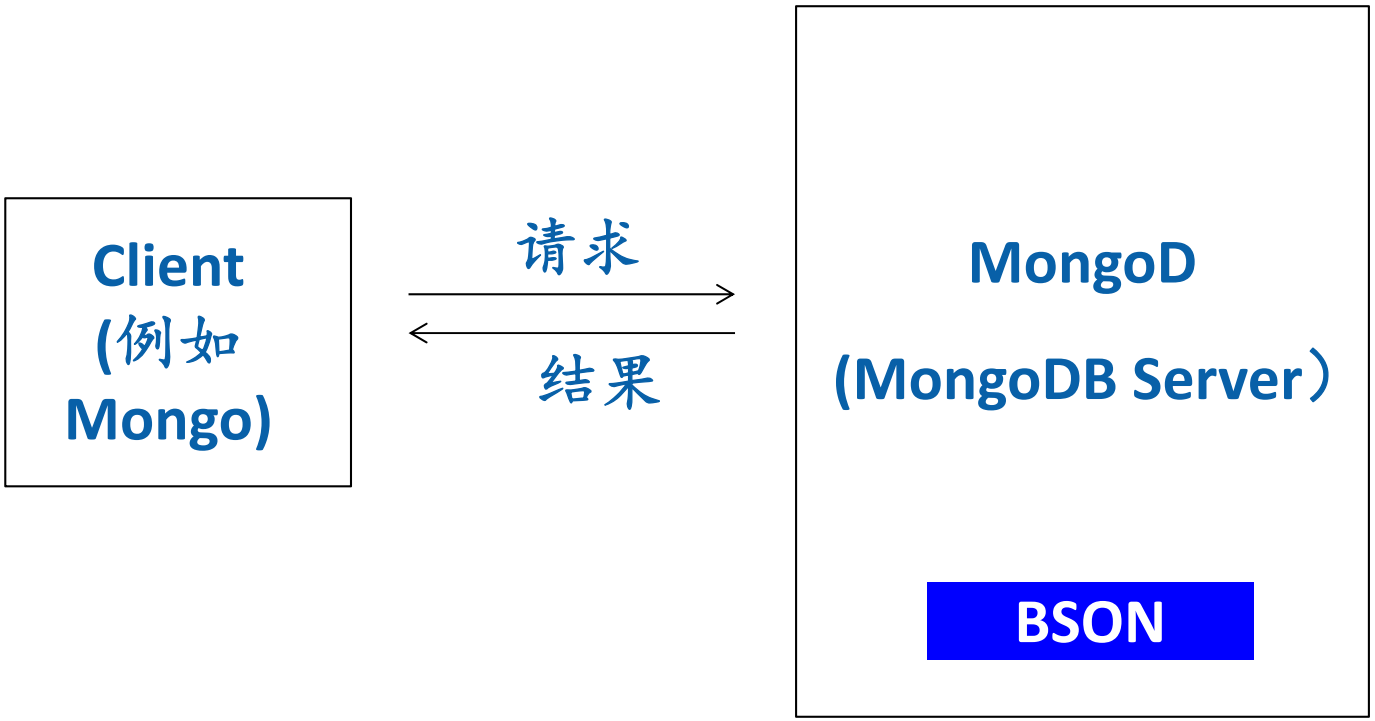

- 与RDBMS(例如MySQL) 非常相似，采用Operator Tree进行执行
- BSON：一种JSON二进制表示
  - 行式，key都是字符串，value根据具体的类型存储二进制值
- 后端可选存储引擎：WiredTiger（默认）等

分布式MongoDB

- Sharding = horizontal partitioning

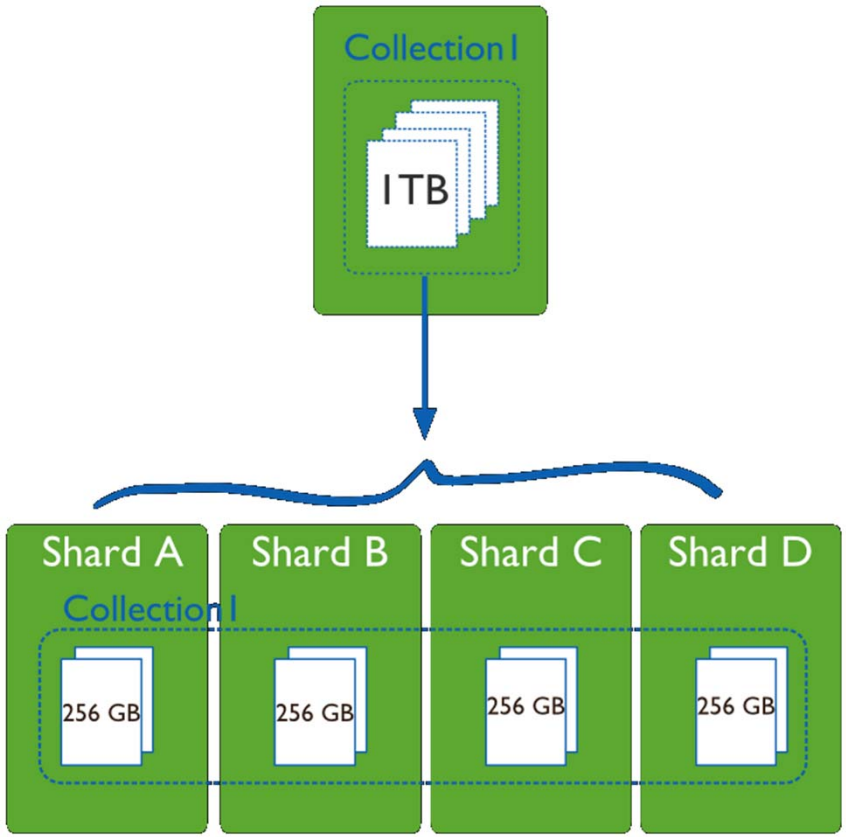

MongoDB Manual

- Shard key
- range partitioning
- hash partitioning

分布式MongoDB

- Sharding = horizontal partitioning

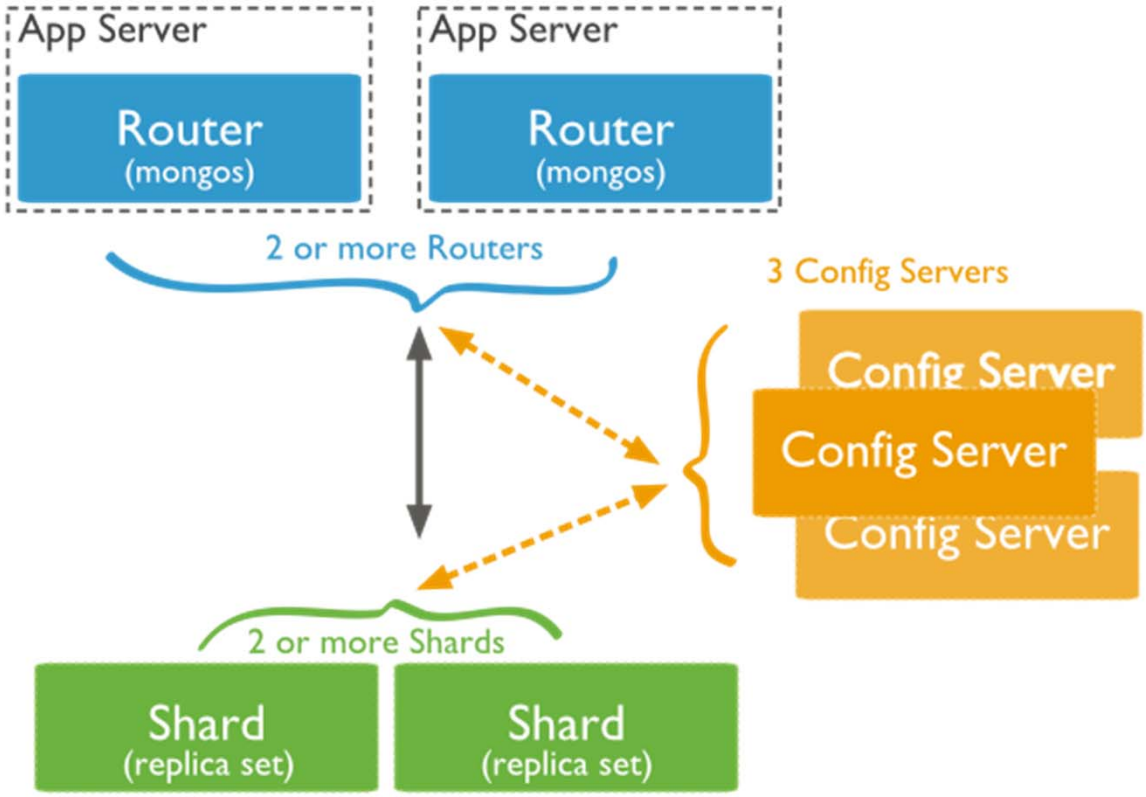

MongoDB Manual

- 没有Join操作
- 选择、投影、分组统计等可以在多个Shard上分布式执行
- 如果过滤条件中包括shard key，mongos会选择符合条件的shard(s)执行

ACID?

- 多document的Transaction
  - Version 4.0之前：只保证单个document（记录）修改的一致性，没有transaction概念
  - Version 4.0增加了多个记录的transaction支持
- Concurrency control
  - 根据存储引擎，具体支持Document-level 或 collection-level
  - WiredTiger支持document-level并发控制
- Journaling
  - 即logging
  - ☞Write concern

Write Concern

- 什么时候认为写完成了？
- MongoDB有多种不同的Write Concern等级
  - Unacknowledged: 写请求发送了，就认为完成
  - Acknowledged：MongoDB应答了收到写请求，就认为完成
  - Journaled：MongoDB把写请求记录在硬盘上的日志中，认为完成
- 显然，前两种并不能保证掉电后写请求仍然有效！
  - Journal会每隔一段时间写入硬盘，这个时间间隔可能是60秒！
    - 这期间发生的数据修改可能丢失！
  - 是性能 vs. 可靠性的折中方案
  - 在配置使用时，需要小心

Availability

- 每个shard可以有多个副本
- 副本一致性vs.性能

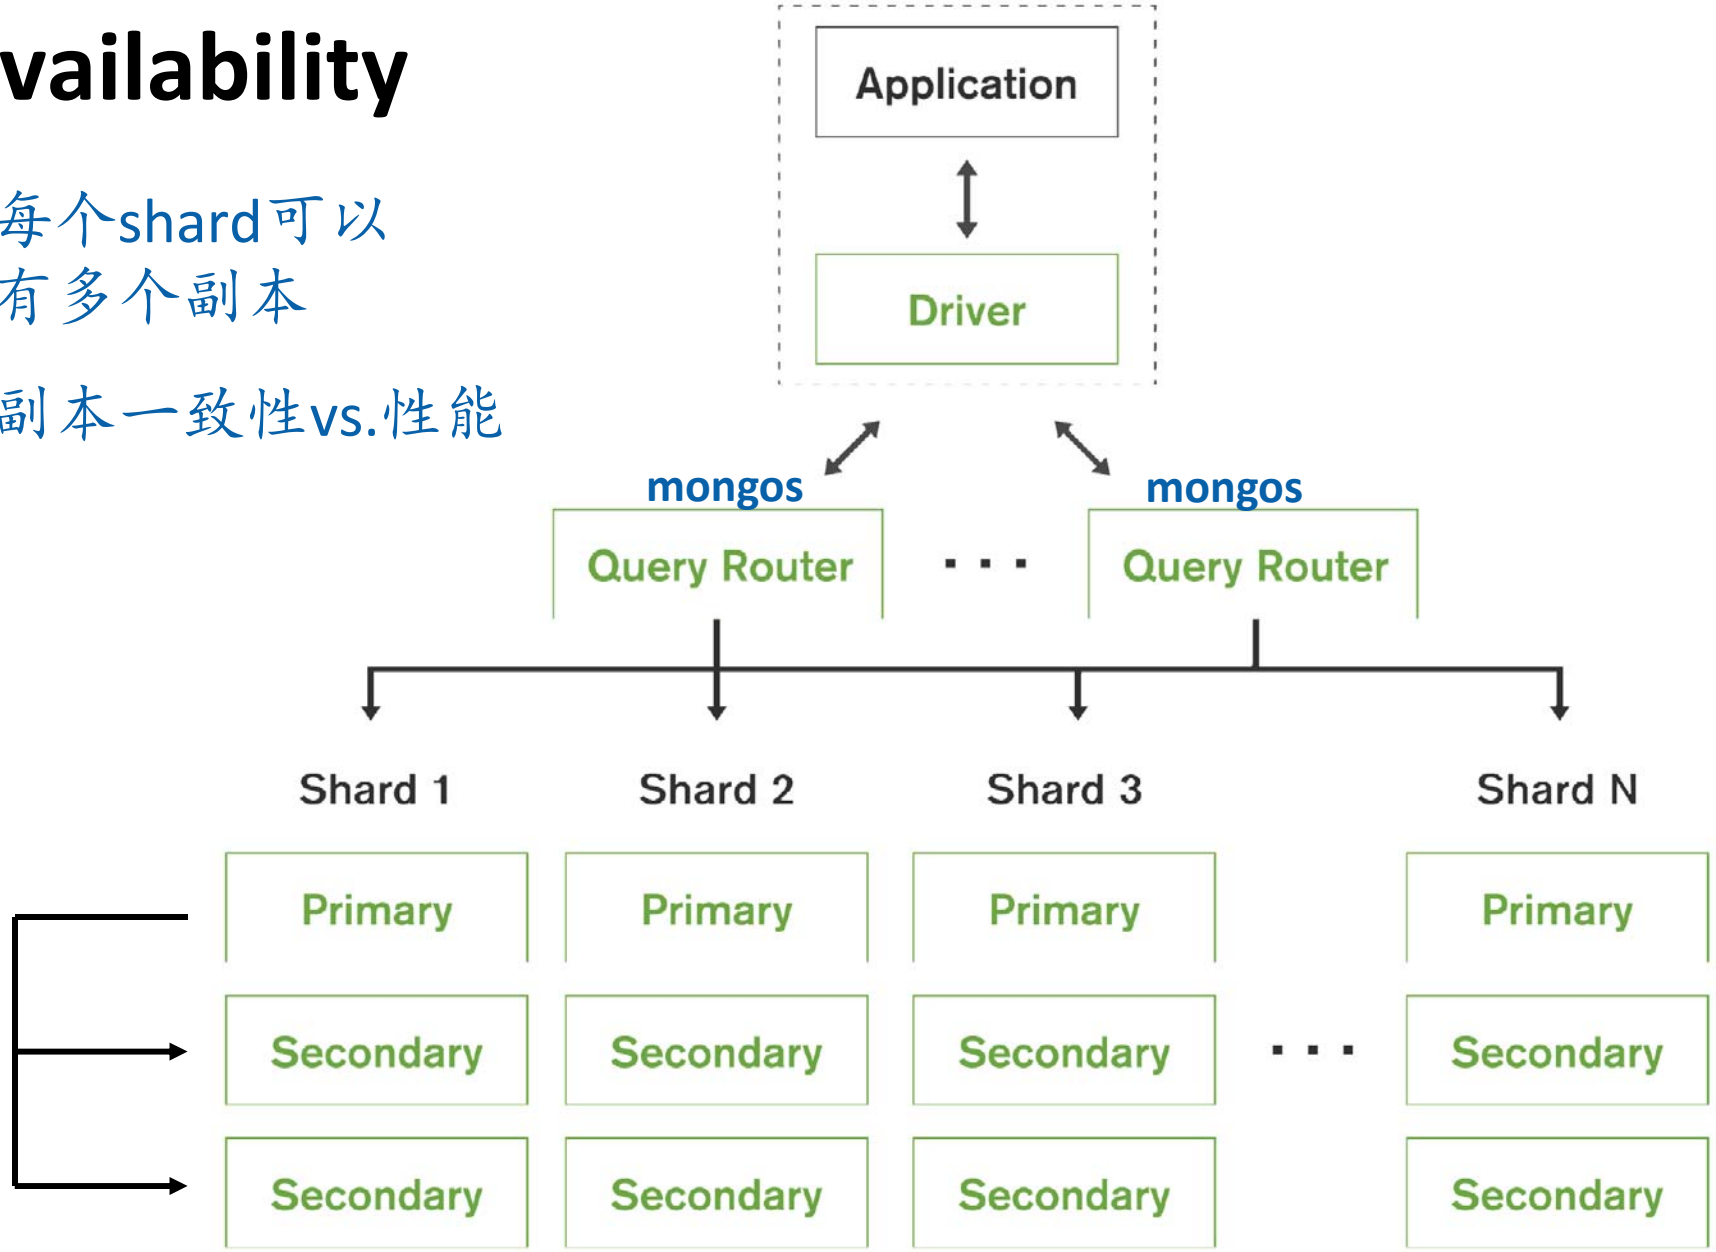

在RDBMS中支持JSON

- 例如PostgreSQL，Oracle等
- 把一个JSON document存储为一个字符串或字节串
  - 例如，PostgreSQL中支持json(文本)和jsonb(二进制)类型
  - 关系表的一个列中对应整个JSON document
  - 数据库提供一组function，可以在SQL中访问JSON列的内容

ID	Name	Birthday	Gender	Major	Year	GPA	myjson
131234	张飞	1995/1/1	男	计算机	2013	85	{…}
145678	貂蝉	1996/3/3	女	经管	2014	90	{…}
129012	孙权	1994/5/5	男	法律	2012	80	{…}
…	…	…	…	…	…	…	{…}
…	…	…	…	…	…	…	{…}
…	…	…	…	…	…	…	{…}

多模数据库系统（Multi-Model DB)

	基础数据类型	支持数据类型	实现语言
ArangoDB	JSON	JSON, 图，KV	C++, Javascript
OrientDB	字节串	JSON, 字节串，图	Java
CouchBase	JSON	JSON, KV	C/C++, Erlang, Go
MarkLogic	XML	XML, JSON, RDF图	C/C++, JavaScript

- 支持多种数据模型
- 通常是在JSON等树状结构模型的基础上形成

Outline

- Document Store
- 图存储系统(Graph Database)
  - 图数据模型
  - Neo4j
  - JanusGraph
  - RDF和Sparql

图(Graph)的概念

- G=(V, E)
  - V：顶点(Vertex)的集合
  - E：边(Edge)的集合
    - 边 e=(u,v), u∈V, v∈V
- 有向图（directed graph）
  - 边有方向
- 无向图
  - 边没有方向
  - 可以用有向图表达无向图：每条无向边➔2条有向边

Twitter社交网络图

顶点是人，
边是人与人之间的关系

Created with NodeXL (http://nodexl.codeplex.com) from the Social Media Research Foundation (http://www.smrfoundation.org)

Internet Connection Map

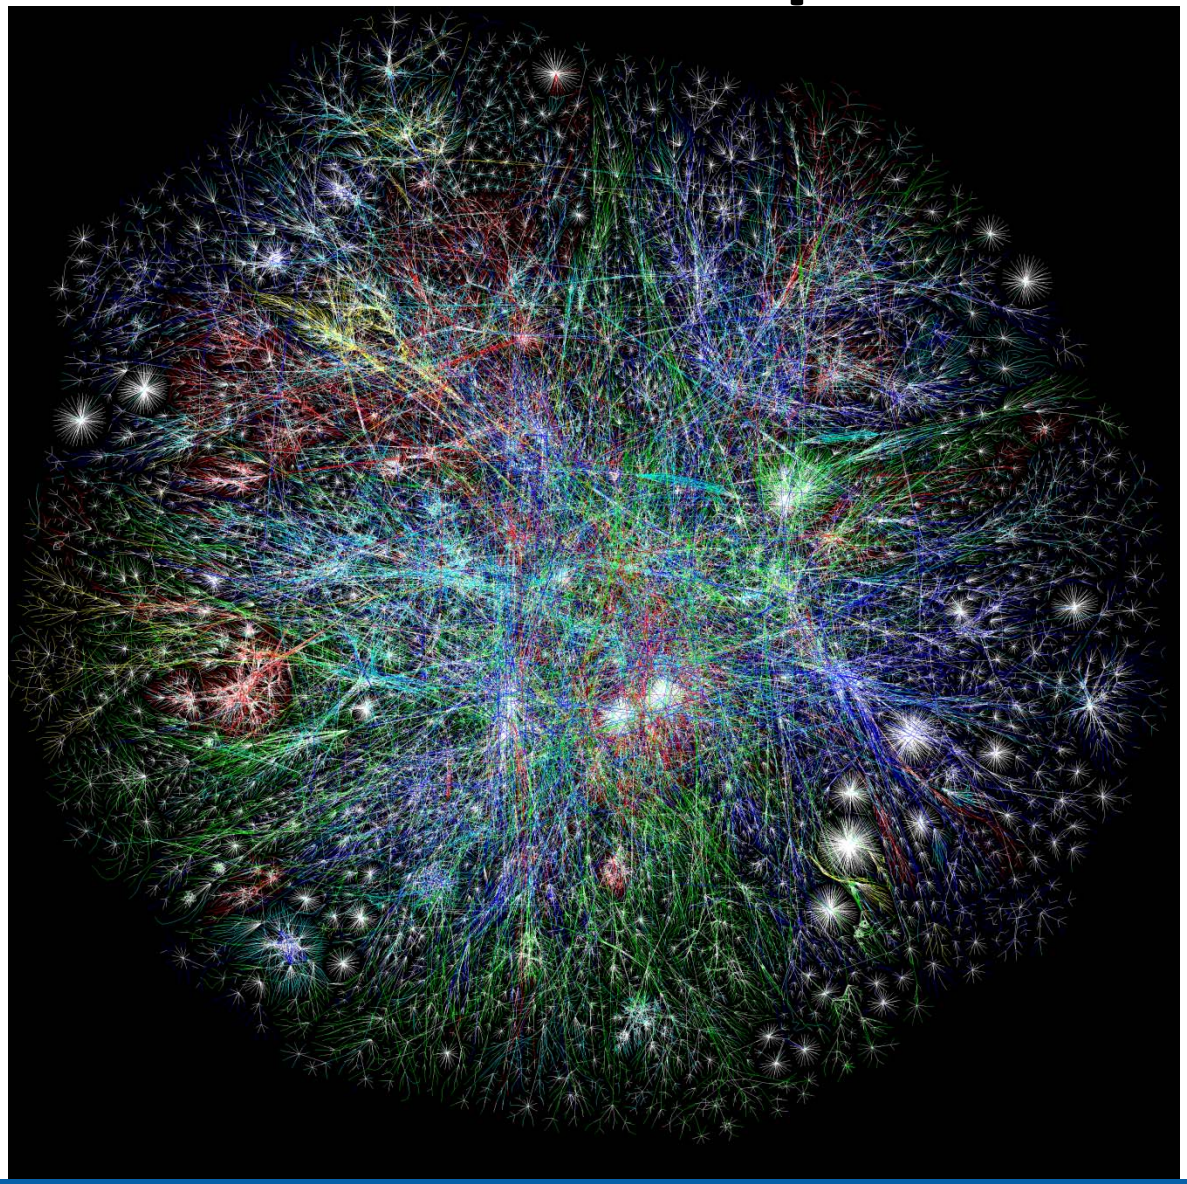

铁路网

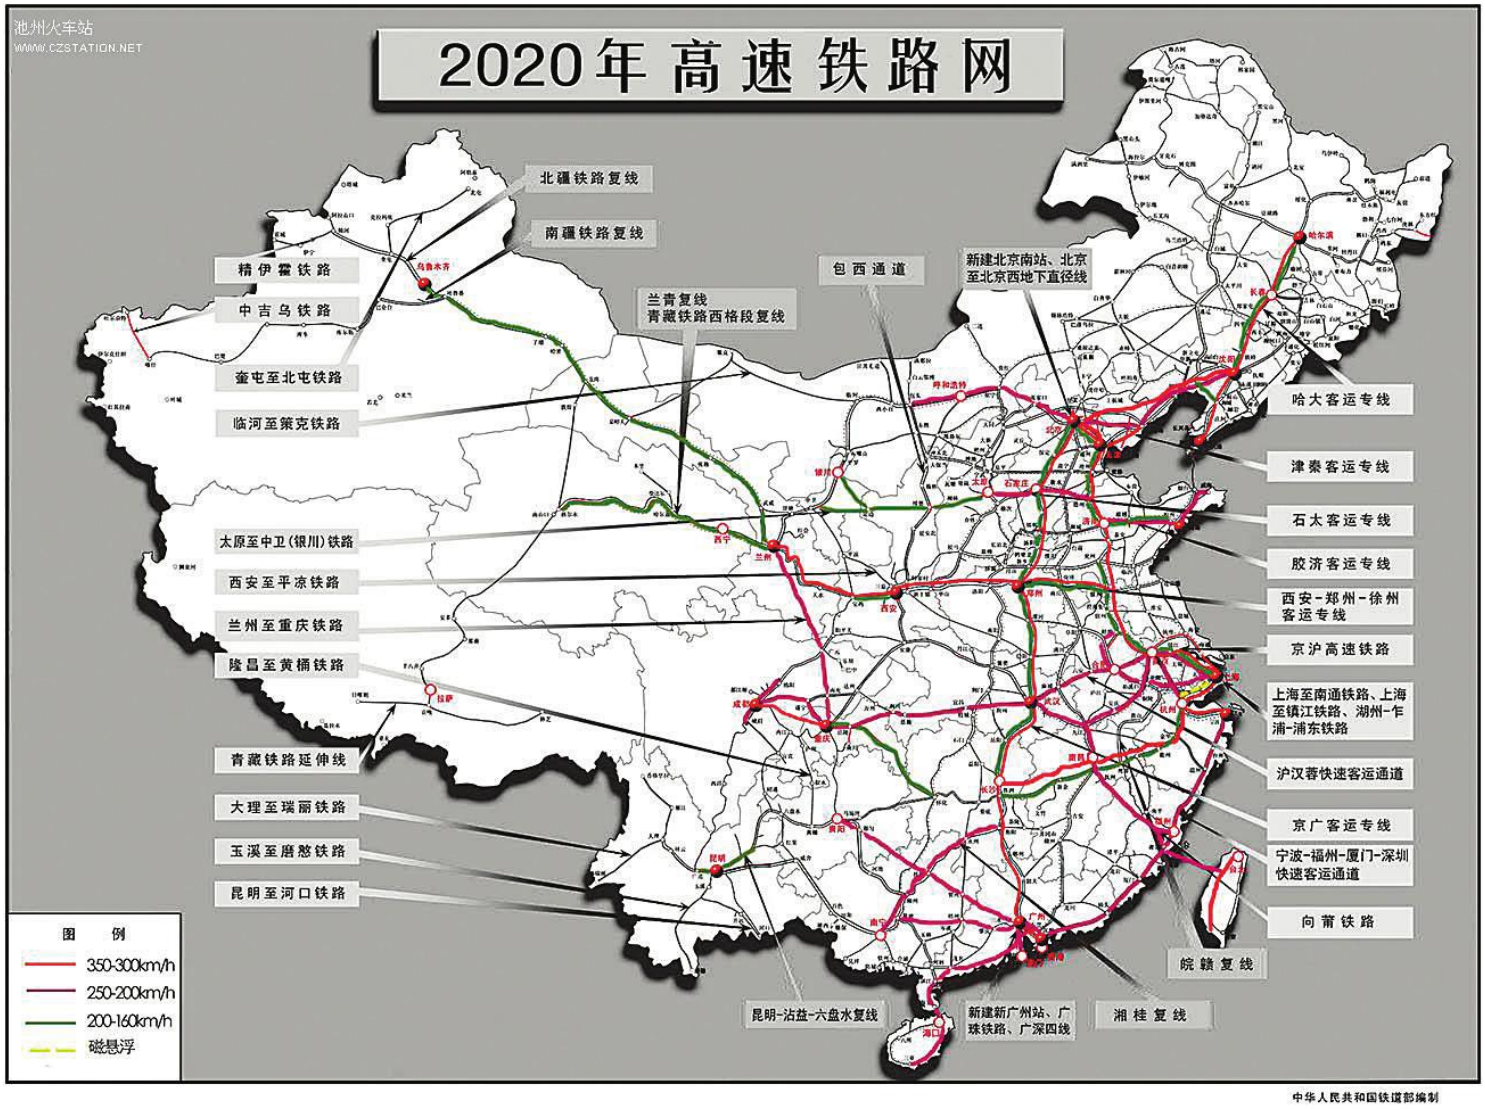

北京地铁

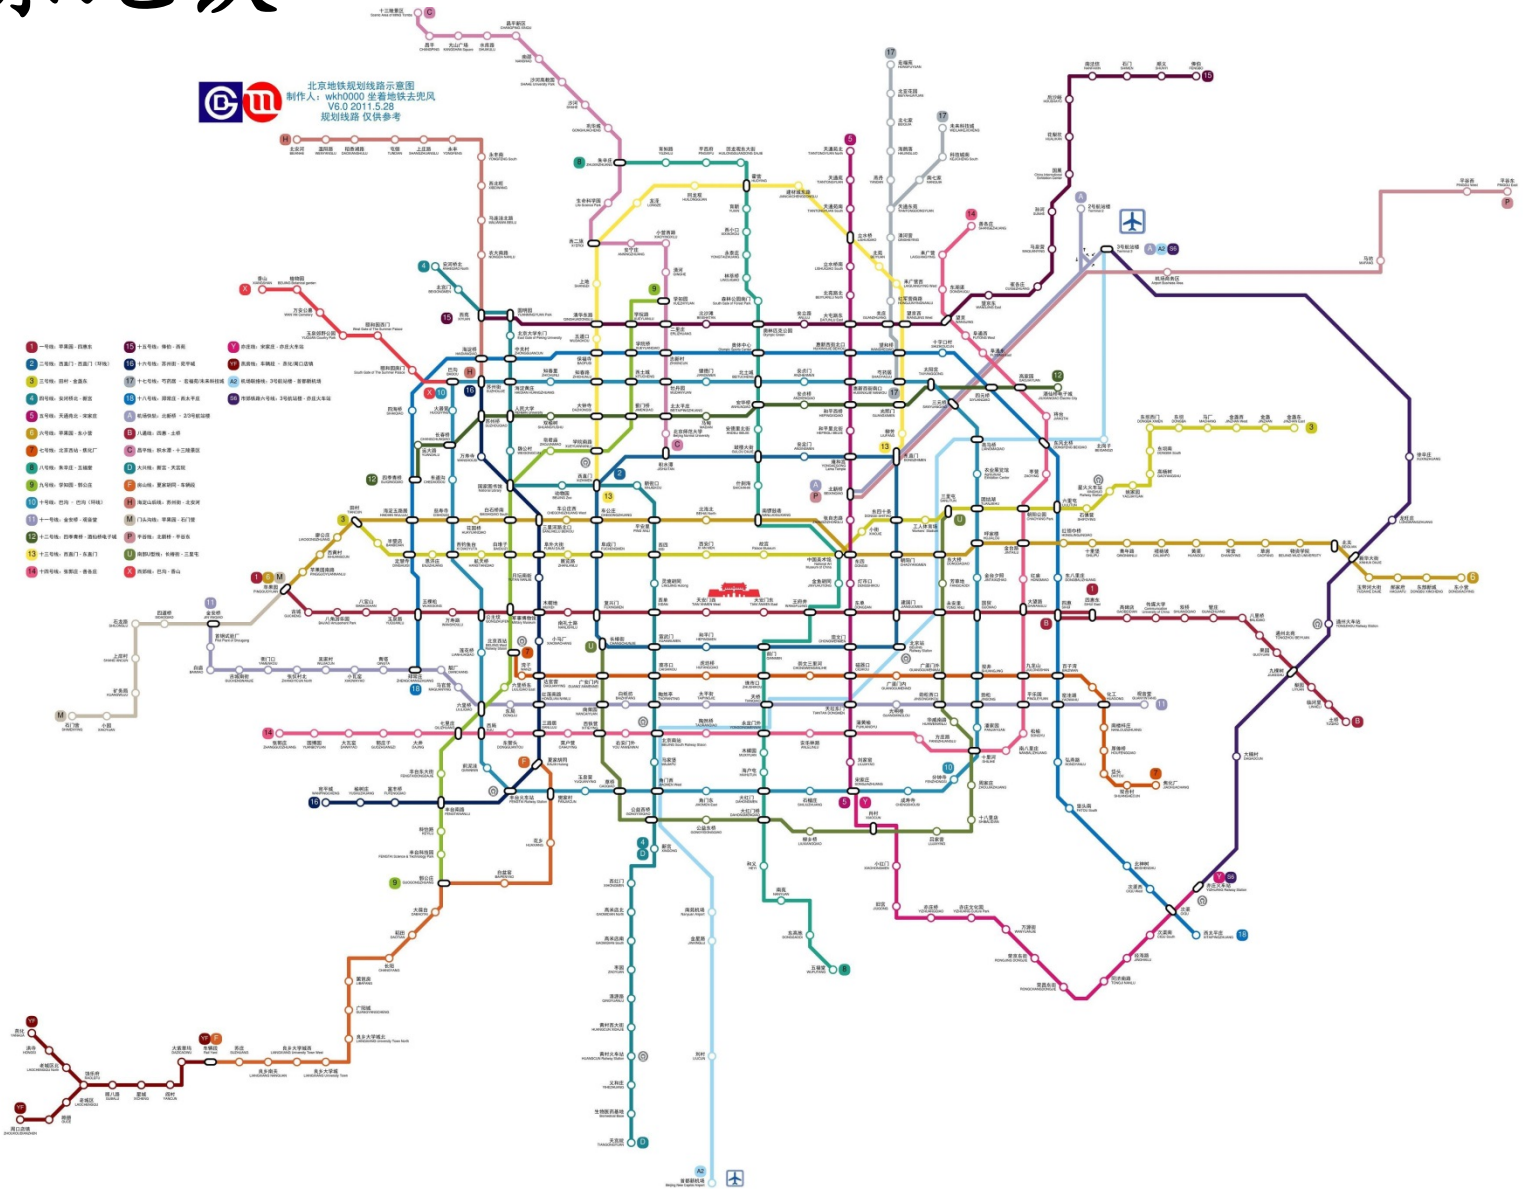

与图相关的系统

- 图数据存储系统
  - 存储图顶点和边
  - 提供顶点和边的查询
- 图运算系统
  - 以图为基础运行大规模算法
- 本节课关注：图数据存储系统

Neo4j

- Native graph database
  - 采用自定义的结构在本地硬盘存储图，而不是存在数据库关系型表中
- 开源Java实现
- Neo4j存储
  - 顶点：称为node
  - 边：称为relationship
  - 顶点和边上可以存储多个key-value值：称为property
- Neo4j使用
  - Cypher：Declarative query language
  - Traversal: Embedded Java lib

Node in Cypher

Cypher的语法知道一下，考试不要求会写，但需要读懂

(nodename:type, {property_key:value, key:value})

例子：

(张飞)

(张飞:Student)

(张飞:Student, {name: “张飞”, major : “计算机”, year: 2013})

(体系结构:Course, {name: “体系结构”})

Relationship in Cypher

```
-[name:type, {property_key:value, key:value}]->
```

例子:

```
-[:Takecourse]->
-[:Takecourse,{year:2014, grade:85}]->
```

Create in Cypher

```
CREATE (张飞:Student, {name: “张飞”,  major : “计算机”,
        year: 2013})

CREATE (体系结构:Course, {name: “体系结构”})

CREATE
  (张飞)-[:Takecourse,{year:2014, grade:85}]->(体系结构)
```

Match in Cypher

- 给定一个图的模板，找到所有匹配的子图

```
MATCH (x {name:”张飞”}) RETURN x
```

找具有name:”张飞”属性的顶点

```
MATCH (x:Student)-[:Takecourse]->(:Course {name:”体系结构”})
RETURN x
```

找到所有选修体系结构课程的学生顶点

```
MATCH
({name:”数据库”})<-[:Takecourse]-(x)-[:Takecourse]->({name:”体系结构”})
RETURN x
```

找到既选修体系结构又选修数据库的顶点

Match in Cypher

```
MATCH (x:Student)-[:Takecourse]->(:Course {name:”体系结构”})
WHERE x.year=2013
RETURN x
```

找到所有选修体系结构课程的学生顶点，
要求学生是2013年入学的

```
MATCH (x:Student)-[:Takecourse]->(:Course {name:”体系结构”})
WHERE NOT (x)-[:Takecourse]->(:Course {name:”操作系统”})
RETURN x
```

找到所有选修体系结构课程的学生顶点，
要求学生没有选修过操作系统

Match in Cypher

- 更多的使用
  - (a)-[*]->(b)
    有路径从a到b
  - (a)-[*3..5]->(b)
    有路径从a到b，路径最短3步，最长5步

Neo4j系统结构

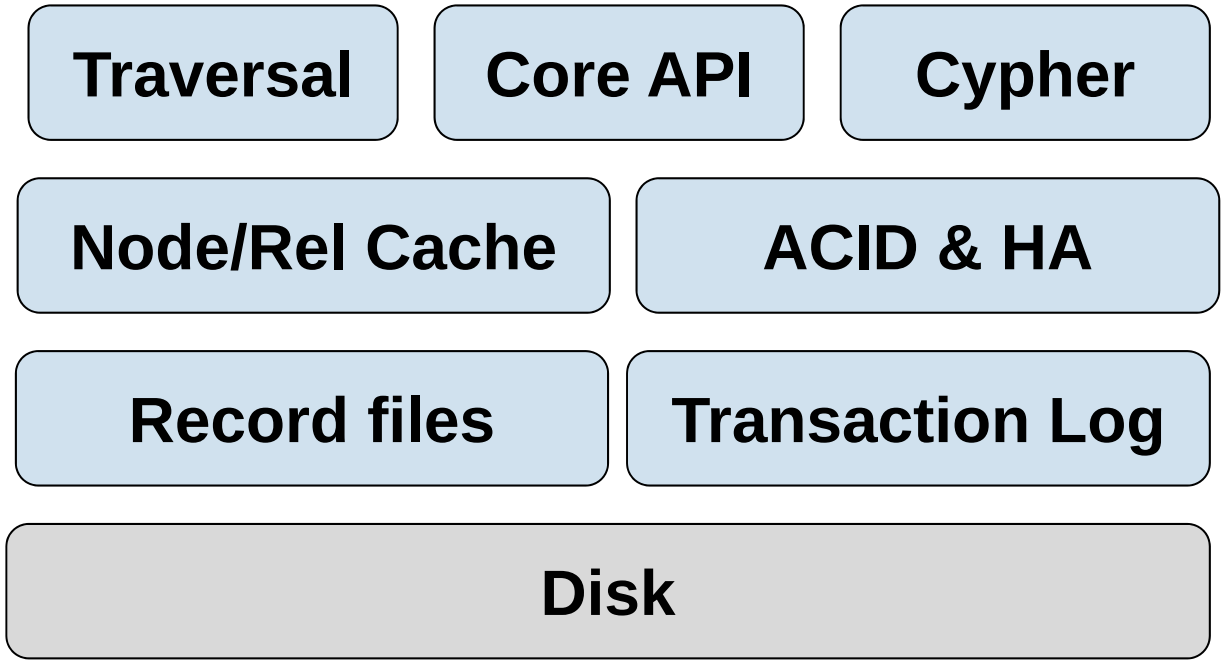

参照：“An Overview of neo4j Internals” presentation，
www.slideshare.net/thobe/an-overview-of-neo4j-internals

文件存储

- Node store文件，Relationship store文件，Property store文件
  - 分别存储所有node, relationship, property的文件
  - unique id
    - 每个node, relationship, property都有unique id
- Relationship双向链表
  - 同一个node的relationship形成一个双向链表
  - 链接指针为relationship id
  - 相应的node中记录链表的第一个relation id
- Property单向链表
  - 同一个node/relationship的property形成一个单向链表
  - 链接指针为next property id
  - 链表第一个property id存在对应的node/relationship中

Node和Relationship

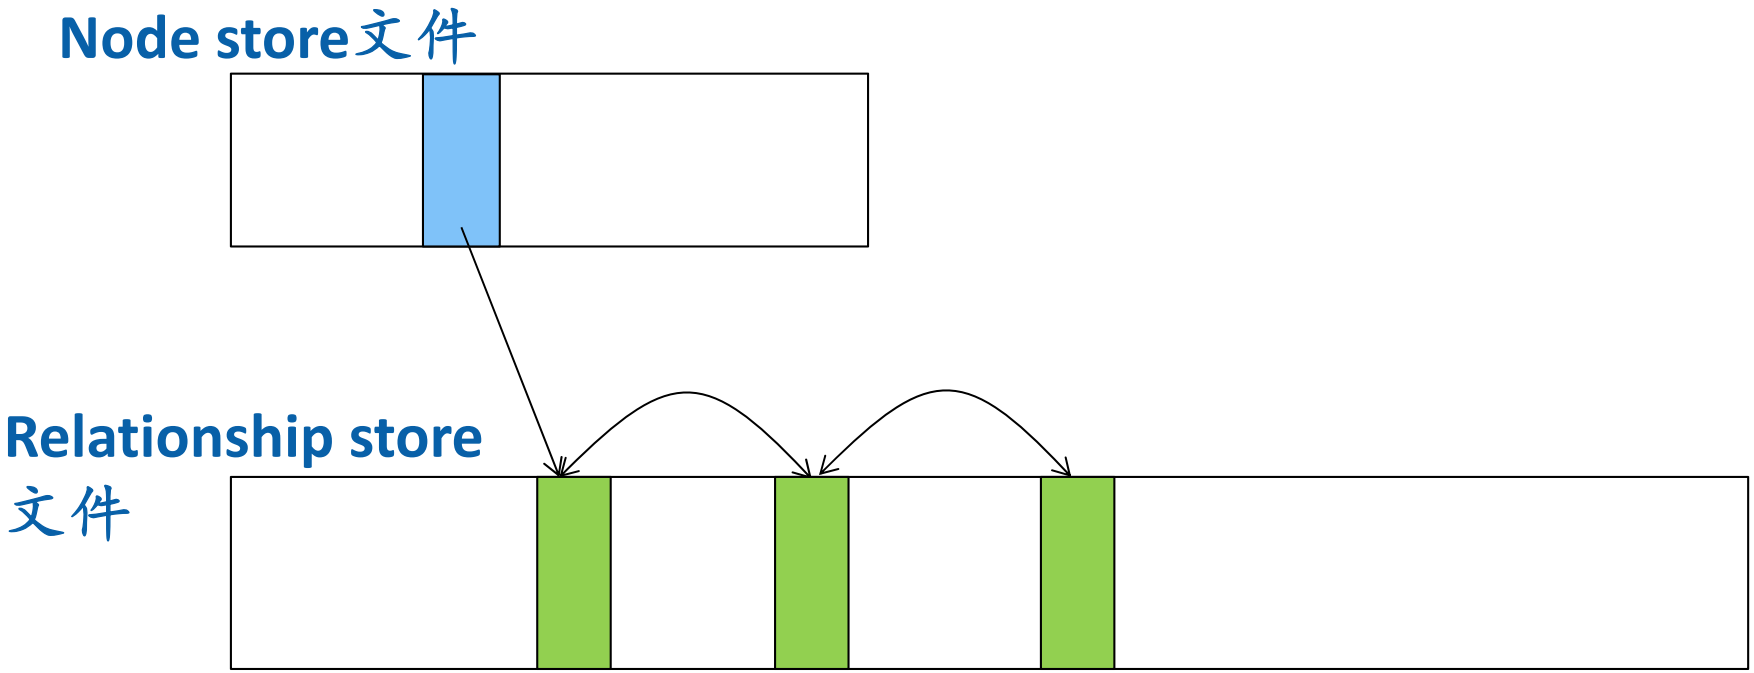

- 同一个node的relationship形成一个双向链表，链接指针为relationship id
- 相应的node中记录链表的第一个relation id

Node和Property

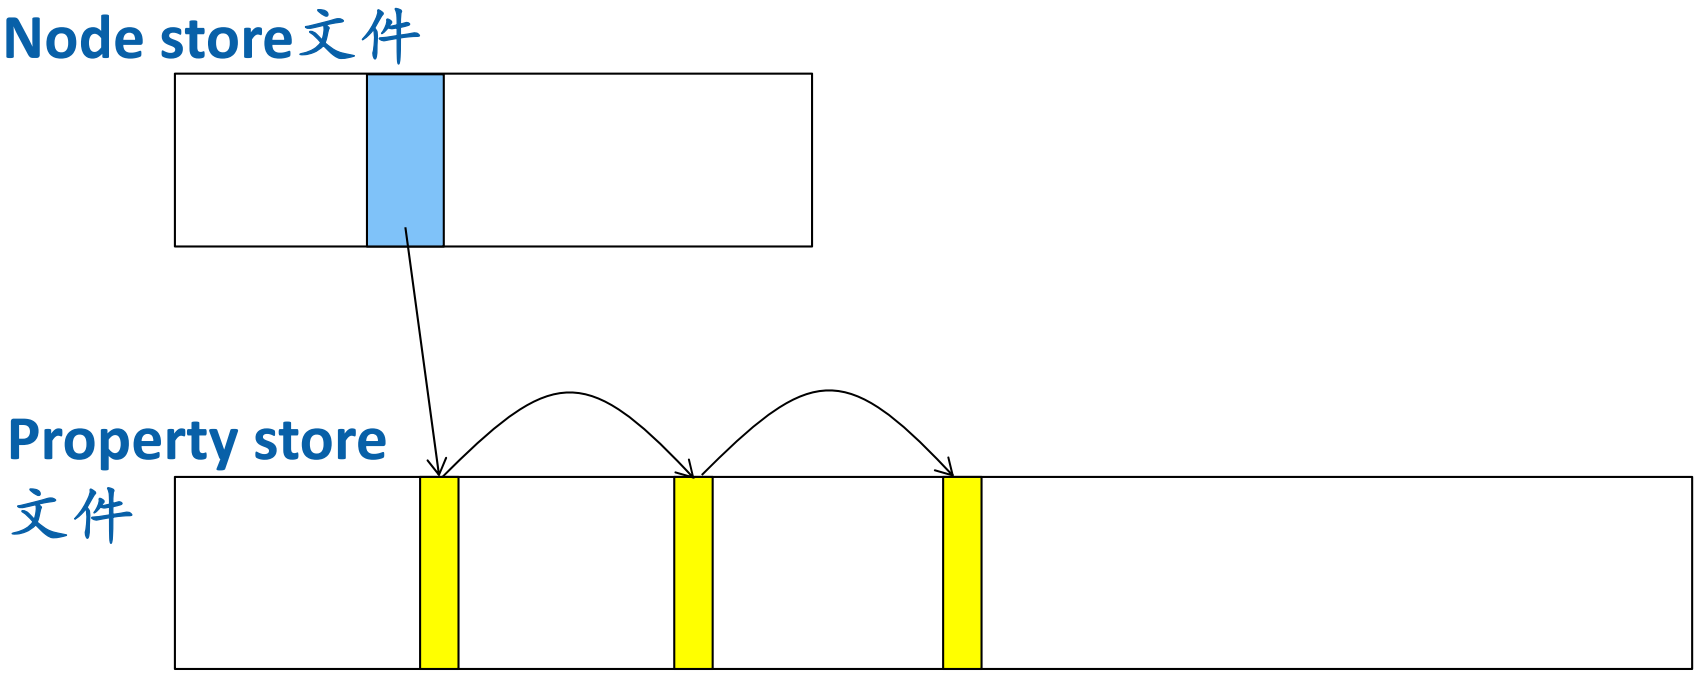

- 每个顶点node可能有多个property
- 同一个node的所有property形成一个单向链表，
  指针为next property id

Relationship和Property

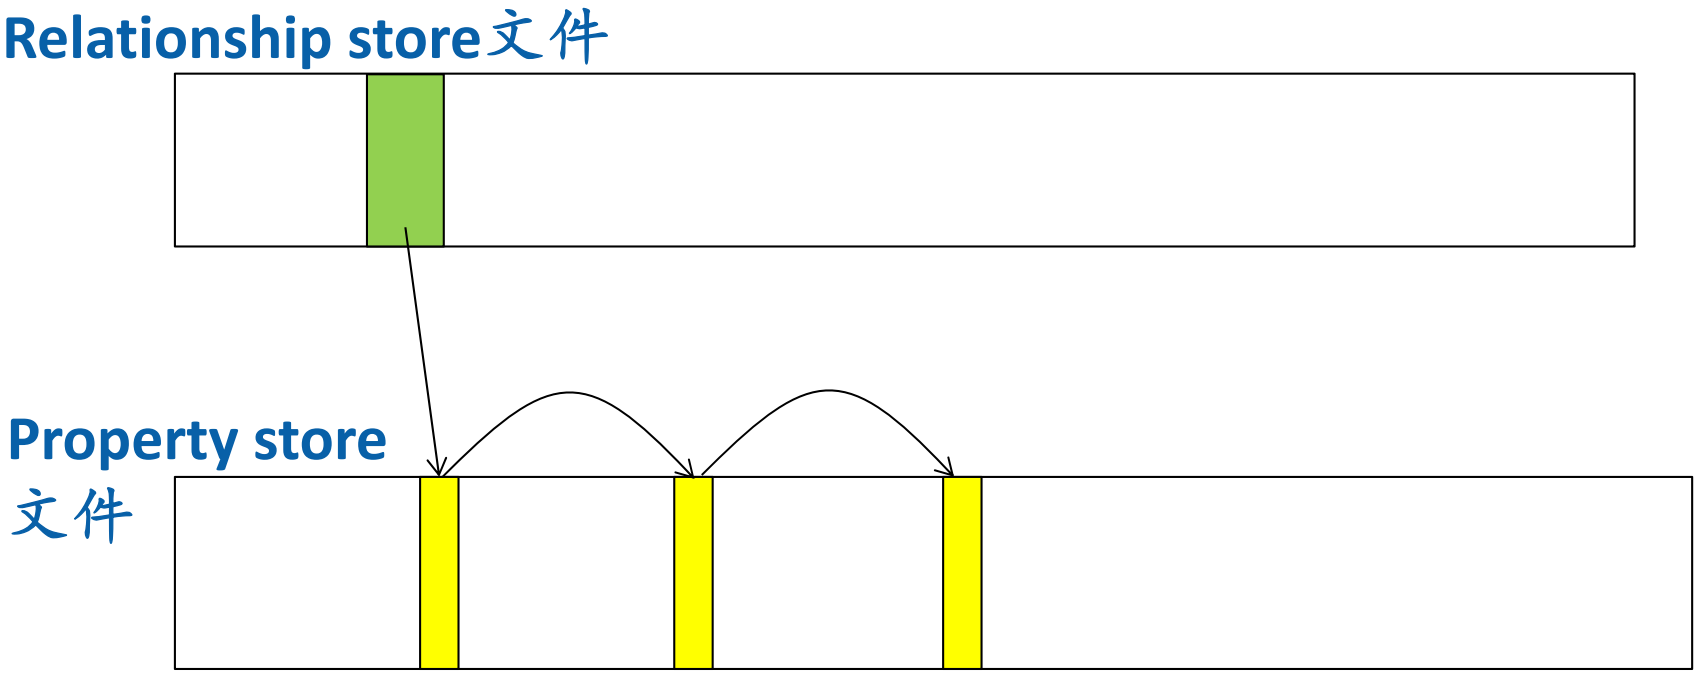

- 每个边relationship可能有多个property
- 同一个relationship的所有property形成一个单向链表，指针为next property id

内存缓冲区

- OS的文件系统有缓冲池
  - 文件page的缓冲
- Node/Rel cache
  - Neo4j对node, relationship, property缓冲
  - 内部的数据结构是以node和relationship为主要单位的
    - Property以key-value形式附加在node/relationship上

ACID

- 定义了transaction概念
  - 在embedded Java中显式使用
  - 在cypher中隐式使用
- 采用类似snapshot isolation的机制
  - 一个transaction的写先保存起来，直至transaction.finish()时，才真正尝试修改数据
  - 可能commit / rollback
- 采用Transaction log

Availability

- HA: High Availability的缩写
- 采用多副本
  - 主副本把transaction log发送到从副本
  - 从副本replay log从而执行同样的操作

JanusGraph：分布式图数据库

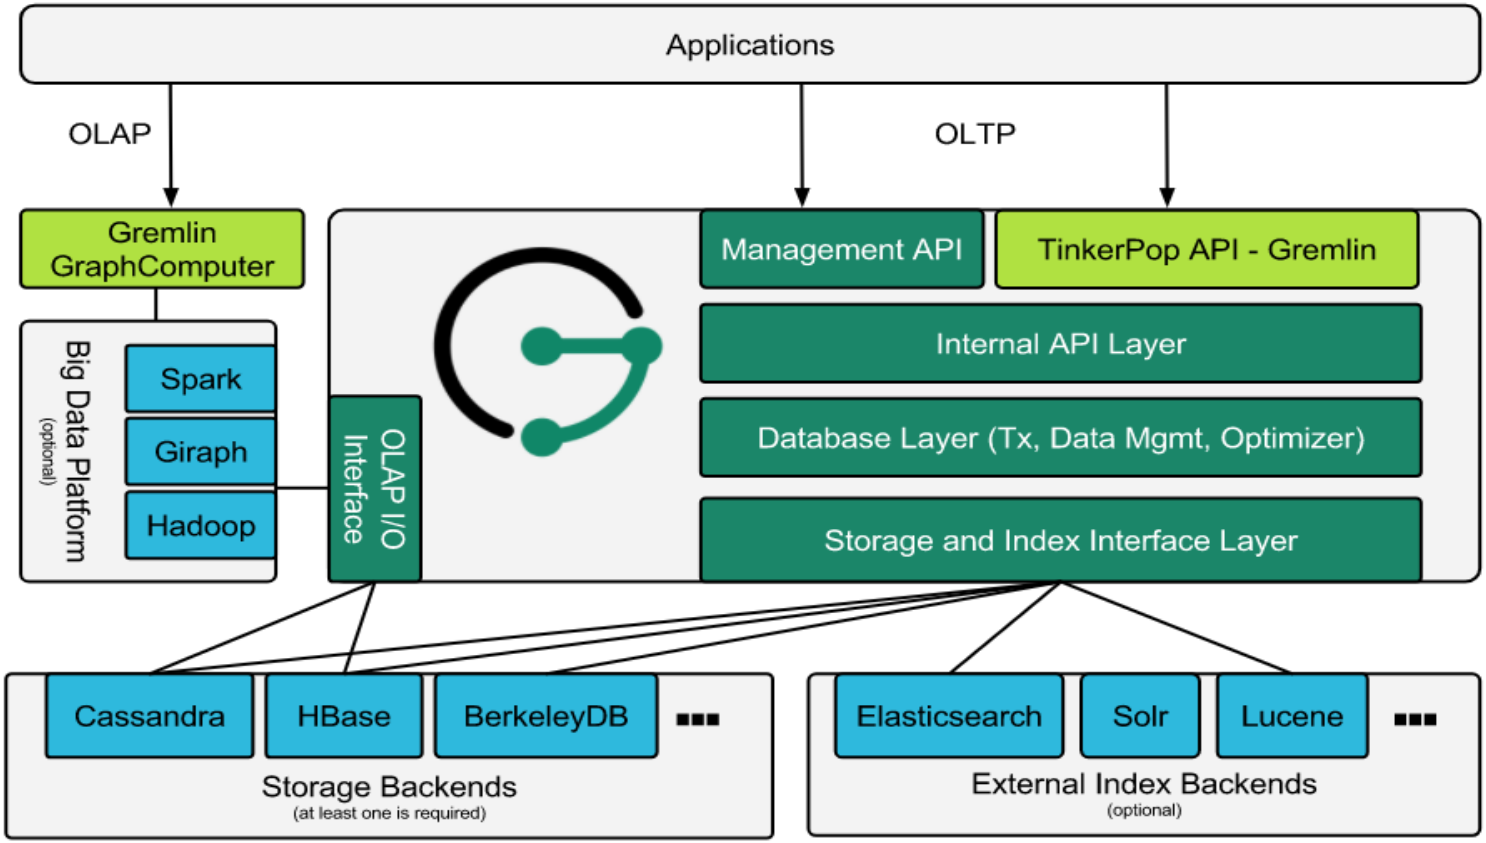

后端使用Key-Value Store来存储图数据

JanusGraph使用Gremlin查询语言

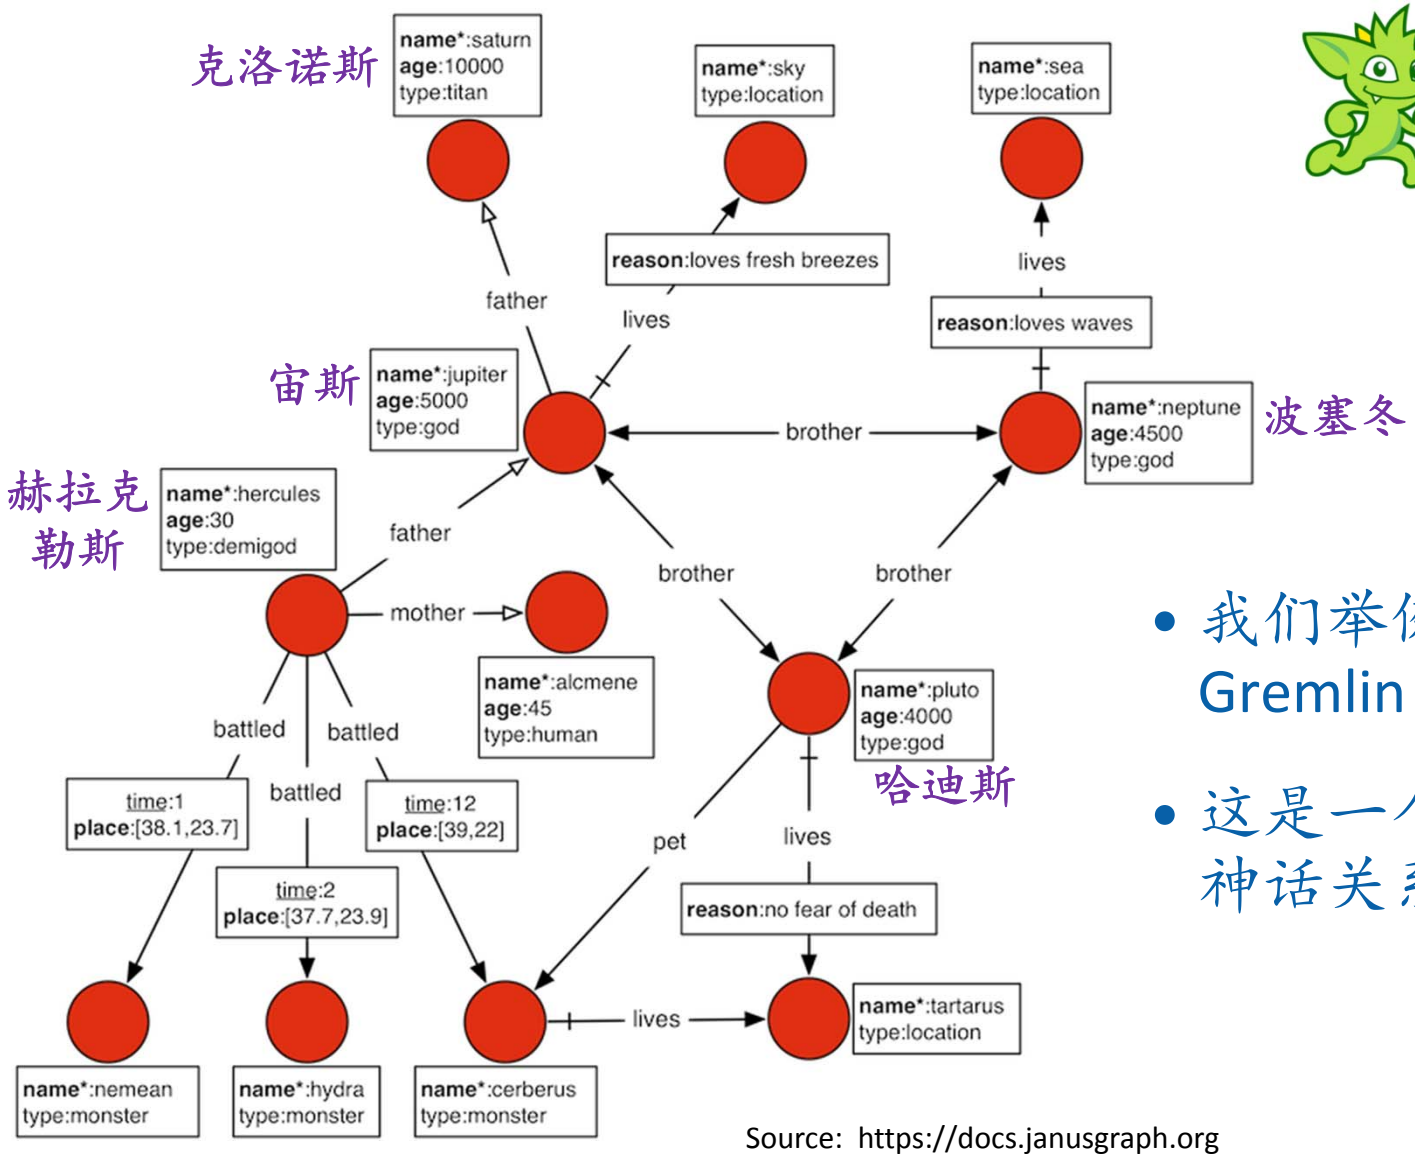

- 我们举例说明Gremlin
- 这是一个图，表示神话关系（罗马名）

Source: https://docs.janusgraph.org

Gremlin查询举例

```
gremlin> g.V().has('name', 'hercules').out('father').out('father').values('name')
==>saturn
```

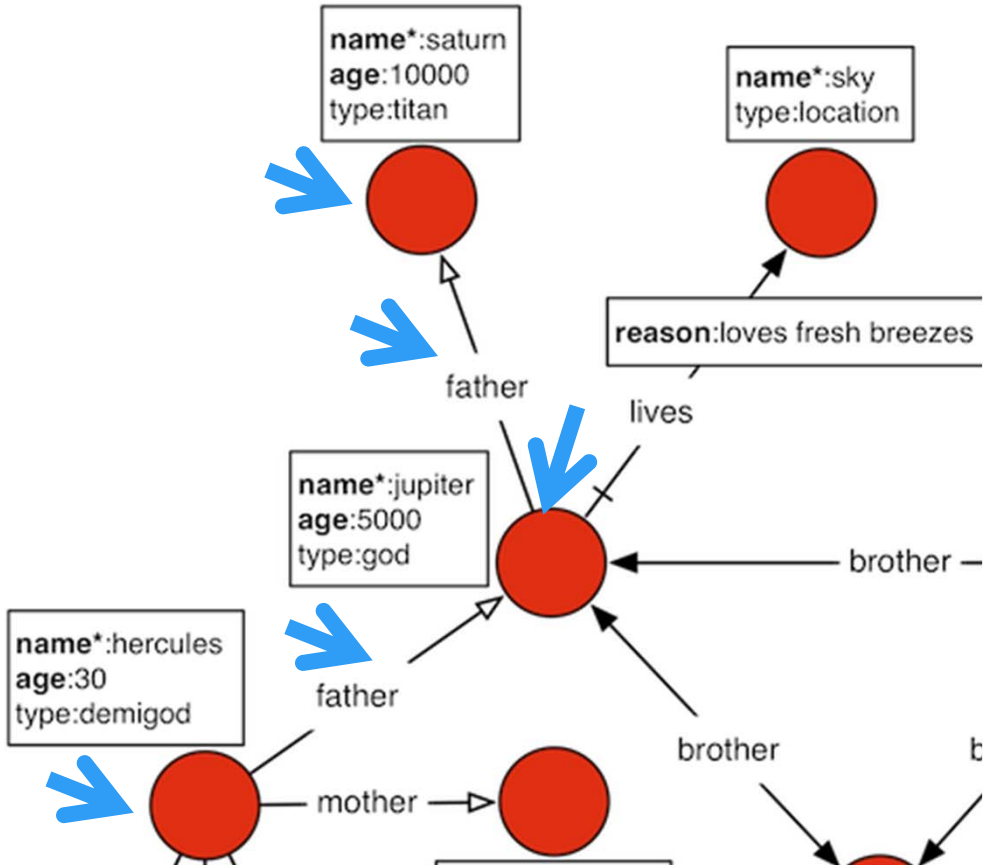

按照路径表达查询

- 上述查询可以分解如下

```
gremlin> g
==>graphtraversalsource[janusgraph[cql:127.0.0.1], standard]
gremlin> g.V().has('name', 'hercules')
==>v[24]
gremlin> g.V().has('name', 'hercules').out('father')
==>v[16]
gremlin> g.V().has('name', 'hercules').out('father').out('father')
==>v[20]
gremlin> g.V().has('name', 'hercules').out('father').out('father').values('name')
==>saturn
```

Gremlin查询举例

```
gremlin> g.V().has('name', 'hercules').repeat(out('father')).emit().values('name')
==>jupiter
==>saturn
```

沿着father出边不断访问下一个顶点

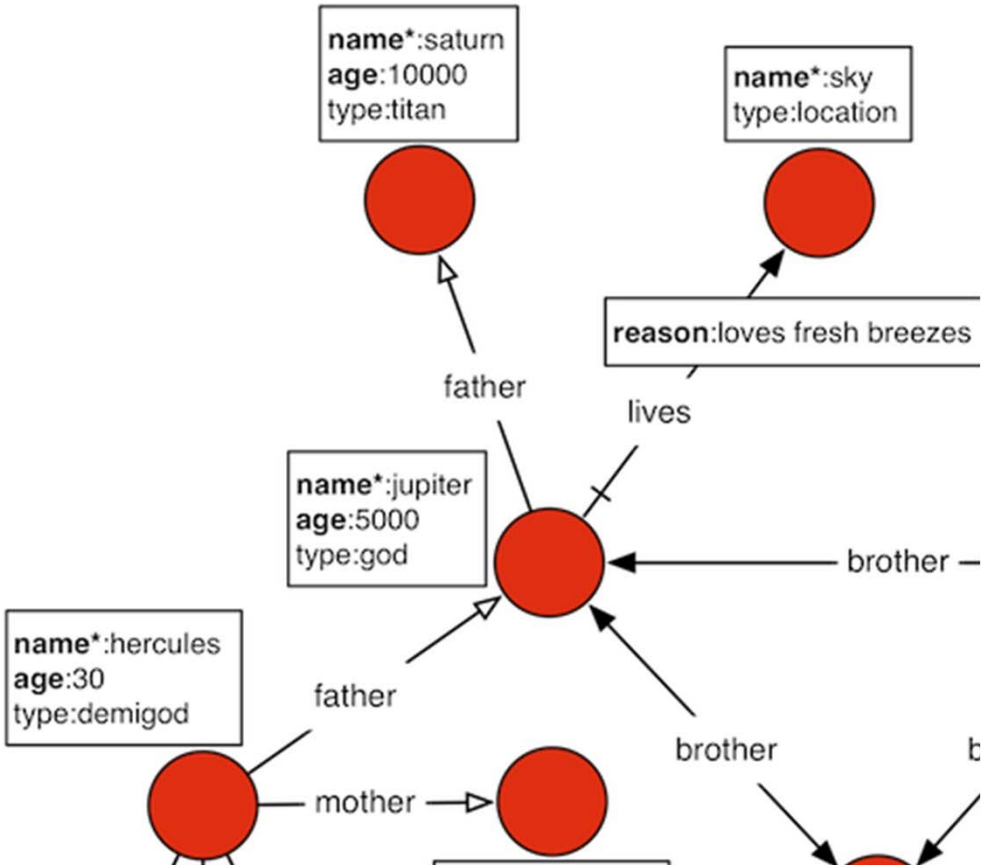

Gremlin查询举例

```
gremlin> g.V(hercules).out('father', 'mother').label()
==>god
==>human
gremlin> g.V(hercules).out('battled').label()
==>monster
==>monster
==>monster
```

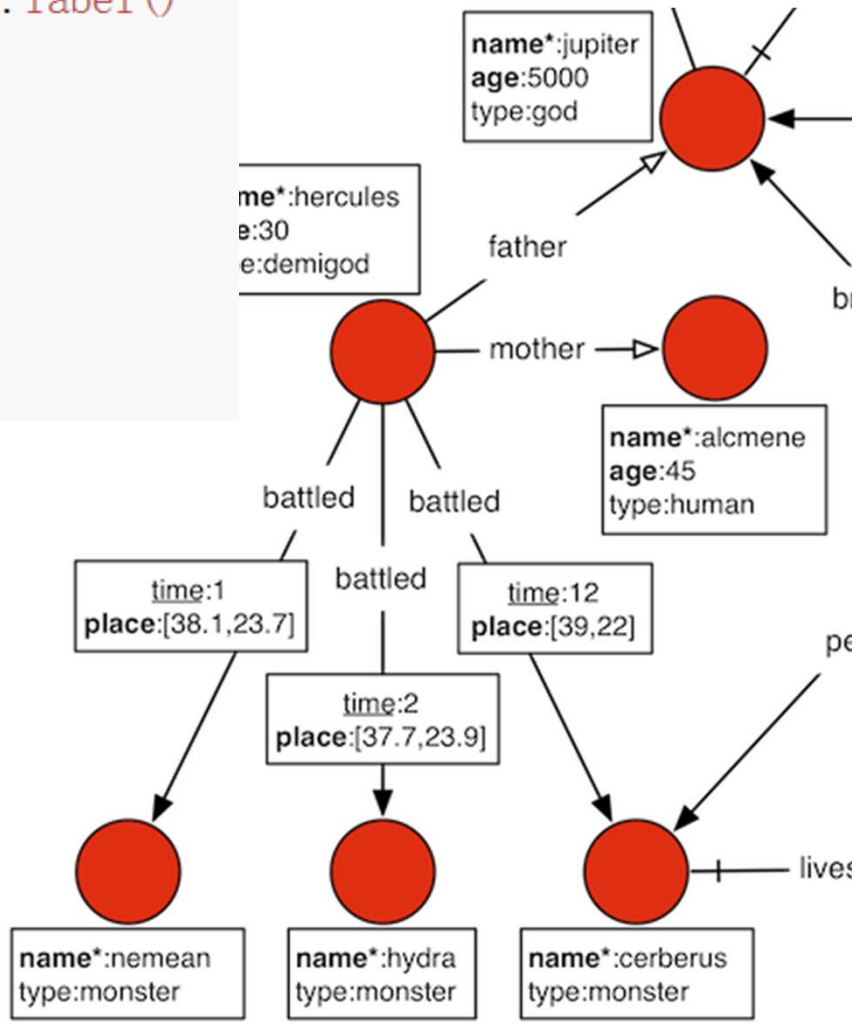

RDF

- RDF(Resource Description Framework)
  - W3C标准，广泛用于语义网络
- 每个RDF记录是三元组(subject 主, predicate 谓, object 宾)
  - 例如，
    (张飞，Takecourse，体系结构)
    (张飞，ISA， Student)
    (体系结构，ISA， Course)

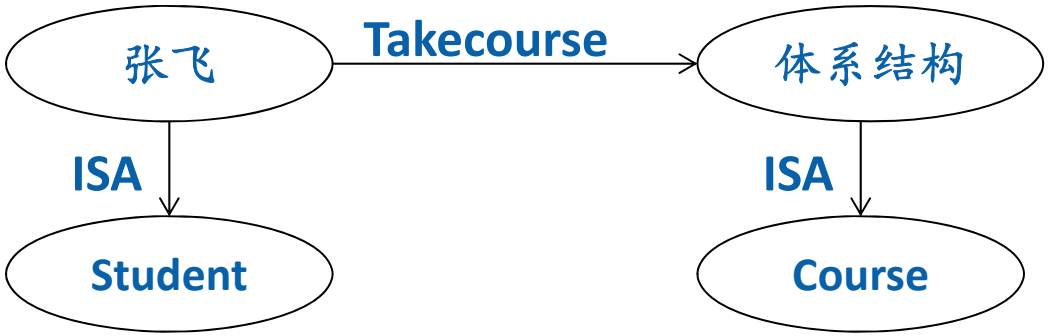

- subject和object都是图的顶点
- predicate表达了边的类型
- 多个RDF三元组表达一张图

SPARQL

- SPARQL（读作sparkle）：RDF的查询语言
  - 类似SQL Select语句
  - where语句规定一个子图模板
  - ?前缀代表变量，注意“.”

```
SELECT ?s
WHERE { ?s Takecourse 体系结构 .
        ?s ISA Student .
      }
```

Select结果：张飞

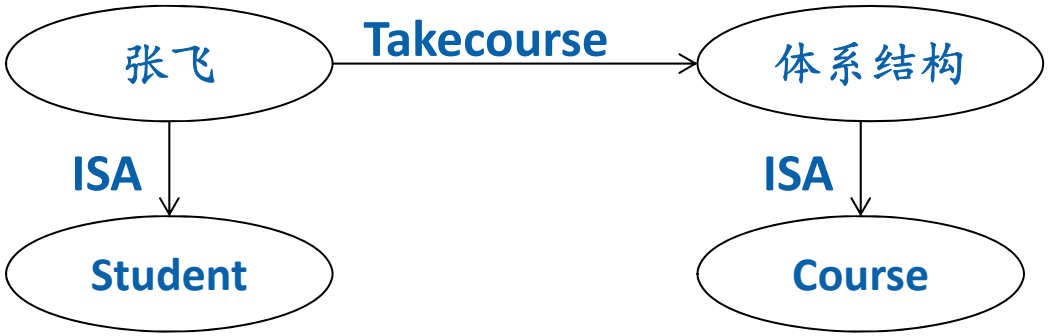

小结

- Document Store
  - 树状结构数据模型
    - JSON
    - Google Protocol Buffers
  - MongoDB
    - API and Query Model
    - Architecture
- 图存储系统(Graph Database)
  - 图数据模型
  - Neo4j
  - JanusGraph
  - RDF和SPARQL